



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

— **TELECOM** ESCUELA
TÉCNICA **VLC** SUPERIOR
DE INGENIERÍA DE
TELECOMUNICACIÓN

UNIVERSITAT POLITÈCNICA DE VALÈNCIA

Escuela Técnica Superior de Ingeniería de
Telecomunicación

Cancelación Activa de Ruido mediante Arquitecturas para
predicción de series temporales: Encoder-LSTM-Decoder

Trabajo Fin de Grado

Grado en Ingeniería Física

AUTOR/A: Atalaya Gómez, Miguel

Tutor/a: González Salvador, Alberto

CURSO ACADÉMICO: 2024/2025

Resumen

El presente Trabajo Fin de Grado tiene como objetivo el estudio y desarrollo de diferentes arquitecturas de redes neuronales aplicadas a la cancelación activa de ruido (ANC) en un entorno simulado que representará una sala de dimensiones cuadradas. Con esta simulación buscaremos imitar las condiciones realistas de propagación del sonido y las interacciones con las superficies de la sala, evaluando así el desempeño de distintos modelos de aprendizaje profundo en la tarea de supresión de ruido en tiempo real.

A lo largo del trabajo se estudiarán y se compararán distintas arquitecturas, entre ellas perceptrones multicapa (MLP), redes convolucionales (CNN) y redes recurrentes con memoria como LSTM, la gran protagonista de este proyecto.

Se evaluará el efecto de alimentar a las redes con espectrogramas frente al ruido en el dominio temporal, para determinar qué representación es más efectiva.

Los resultados de este estudio nos permitirán conocer en profundidad la capacidad de aprendizaje y generalización de cada tipo de red en el contexto ANC. En particular, se demuestra, como era de esperar, la superioridad de las redes LSTM para tareas que requieren memoria, como es el caso del seguimiento y la cancelación del ruido estacionario y variante.

Este trabajo contribuirá al entendimiento y diseño de modelos de inteligencia artificial aplicados a problemas de generación de señales sonoras y abrirá nuevos retos para el desarrollo de soluciones eficientes y adaptables a entornos reales.

Abstract

This Final Degree Project aims to study and develop different neural network architectures applied to active noise cancellation (ANC) in a simulated environment representing a square-shaped acoustic room. The simulation seeks to mimic realistic conditions of sound propagation and its interactions

with room surfaces, allowing us to evaluate the performance of various deep learning models in real-time noise suppression tasks.

Throughout the project, different architectures will be studied and compared, including multilayer perceptrons (MLP), convolutional neural networks (CNN), and recurrent networks with memory such as LSTM — the main focus of this project. Additionally, the effect of feeding the networks with frequency spectra versus raw noise in the time domain will be evaluated, in order to determine which representation is more effective.

The results of this study will provide deeper insight into the temporal learning and generalization capabilities of each type of network in the ANC context. In particular, we aim to demonstrate the superiority of LSTM networks for tasks that require memory retention, such as tracking and canceling persistent or sequential noise.

This project will contribute to a better understanding and optimal design of artificial intelligence models applied to acoustic problems and will pave the way for developing efficient and adaptable solutions in real-world environments.

Resum

Aquest Treball de Fi de Grau té com a objectiu l'estudi i desenvolupament de diferents arquitectures de xarxes neuronals aplicades a la cancel·lació activa de soroll (ANC) en un entorn simulat que representarà una sala acústica de dimensions quadrades. La simulació pretén imitar condicions realistes de propagació del so i les interaccions amb les superfícies de la sala, per tal d'avaluar el rendiment de diversos models d'aprenentatge profund en la tasca de supressió de soroll en temps real.

Al llarg del treball s'estudiaran i compararan diferents arquitectures, entre elles perceptrons multicapa (MLP), xarxes convolucionals (CNN) i xarxes recurrents amb memòria com LSTM, la gran protagonista d'aquest projecte. S'avaluarà l'efecte d'alimentar les xarxes amb espectres de freqüència front a soroll en brut en el domini temporal, per tal de determinar quina representació és més efectiva. Els resultats d'aquest estudi ens permetran conèixer més a fons la capacitat d'aprenentatge temporal i generalització de cada tipus de xarxa en el context de l'ANC. En particular, s'espera demostrar la superioritat de les xarxes LSTM per a tasques que requereixen retenció de memòria, com en aquest cas, el seguiment i cancel·lació de soroll persistent o seqüencial.

Aquest treball contribuirà a l'enteniment i disseny òptim de models d'intel·ligència artificial aplicats a problemes d'acústica i obrirà nous reptes per al desenvolupament de solucions eficients i adaptables a entorns reals.

RESUMEN EJECUTIVO

La memoria del TFG debe desarrollar en el texto los siguientes conceptos, debidamente justificados y discutidos, centrados en el ámbito de la **Ingeniería Física**

CONCEPTO (ABET)	Cumple?	Páginas
1. IDENTIFICAR:		
1.1. Planteamiento del problema y oportunidad	S	1–5
1.2. Condicionantes (normas, necesidades, requisitos)	S	23–28
1.3. Establecimiento de objetivos	S	4-5
2. FORMULAR:		
2.1. Generación de soluciones creativas	S	29–38
2.2. Evaluación de soluciones y decisión	S	38–65
3. RESOLVER:		
3.1. Cumplimiento de objetivos	S	69–70
3.2. Impacto y contribuciones	S	70–73

A mis padres, Lola y Paco, por su apoyo incondicional.
A mis hermanos, Carlos y Paco, por su ejemplo e inspiración.
A Carmela, por su compañía en el camino y su confianza.
A mis amigos en Cracovia, Toledo y Valencia, por estar siempre ahí.
Y a mi tutor, Alberto, por su esfuerzo y dedicación en este proyecto.

Índice general

I Memoria

1	Introducción	1
1.1	Planteamiento del problema y oportunidad	1
1.2	Estado del arte	2
1.3	Objetivos del trabajo	4
2	Marco Teórico	6
2.1	Fundamentos Acústicos de relevancia para el control activo de ruido	6
2.2	Fundamentos de Cancelación Activa	8
2.3	Fundamentos de Redes Neuronales	11
2.4	Arquitecturas comunes	12
2.5	Optimizadores	14
2.6	Redes Long Short-Term Memory.	16
2.6.1	Modelado en el dominio espectral complejo para redes LSTM	18
2.6.2	El problema del desvanecimiento del gradiente y su mitigación en las redes LSTM	20
2.6.3	Mecanismo de atención en LSTM	21
3	Desarrollo del proyecto	23
3.1	Preparación del sistema acústico	23
3.2	Preparación de los datos	26
3.2.1	Segmentación en ventanas temporales	26
3.2.2	Relación entre ventana y reverberación	27
3.2.3	Construcción del conjunto de entrenamiento	28
3.2.4	Transformación espectral	28
3.3	Modelos propuestos	29
3.3.1	Modelo 1: Perceptrón Multicapa (MLP)	29
3.3.2	Modelo 2: LSTM simple	29
3.3.3	Modelo 3: LSTM espectral con convoluciones (ConvSpecLSTM)	30
3.3.4	Modelo 4: LSTM espectral con proyección de características (ProjSpecLSTM)	31
3.3.5	Modelo 5: LSTM con mecanismo de atención (AttLSTM)	31
3.3.6	Modelo 6: LSTM espectral con convoluciones y atención (AttConvSpecLSTM)	32
3.4	Inferencia y reconstrucción de señal	33
3.4.1	Método de solape y suma	33
3.4.2	Consideraciones según tipo de arquitectura	34
3.4.3	Definición de Problema Estacionario	34

3.4.4	Métrica NMSE	35
3.5	Fases experimentales del proyecto	36
4	Resultados	38
4.1	Fase 1: Prueba con tonos aislados y combinados	38
4.1.1	Modelo 0: FxLMS clásico	40
4.1.2	Modelo 1: MLP	41
4.1.3	Modelo 2: LSTM	42
4.1.4	Modelo 3: ConvSpecLSTM	43
4.1.5	Modelo 4: ProjSpecLSTM	45
4.1.6	Modelo 5: AttLSTM	46
4.1.7	Modelo 6: AttConvSpecLSTM	47
4.1.8	Conclusión de resultados en la Fase 1	48
4.2	Fase 2: Evaluación sobre señales reales de benchmarking	49
4.2.1	Modelos de referencia: FxLMS y DeepANC	50
4.2.2	Modelo 1: MLP	51
4.2.3	Modelo 2: LSTM	51
4.2.4	Modelo 3: ConvSpecLSTM	55
4.2.5	Modelo 4: ProjSpecLSTM	57
4.2.6	Modelo 5: AttLSTM	59
4.2.7	Modelo 6: AttConvSpecLSTM	61
4.2.8	Conclusión de resultados de la fase 2	62
4.3	Fase 3: Evaluación frente a ruido altamente aleatorio	65
5	Conclusiones y trabajo futuro	69
5.1	Cumplimiento de los objetivos de investigación	69
5.2	Hallazgos principales	70
5.3	Contribuciones al Desarrollo Sostenible	70
5.4	Trabajos Futuros	71
	Bibliografía	73
II	Anexos	77
6	Anexo A: Explicaciones adicionales	78
6.1	Deconvolución de Wiener	79
6.2	Transformada Discreta de Fourier (DFT)	80
6.2.1	Definición formal	80
6.2.2	Propiedad de simetría hermítica	81
6.2.3	Transformada Rápida de Fourier (FFT)	81
6.3	Algoritmo LMS	81
6.4	Algoritmo FxLMS	83

Índice de figuras

1	Esquema general de un sistema de cancelación activa de ruido. En la posición determinada por “Mic” se produce la superposición de ondas dada por (2.2).	8
2	Esquema simple de una red MLP en la primera capa oculta.	12
3	Esquema de una Red Neuronal Convolutiva (CNN)	13
4	Esquema de las puertas de una LSTM. En este esquema, el bloque g es la celda candidata $\tilde{c}$. [20]	17
5	Sala acústica y configuración.	24
6	Respuestas impulsivas del camino primario (r_{ir1}) y secundario (r_{ir2}).	24
7	Simulación del funcionamiento correcto del sistema de cancelación activa para una sala ejemplo con una superposición de tonos simples como fuente de ruido.	26
8	Funcionamiento de <code>prepare_data()</code> . Si escogemos $hop = 128$, habrá un solape del 50 % entre bloques consecutivos	27
9	Ejemplo de input-target de entrenamiento para una sala de $RT60=0.212s$	28
10	Esquema básico de MLP.	29
11	Esquema básico de LSTM. Dentro del bloque LSTM se procesa como se vió en la figura 4	30
12	Esquema básico de ConvSpecLSTM.	31
13	Esquema básico de ProjSpecLSTM.	31
14	Esquema básico de AttLSTM.	32
15	Esquema básico de AttConvSpecLSTM.	33
16	Señal registrada en el micrófono durante la simulación con FxLMS.	41
17	Resultados del modelo MLP: evolución de la pérdida durante el entrenamiento, espectro residual y señal temporal en el micrófono de error.	42
18	Señal registrada con MLP y una fuente de ruido más monótona.	42
19	Resultados del modelo LSTM: evolución de la pérdida durante el entrenamiento, espectro residual y señal temporal en el micrófono de error.	43
20	Resultados del modelo ConvSpecLSTM: evolución de la pérdida durante el entrenamiento, espectro residual y señal temporal en el micrófono de error.	44
21	Resultados del modelo ProjSpecLSTM: evolución de la pérdida durante el entrenamiento, espectro residual y señal temporal en el micrófono de error.	45
22	Resultados del modelo AttSpecLSTM: evolución de la pérdida durante el entrenamiento, espectro residual y señal temporal en el micrófono de error.	46
23	Resultados del modelo AttConvSpecLSTM: evolución de la pérdida durante el entrenamiento, espectro residual y señal temporal en el micrófono de error.	47
24	Espectrogramas de las señales a utilizar.	50

25	Espectro ejemplo de SSN cancelado con MLP.	52
26	Resultados del modelo LSTM para señales Babble, Factory y SSN (de arriba a abajo). A la izquierda se muestra la señal en micrófono y a la derecha el espectro residual correspondiente.	53
27	Ejemplo del funcionamiento en SSN entrenado con Factory.	54
28	Espectro de cancelación en Factory entrenado con SSN para LSTM.	55
29	Espectro residual del modelo ConvSpecLSTM para la señal SSN.	56
30	Espectro de salida del modelo ProjSpecLSTM para la señal SSN.	57
31	Señal en el micrófono (arriba) y espectro de salida (abajo) del modelo ProjSpecLSTM para la señal Factory.	58
32	Espectro de cancelación en SSN entrenado con Babble para ProjSpecLSTM.	59
33	Resultados del modelo AttLSTM para señales Factory (arriba) y SSN (debajo). A la izquierda se muestra la señal en micrófono y a la derecha el espectro residual corres- pondiente.	60
34	Espectros para Babble (arriba) y SSN (abajo) entrenados con Factory para AttLSTM.	61
35	Micrófono de cancelación en SSN para AttConvSpecLSTM.	62
36	Espectro Señal de ruido en Lima.	65
37	Espectrograma de la señal de ruido de tráfico en Lima.	66
38	Espectrograma de la señal de ruido de tráfico en Uttar Pradesh.	67
39	Micrófono y espectro para la señal de ruido de tráfico de Uttar Pradesh con el modelo LSTM.	68
40	Diagrama de FxLMS	84

Índice de tablas

1	Comparación de desempeño y complejidad de los modelos evaluados en la Fase 1. . .	48
2	NMSE en dB reportado en [4] para los modelos FxLMS y DeepMCANC bajo reverberación moderada ($RT_{60} \approx 0,2$ s).	50
3	Rendimiento del modelo MLP para distintas señales de ruido en Fase 2.	51
4	Rendimiento del modelo LSTM para distintas señales de ruido en Fase 2.	52
5	Resultados de NMSE al evaluar el modelo LSTM entrenado con Factory sobre otras señales.	54
6	Resultados de NMSE al evaluar el modelo LSTM entrenado con SSN sobre otras señales.	55
7	Rendimiento del modelo ConvSpecLSTM para distintas señales de ruido en Fase 2. .	55
8	Comparación cruzada de rendimiento del modelo ConvSpecLSTM entrenado con distintas señales al evaluarse sobre señales distintas.	56
9	Rendimiento del modelo ConvSpecLSTM para distintas señales de ruido en Fase 2. .	57
10	Comparación cruzada de rendimiento del modelo ProjSpecLSTM entrenado con distintas señales al evaluarse sobre señales distintas.	59
11	Rendimiento del modelo AttLSTM para distintas señales de ruido en Fase 2.	59
12	Comparación cruzada de rendimiento del modelo AttSpecLSTM entrenado con distintas señales al evaluarse sobre señales distintas.	60
13	Rendimiento del modelo AttConvSpecLSTM para distintas señales de ruido en Fase 2.	61
14	Comparación cruzada de rendimiento del modelo AttConvSpecLSTM entrenado con distintas señales al evaluarse sobre señales distintas.	62
15	Comparación entre modelos temporales y espectrales. En negrita los mejores resultados para cada señal.	63
16	Comparación del efecto del mecanismo de atención. Valores promedio de NMSE en dB.	63
17	Comparación entre enfoques de codificación espectral.	63
18	Desempeño del modelo LSTM en entornos con diferentes tiempos de reverberación RT_{60}	67

Lista de Siglas

ANC	Cancelación Activa de Ruido
MCANC	Cancelación Activa de Ruido Multi Canal
NMSE	Error cuadrático medio normalizado
MLP	Perceptrón Multiacapa
CNN	Red Neuronal Convolucional
CRN	Red Convolucional Recurrente
LSTM	Red de memoria a corto-largo plazo
ARN	Red Recurrente dotada de “Atención”
BPTT	Retropropagación a lo largo del tiempo
DFT	Transformada Discreta de Fourier
FFT	Transformada Rápida de Fourier
iFFT	Transformada inversa Rápida de Fourier
LMS	Least-Mean Squares
FxLMS	Algoritmo “Filtered-x Least-Mean Squares”

Parte I

Memoria

Capítulo 1:

Introducción

1.1 Planteamiento del problema y oportunidad

La exposición constante a ambientes ruidosos constituye un problema cotidiano en numerosos entornos profesionales, industriales y urbanos. Esta presencia persistente de ruido indeseado repercute negativamente en la salud auditiva, la concentración, la comunicación efectiva y la calidad de vida en general. En este contexto, la *cancelación activa de ruido* (ANC, por sus siglas en inglés) ha emergido como una solución tecnológica eficaz orientada a reducir el impacto del ruido ambiental mediante la generación de una señal opuesta que interfiera destructivamente con la señal de ruido original. A diferencia de los métodos pasivos basados en barreras físicas, la ANC actúa directamente sobre la señal acústica, siendo especialmente efectiva en las bajas frecuencias, donde las soluciones pasivas resultan ineficientes o impracticables.

Los sistemas ANC se encuentran actualmente implementados en una amplia gama de dispositivos y sectores. En la electrónica de consumo, destacan su incorporación en auriculares y cascos inteligentes, donde el objetivo es mejorar la experiencia auditiva en entornos urbanos o durante desplazamientos. En el ámbito automotriz, se aplican en el interior de vehículos para reducir vibraciones y ruidos estructurales, contribuyendo al confort del usuario. Otros casos de uso relevantes incluyen entornos aeronáuticos, quirófanos, sistemas de climatización o maquinaria industrial, donde la reducción de ruido repercute en la seguridad, la eficiencia y el bienestar de los operarios.

El control activo de ruido (ANC) consiste en generar una señal acústica de igual amplitud pero en antifase (oposición de fase de 180°) respecto al ruido no deseado, logrando su cancelación por interferencia destructiva. A diferencia del control pasivo —que utiliza materiales absorbentes (espumas, fibras) o barreras físicas—, el ANC es especialmente eficaz en frecuencias bajas (20–500 Hz), donde los métodos pasivos requieren materiales excesivamente gruesos y pesados para lograr una atenuación significativa (la longitud de onda a 100 Hz es de ~ 3.4 m, lo que exige absorbentes de espesor considerable). La principal ventaja del ANC radica en su naturaleza adaptativa: mediante algoritmos los sistemas se ajustan en tiempo real para compensar cambios en las características del ruido (frecuencia, amplitud o dirección de propagación). Esta adaptabilidad lo hace ideal para entornos dinámicos, como el interior de un vehículo en movimiento o espacios con fuentes de ruido variables.

Históricamente, los sistemas de ANC se han basado en algoritmos adaptativos que adaptan modelos lineales, siendo el algoritmo *Least Mean Squares* (LMS) y su variante multicanal FxLMS (Filtered-x LMS) los enfoques predominantes. Estas técnicas presentan claras ventajas en cuanto a su bajo coste computacional, facilidad de implementación en tiempo real y estabilidad en entornos controlados [1]. No obstante, su rendimiento se ve comprometido ante condiciones acústicas complejas, como aquellas caracterizadas por reflexiones o no linealidades. En tales escenarios, la capacidad de estos modelos para adaptarse dinámicamente y generar una cancelación efectiva se ve limitada, lo cual ha motivado la búsqueda de soluciones más sofisticadas.

El campo de la cancelación activa de ruido se ha enfocado recientemente en explorar el potencial del aprendizaje automático, y en particular del aprendizaje profundo [2], como herramienta para modelar de manera más precisa y flexible las relaciones entre las señales de entrada y salida de los sistemas acústicos implicados. Las redes neuronales profundas, como las convolucionales (CNN), recurrentes como LSTM o arquitecturas híbridas, han demostrado una notable capacidad para aprender representaciones complejas directamente a partir de datos, superando las limitaciones impuestas por los modelos lineales clásicos en numerosos contextos. Este enfoque ha abierto la puerta al desarrollo de sistemas ANC más robustos, capaces de operar en entornos acústicamente desafiantes sin necesidad de un modelado explícito del sistema. No obstante, esta nueva generación de soluciones conlleva también ciertas desventajas prácticas. En muchos casos, los modelos propuestos en la literatura presentan una alta complejidad computacional, tanto por el número de parámetros de las redes como por el preprocesado exhaustivo que se requiere sobre la señal acústica de entrada. A menudo, estos modelos dependen de representaciones espectrales de alta resolución o arquitecturas con millones de parámetros que dificultan su implementación en tiempo real o en dispositivos embebidos con recursos computacionales limitados. Este sobredimensionamiento técnico supone una barrera significativa para su adopción en aplicaciones prácticas del mercado de consumo.

En este contexto, se identifica una oportunidad clara: analizar y evaluar si es posible alcanzar un rendimiento comparable al de los modelos actuales del estado del arte mediante arquitecturas más simples y eficientes, tanto en términos de estructura como de preprocesado. Esta línea de trabajo resulta especialmente relevante para extender la aplicabilidad de la cancelación activa de ruido basada en inteligencia artificial a entornos con restricciones computacionales o de latencia, como dispositivos móviles, auriculares inalámbricos, wearables o sistemas embebidos de bajo consumo. Así, la simplificación de modelos no solo tiene un impacto en términos de viabilidad técnica, sino que también contribuye al desarrollo de soluciones más sostenibles, escalables y accesibles para la sociedad.

1.2 Estado del arte

Tradicionalmente, las soluciones ANC han estado dominadas por algoritmos adaptativos con modelos lineales, como el algoritmo de filtrado X LMS (Filtered X Least Mean Squares, FXLMS) y su variante multicanal como MFxLMS (Multiple Error FXLMS) propuesto por [3], que estableció las bases para sistemas ANC modernos al generalizar la adaptación de filtros para múltiples sensores y actuadores.

Estos métodos presentan un bajo coste computacional y son relativamente sencillos de implementar para su funcionamiento en tiempo real [1]. Sin embargo, en entornos complejos y no lineales, como los encontrados en escenarios con múltiples fuentes, transductores y reflexiones acústicas, su rendimiento es limitado. La linealidad del modelo, la baja capacidad de representación y su sensibilidad a retardos

y errores de modelado son factores críticos que afectan a su efectividad.

Un hito clave en la aplicación de técnicas de aprendizaje profundo a la cancelación activa de ruido multicanal (MCANC) es el trabajo de Zhang y Wang, titulado *DeepMCANC: A Deep Learning Approach to Multi-Channel Active Noise Control* [4]. En esta propuesta, los autores desarrollan una arquitectura basada en una red convolucional-recurrente (CRN) capaz de predecir múltiples señales antirruído a partir de señales de referencia acústica, lo que permite generar zonas de silencio o cancelación en entornos acústicos complejos. A diferencia de los métodos clásicos como el FxLMS, que requieren un modelado explícito de la función de transferencia del entorno, DeepMCANC aprende de forma supervisada la transformación directa entre señales de entrada (referencia) y salida (anti-ruído), eliminando así la dependencia de modelos acústicos lineales aproximados. Esta arquitectura permite estimar simultáneamente múltiples señales de ruido, facilitando así la implementación de sistemas multicanal con múltiples micrófonos de error y altavoces distribuidos espacialmente. Uno de los aspectos más destacados de este trabajo es la versatilidad del modelo, que ha sido evaluado en seis escenarios acústicos reales (como entornos urbanos, salas de reuniones o estaciones de metro) con distintas configuraciones de entrada y salida. En estas pruebas, el modelo alcanzó valores medios atenuación medidos mediante la *Normalized Mean Square Error* (NMSE) que oscilan entre aproximadamente 11 y 15 dB para las configuraciones más efectivas. Estos resultados representan una alternativa respecto a los métodos tradicionales, especialmente en entornos complejos con múltiples fuentes de ruido y condiciones acústicas variables.

Por otra parte, DeepMCANC demostró una notable capacidad de generalización frente a tipos de ruido no utilizados durante el entrenamiento, así como una buena adaptación a la no linealidad de los altavoces, y a las variaciones espaciales controladas en la ubicación de los sensores. Esta adaptabilidad hace del modelo una solución robusta para aplicaciones reales de ANC en escenarios complejos. No obstante, esta mejora en el rendimiento tiene un coste computacional considerable. La arquitectura cuenta con aproximadamente 8 millones de parámetros entrenables, lo que implica una carga significativa en cuanto a almacenamiento, procesamiento y latencia, dificultando su implementación directa en sistemas embebidos o en aplicaciones con restricciones de tiempo real. Esta observación abre la puerta a una línea de investigación centrada en la simplificación de estas arquitecturas, buscando modelos más ligeros y eficientes que puedan mantener un rendimiento competitivo con un coste computacional mucho menor. Esta es precisamente la motivación principal que sustenta el presente trabajo.

Tras el desarrollo de DeepMCANC, uno de los avances más relevantes en este tema es el trabajo de Zhang, Pandey y Wang titulado “*Low-Latency Active Noise Control Using Attentive Recurrent Network*” [5]. Este artículo aborda una limitación crítica para la aplicación práctica de modelos profundos en ANC: la latencia. Los autores proponen una arquitectura denominada *Attentive Recurrent Network* (ARN), que integra mecanismos de atención en una red recurrente para realizar ANC en el dominio temporal. El énfasis principal radica en reducir la latencia del sistema para cumplir con la restricción de causalidad inherente a los sistemas ANC. El modelo utiliza marcos temporales cortos y aplica un entrenamiento compensado por retardo (*delay-compensated training*) junto con un método revisado de *overlap-add* en la síntesis de la señal. Gracias a esto, el sistema logra una latencia efectiva cercana a cero, e incluso ligeramente negativa, sin sacrificar la capacidad de cancelación. Este resultado es fundamental, ya que la latencia nula o negativa permite que la señal de antirruído llegue al micrófono al mismo tiempo que el ruido primario, superando así una de las restricciones más exigentes en el diseño de ANC. En este trabajo los autores entrenan dos versiones del modelo ARN

para evaluar la escalabilidad y la capacidad del sistema: una con aproximadamente 8,8 millones de parámetros y otra con 15,9 millones. Aunque la complejidad paramétrica de ARN es igual o incluso superior a la de DeepMCANC (que cuenta con alrededor de 8 millones de parámetros), la diferencia fundamental radica en el enfoque: ARN está específicamente diseñado para minimizar la latencia sin comprometer la eficacia de cancelación. Los resultados experimentales demuestran que ARN mantiene una calidad de cancelación comparable a modelos más complejos, pero con una velocidad de procesamiento adecuada para aplicaciones en tiempo real. Además, el uso del mecanismo de atención mejora la capacidad del modelo para enfocar componentes relevantes del ruido, manteniendo su eficacia incluso frente a señales no vistas durante el entrenamiento.

Un avance reciente en la adaptabilidad de sistemas ANC a entornos dinámicos es el trabajo de Im et al. [6], que propone un modelo de dos etapas basado en redes neuronales para estimar en tiempo real la ruta secundaria bajo condiciones variables. A diferencia de los métodos clásicos que requieren inyección de ruido auxiliar para la estimación del ruido secundario, este enfoque utiliza:

- Un MLP simple para predecir el tiempo de llegada (n_s) del sonido, crítico para la alineación temporal.
- Un MLP profundo (capas 50-100-200) para modelar la respuesta al impulso ($s_s(n)$) posterior, capturando reflexiones y no linealidades.

La clave de su innovación radica en la separación de las tareas (tiempo vs. forma de onda), demostrando superioridad frente a modelos *end-to-end*. En pruebas con un conducto acústico y un micrófono móvil, el sistema mantuvo una atenuación de 9.3 dB incluso ante cambios bruscos (movimiento súbito de la posición del sensor), superando las limitaciones de adaptación del FxLMS tradicional. Esto representa un enfoque diferente a los modelos anteriormente implementados basados en aprendizaje automático para ANC.

Estas investigaciones y la oportunidad ya nombrada en el apartado anterior nos permite formular los objetivos a realizar a lo largo de este trabajo:

1.3 Objetivos del trabajo

Este trabajo parte de la hipótesis de que es posible simplificar significativamente la arquitectura y en consecuencia el coste del procesamiento de los modelos de cancelación activa de ruido multicanal sin comprometer sustancialmente su rendimiento. Para abordar esta hipótesis, se establecen los siguientes objetivos principales:

- Estudiar modelos en base a modelos de referencia como DeepMCANC [4], analizando sus requisitos computacionales y su arquitectura.
- Diseñar modelos alternativos con arquitecturas más simples (por ejemplo, LSTM unidireccionales, versiones reducidas de convolucionales o modelos híbridos espectrales), optimizados para ejecutarse con menos recursos.
- Realizar un análisis de diferentes representaciones de la señal en la entrada a la red (temporal, espectral, real-imaginaria, etc.), estudiando el impacto del preprocesado sobre la eficiencia y rendimiento de los modelos.

- Comparar el rendimiento de los modelos propuestos con las arquitecturas complejas del estado del arte mediante experimentos cuantitativos en entornos simulados, evaluando su capacidad de generalización y su coste computacional.
- Contribuir a la discusión sobre la viabilidad de aplicar modelos ligeros de aprendizaje profundo en ANC, favoreciendo su implementación práctica en dispositivos con recursos limitados.

En resumen, este trabajo se enmarca en una oportunidad clara: el rediseño y análisis crítico de soluciones de cancelación de ruido basadas en inteligencia artificial desde una perspectiva de eficiencia y simplicidad arquitectónica. Los resultados obtenidos podrán servir como base para futuras implementaciones reales de ANC en sistemas embebidos, donde el equilibrio entre rendimiento y coste computacional es esencial.

Capítulo 2:

Marco Teórico

2.1 Fundamentos Acústicos de relevancia para el control activo de ruido

Para entender y profundizar en la implementación y evaluación de las redes neuronales aplicadas a la cancelación activa de ruido, es necesario conocer primero los fundamentos de la acústica y las técnicas de supresión de ruido. Los sistemas ANC se basan en generar señales que interfieren destructivamente con el ruido indeseado para reducir su impacto. Su eficacia depende en gran medida del correcto modelado del entorno acústico, como una sala cerrada con características acústicas específicas, como la propagación y reflexión del sonido. Comprender estos fenómenos físicos así como su caracterización para su utilización en entornos de simulación nos permite entender mejor el funcionamiento de las arquitecturas que vamos a diseñar y comparar distintas propuestas en un entorno controlado.

La propagación del sonido en espacios cerrados, asumiendo que no hay atenuación por absorción de energía del aire, está influenciada principalmente por la interacción de las ondas sonoras con las superficies del entorno. Estas interacciones generan reflexiones que afectan la percepción del sonido para un humano, especialmente en salas pequeñas donde los efectos de reverberación están más pronunciados.

El método de las imágenes propuesto por Allen y Berkley en 1979 [7] ofrece una aproximación eficiente para modelar estos efectos. Este método simula la respuesta impulsiva entre dos puntos en una sala rectangular utilizando fuentes virtuales o “imágenes” que representan el efecto de las superficies reflectantes sobre la fuente sonora original. La posición y orientación de estas imágenes se determinan mediante reflexiones especulares, asumiendo que las paredes son rígidas y las reflexiones son ideales. La respuesta impulsiva resultante se puede convolucionar con una señal sonora producida por una fuente para simular la reverberación del sonido en un punto de la sala.

Cuando el sonido se propaga en una sala, no solo se refleja en las paredes, sino que parte de su energía se pierde debido a la absorción por los materiales que recubren esas superficies. La absorción acústica mide qué porcentaje de energía sonora es absorbida y no reflejada, y varía según el tipo de material (por ejemplo, una pared lisa refleja más que una cortina o alfombra).

Esta absorción influye directamente en el tiempo de reverberación, conocido como RT60, que es el

tiempo que tarda el sonido en reducir su intensidad en 60 decibelios después de que la fuente sonora ha cesado. Un RT60 alto indica una sala muy reverberante, mientras que un RT60 bajo indica un espacio más absorbente y con menos eco.

Este parámetro es esencial para diseñar sistemas de cancelación activa de ruido, ya que la reverberación afecta la forma en que las señales de ruido se propagan y se perciben, y por tanto condiciona la dificultad de la tarea para los sistemas de control activo, en particular los basados en modelos con redes neuronales.

Para estimar el RT60 de una sala, se utiliza la fórmula de Sabine [8]:

$$RT60 = \frac{0,161V}{A}, \quad (2.1)$$

donde:

- V es el volumen de la sala en metros cúbicos,
- A es la absorción total efectiva de la sala, calculada como la suma del producto del área de cada superficie por su coeficiente de absorción.

Es importante destacar que la fórmula de Sabine se basa en coeficientes de absorción acústica que son valores promedio por banda de frecuencia para cada superficie. Esto se debe a que la capacidad de absorción varía con la frecuencia del sonido: algunos materiales absorben mejor las frecuencias bajas, mientras que otros son más efectivos con las altas. Por ello, para obtener un cálculo realista del tiempo de reverberación, se emplean estos coeficientes promedio que representan la absorción típica en diferentes rangos de frecuencia.

Además, la relación entre las dimensiones de la sala y los coeficientes de absorción no siempre es directa ni sencilla de determinar solo con fórmulas clásicas como la de Sabine. Estudios recientes, como el de [9], han demostrado que es posible utilizar funciones de transferencia acústicas combinadas con técnicas de aprendizaje automático para estimar tanto las dimensiones de la sala como los coeficientes de absorción con mayor precisión. Este enfoque permite una caracterización más detallada y adaptada a entornos reales, donde la variabilidad y complejidad de las superficies afectan la absorción acústica y, por ende, el tiempo de reverberación.

En general, una superficie suele absorber mejor las frecuencias cuya longitud de onda es menor que el grosor o la profundidad del material absorbente. Esto se debe a que las ondas sonoras de baja frecuencia, que tienen longitudes de onda más largas, requieren materiales más gruesos para ser absorbidas eficazmente. Por el contrario, las frecuencias altas, con longitudes de onda más cortas, son más fácilmente atenuadas por superficies delgadas o materiales porosos [10].

La posición relativa de las fuentes sonoras y los micrófonos dentro de la sala es fundamental en la simulación acústica y en la cancelación activa de ruido. Esto se debe a que la distancia entre la fuente y el micrófono determina el retardo temporal (delay) con el que el sonido directo y sus reflexiones llegan al micrófono.

Este retardo afecta la sincronización necesaria para que el sistema de cancelación genere la señal opuesta al ruido en el momento justo. Si el retardo no se considera correctamente, la señal de cancelación puede llegar desfasada, reduciendo la eficacia del proceso. Por eso, la correcta ubicación de

fuentes y micrófonos es clave para modelar con precisión el entorno acústico y optimizar el rendimiento de las redes neuronales aplicadas a ANC.

Aunque el método de las imágenes es una herramienta eficiente para simular la acústica en salas rectangulares, presenta algunas limitaciones importantes. Entre ellas está la suposición de que las paredes son rígidas y que las reflexiones son especulares y perfectas. Estas simplificaciones no capturan fenómenos acústicos más complejos, como la difusión del sonido, la absorción no uniforme en las superficies o las pérdidas por materiales no homogéneos. Por ello, el modelo puede no reflejar con precisión ciertas características del sonido en entornos reales más complejos. Sin embargo, para los fines de evaluación y comparación de diferentes arquitecturas de redes neuronales en cancelación activa de ruido, esta aproximación resulta adecuada y permite un análisis controlado y reproducible.

2.2 Fundamentos de Cancelación Activa

El principio fundamental de los sistemas de cancelación activa de ruido (ANC) se basa en el fenómeno de la interferencia destructiva de ondas acústicas. Dado un campo sonoro indeseado $p_1(\mathbf{r}, t)$, generado por una fuente de ruido en un medio homogéneo e isotrópico, el objetivo del sistema ANC es generar un segundo campo $p_2(\mathbf{r}, t)$ tal que la superposición lineal de ambos reduzca o anule la presión sonora total en una región de interés:

$$p_{\text{total}}(\mathbf{r}, t) = p_1(\mathbf{r}, t) + p_2(\mathbf{r}, t) \approx 0. \quad (2.2)$$

Esta aproximación se fundamenta en el principio de superposición de ondas en medios lineales, y su eficacia depende de la coincidencia de fase, amplitud y dirección del campo generado con respecto al campo original.




Figura 1: Esquema general de un sistema de cancelación activa de ruido. En la posición determinada por “Mic” se produce la superposición de ondas dada por (2.2).

Los canales *primario* y *secundario* representan trayectorias físicas a través de las cuales se propagan las ondas desde la fuente de ruido hasta el micrófono y desde el actuador (altavoz) hasta el mismo punto de captura, respectivamente. Cada uno de estos canales se comporta como un sistema acústico, que se modela normalmente de forma lineal, cuya respuesta depende del entorno y puede modelarse mediante soluciones de la ecuación de onda a las que se añaden las respuestas de los transductores utilizados en su caso.

Ecuación de propagación acústica

La dinámica de presión acústica $p(\mathbf{r}, t)$ en un medio sin pérdidas, homogéneo e isotrópico, está gobernada por la ecuación de onda escalar en tres dimensiones:

$$\nabla^2 p(\mathbf{r}, t) - \frac{1}{c^2} \frac{\partial^2 p(\mathbf{r}, t)}{\partial t^2} = 0, \quad (2.3)$$

donde:

- ∇^2 es el operador Laplaciano espacial,
- c es la velocidad del sonido en el medio,
- $\mathbf{r} = (x, y, z)$ representa la posición espacial,
- t es el tiempo.

Una solución fundamental de esta ecuación en campo libre para una determinada frecuencia ω es la onda esférica dada por:

$$p(\mathbf{r}, t) = \frac{A}{|\mathbf{r} - \mathbf{r}_0|} \cos(\omega t - k|\mathbf{r} - \mathbf{r}_0| + \phi), \quad (2.4)$$

donde:

- $\mathbf{r}_0$ es la posición de la fuente,
- $\omega = 2\pi f$ es la frecuencia angular,
- $k = \frac{2\pi}{\lambda}$ es el número de onda,
- $\lambda = \frac{c}{f}$ es la longitud de onda,
- A y ϕ son la amplitud y la fase de la onda.

Esta solución sacada de [11] ilustra cómo la presión varía con la distancia y el tiempo, y permite modelar la propagación directa y reflejada del sonido, como se hace en el método de imágenes que se utiliza de forma general en las simulaciones de propagación de sonido en salas.

Relación con la percepción humana y la dificultad de cancelación

Desde el punto de vista perceptual, la audición humana es especialmente sensible en ciertas bandas de frecuencia. El oído humano es más preciso en la localización y percepción de sonidos en el rango de 1 a 4 kHz, debido a resonancias propias del canal auditivo y la forma del pabellón auricular.

En términos de cancelación activa, las señales con longitudes de onda más cortas (frecuencias altas) son más difíciles de cancelar por dos razones principales:

1. **Sensibilidad espacial:** Al disminuir la longitud de onda λ , las variaciones de fase y amplitud son más pronunciadas con pequeños cambios en la posición espacial. Esto significa que una señal diseñada para cancelar el ruido en un punto de una sala puede no funcionar adecuadamente a unos pocos centímetros de distancia.
2. **Precisión temporal:** Las ondas de alta frecuencia requieren un mayor grado de sincronización temporal entre la señal original y la señal de cancelación. Un pequeño desfase temporal puede convertir la interferencia destructiva en constructiva.

Todo esto sumado a los resultados que se obtuvieron en [12] que fundamentan que el oído es más sensible en frecuencias entre 200Hz y 5kHz nos llevan a la conclusión de que los sistemas ANC tienen mayor eficacia en la cancelación de sonidos de baja frecuencia (mayor λ), donde las variaciones espaciales y temporales son más suaves, predecibles y notorias para el oído humano.

Esquema conceptual de los canales acústicos

El canal *primario* representa la transmisión del sonido desde la fuente de ruido hasta el micrófono, mientras que el canal *secundario* representa el trayecto desde el altavoz de cancelación hasta el micrófono. Ambos canales son sistemas físicos que afectan la forma en que las señales se propagan y transforman. Un ejemplo básico de estos sistemas se encuentra en la Figura 1.

En este proyecto, se modelan ambos canales como sistemas lineales e invariantes de modo que su salida se calcula mediante convoluciones de la señal de entrada con respuestas impulsivas específicas $r_{ir1}[n]$ y $r_{ir2}[n]$, que corresponden a la discretización de la solución de la ecuación de onda bajo condiciones de contorno determinadas. Esta aproximación se justifica por la linealidad y el carácter tiempo-invariante del medio acústico simulado.

Una explicación más detallada de estos operadores se abordará en secciones posteriores del desarrollo del trabajo, donde se introducen formalmente los operadores funcionales $P\{\cdot\}$ y $S\{\cdot\}$ para representar el canal primario y el secundario, respectivamente.

Importancia de la latencia en la arquitectura del sistema

En el contexto de sistemas de cancelación activa de ruido (ANC), la latencia total del sistema de procesamiento —incluyendo el preprocesamiento digital, la inferencia del modelo y el retardo físico del canal secundario— constituye un parámetro crítico para la viabilidad funcional del sistema.

Para que la señal de cancelación generada tenga un efecto destructivo eficaz sobre el ruido incidente, es necesario que dicha señal pueda llegar al micrófono de error antes, o al menos simultáneamente, que la porción correspondiente del ruido original transmitida por el canal primario. Formalmente, esto puede expresarse como la siguiente desigualdad de sincronización:

$$T_{\text{primario}} \geq T_{\text{pre}} + T_{\text{modelo}} + T_{\text{secundario}}, \quad (2.5)$$

donde:

- T_{primario} : tiempo de propagación de la señal a través del canal primario,
- T_{pre} : tiempo requerido para el preprocesamiento digital (e.g., segmentación, FFT),

- T_{modelo} : tiempo de inferencia del modelo de cancelación,
- $T_{\text{secundario}}$: tiempo de propagación acústica desde el altavoz de cancelación hasta el micrófono.

De forma general, el incumplimiento de esta condición provocaría que la señal de cancelación llegue con un desfase temporal significativo, reduciendo drásticamente la eficacia de la interferencia destructiva, o incluso amplificando el ruido percibido.

Como propone [13], los modelos basados en redes neuronales deben optimizarse para latencias inferiores a 1 ms en ANC, requiriendo arquitecturas esbeltas y aceleración hardware.

Por lo tanto, al diseñar modelos de inferencia en sistemas ANC, es fundamental que sus requerimientos computacionales y temporales estén subordinados a las restricciones físicas del entorno.

2.3 Fundamentos de Redes Neuronales

Tras establecer los fundamentos acústicos que sustentan la simulación del entorno y los principios teóricos de la cancelación activa de ruido (ANC), resulta necesario introducir los conceptos esenciales de las redes neuronales, dado que estos modelos serán empleados como núcleo del sistema de cancelación en la etapa de aprendizaje.

Las redes neuronales artificiales constituyen un paradigma fundamental en el campo del aprendizaje automático. Su propósito principal es aproximar funciones desconocidas a partir de datos observados. Formalmente, el objetivo de una red neuronal es modelar una función $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$, de modo que, dado un conjunto de pares de entrenamiento $\{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^N$, se pueda aprender la relación subyacente entre los vectores de entrada $\mathbf{x}_i \in \mathbb{R}^n$ y sus correspondientes salidas deseadas $\mathbf{y}_i \in \mathbb{R}^m$.

El modelo está parametrizado por un conjunto de variables ajustables, agrupadas en el vector de parámetros $\boldsymbol{\theta}$, que incluye los pesos y sesgos de todas las capas de la red. El proceso de entrenamiento consiste en encontrar el conjunto óptimo de parámetros $\boldsymbol{\theta}^*$ que minimice una función de pérdida $L(\boldsymbol{\theta})$, la cual cuantifica el error entre la salida generada por la red y la salida esperada. Este proceso se plantea como un problema clásico de optimización:

$$\boldsymbol{\theta}^* = \arg \min_{\boldsymbol{\theta}} L(\boldsymbol{\theta}). \quad (2.6)$$

Como se demuestra en [14], las redes neuronales son aproximadores universales de funciones cuando poseen suficientes unidades ocultas y no linealidades apropiadas.

Para resolver este problema de optimización, una de las técnicas más utilizadas es el *descenso de gradiente* (*gradient descent*). Este método ajusta iterativamente los parámetros de la red en la dirección opuesta al gradiente de la función de pérdida con respecto a $\boldsymbol{\theta}$, es decir:

$$\boldsymbol{\theta}_{k+1} = \boldsymbol{\theta}_k - \eta \nabla_{\boldsymbol{\theta}} L(\boldsymbol{\theta}_k), \quad (2.7)$$

donde $\eta > 0$ representa la tasa de aprendizaje (o *learning rate*) y $\nabla_{\boldsymbol{\theta}} L(\boldsymbol{\theta}_k)$ es el gradiente de la función de pérdida respecto de los parámetros, evaluado en la iteración k . Este procedimiento se repite hasta que se cumple un criterio de convergencia, como la reducción del error por debajo de un umbral

o la estabilización del valor de la pérdida. El marco teórico del descenso de gradiente ([15]) proporciona las bases para entender la optimización de parámetros en espacios de alta dimensionalidad.

El diseño y profundidad de la red, junto con el tipo de funciones de activación utilizadas, influyen directamente en su capacidad para representar funciones complejas y no lineales. Por este motivo, el entrenamiento exitoso de una red neuronal requiere no solo una formulación matemática adecuada, sino también una cuidadosa elección de su arquitectura y de los hiperparámetros involucrados.

En problemas de regresión, la función de pérdida más común es el error cuadrático medio (MSE), definido como:

$$L(\theta) = \frac{1}{N} \sum_{i=1}^N \|y_i - \hat{y}_i\|^2, \quad (2.8)$$

donde $\hat{y}_i$ es la salida de la red neuronal para la entrada x_i .

2.4 Arquitecturas comunes

Entre las arquitecturas más relevantes destacan el perceptrón multicapa (MLP) y las redes convolucionales (CNN), que difieren en la forma en que procesan y extraen características de la información de entrada.

El MLP es un modelo feedforward compuesto por capas de neuronas completamente conectadas (fully-connected). Sea $\mathbf{x} \in \mathbb{R}^n$ la entrada, la salida de la capa l -ésima se define como

$$\mathbf{h}^{(l)} = \sigma \left(\mathbf{W}^{(l)} \mathbf{h}^{(l-1)} + \mathbf{b}^{(l)} \right), \quad (2.9)$$

donde $\mathbf{W}^{(l)}$ es la matriz de pesos de la etapa l y $\mathbf{b}^{(l)}$ el vector de sesgos (bias) de la etapa l . Se tiene además que $\mathbf{h}^{(0)} = \mathbf{x}$ y $\sigma(\cdot)$ es una función no lineal denominada “de activación”, comúnmente la función ReLU o la función sigmoide. La salida final se obtiene tras la composición de sucesivas capas como en (2.9). En este modelo, la matriz de pesos y el vector de sesgos representan los parámetros entrenables de cada etapa.




Figura 2: Esquema simple de una red MLP en la primera capa oculta.

Por otro lado, las redes convolucionales introducen la operación de convolución para explotar la estructura local y la invariancia espacial en los datos. La operación de convolución para un canal con

entrada x y caracterizado por un filtro w se define como

$$(x * w)(t) = \sum_{\tau} x(\tau) w(t - \tau), \quad (2.10)$$

y se aplica a lo largo de la dimensión temporal o espacial de la entrada dependiendo de su tipo, generando mapas de características que resaltan patrones locales. En este caso, serán los filtros los parametros entrenables. Algunos hiperparámetros fundamentales característicos del filtro w en la operación convolucional son:

- *Tamaño del kernel* (k): representa la longitud del filtro o ventana que se desliza sobre la entrada. Un tamaño pequeño (por ejemplo, $k = 3$) permite capturar relaciones locales, mientras que valores mayores pueden capturar patrones más globales.
- *Stride* (s): indica el número de posiciones que el filtro se desplaza en cada paso. Un stride mayor que 1 produce una salida más comprimida (submuestreo), ya que se reducen las posiciones donde se aplica la convolución.
- *Padding* (p): consiste en añadir ceros (u otro valor) en los bordes de la entrada para controlar el tamaño de la salida. El padding puede ser:
 - *same*: se elige p para que la salida tenga la misma dimensión que la entrada.
 - *valid*: no se añade padding, lo que reduce el tamaño de la salida.

La relación entre el tamaño de la entrada n_{in} y el tamaño de la salida n_{out} en una dimensión (por ejemplo, temporal o espacial) viene dada por la siguiente fórmula:

$$n_{out} = \left\lfloor \frac{n_{in} + 2p - k}{s} \right\rfloor + 1. \quad (2.11)$$

Este mecanismo permite construir arquitecturas jerárquicas donde las capas convolucionales actúan como codificadores (*encoders*), comprimiendo la dimensión de la entrada mientras aumentan el número de canales de activación (profundidad), extrayendo así representaciones más abstractas. De forma análoga, en tareas de reconstrucción (como en autoencoders o arquitecturas tipo U-Net), se utilizan capas de decodificación (*decoders*), como convoluciones transpuestas, basadas en inserción de ceros y convolución estándar, o técnicas de *upsampling*, para revertir esta compresión y recuperar la resolución original. En general, este tipo de arquitecturas son robustas frente al ruido como se concluyó en [16].




Figura 3: Esquema de una Red Neuronal Convolucional (CNN)

Este patrón de diseño podría resultar especialmente útil en contextos acústicos o de procesamiento de señales fuertemente afectadas por ruido, donde las representaciones locales pueden ser jerárquicamente aprendidas y combinadas para tareas como cancelación activa de ruido.

2.5 Optimizadores

Una extensión del descenso de gradiente (2.7) ampliamente utilizada en el entrenamiento de redes neuronales es el algoritmo *Adam* (Adaptive Moment Estimation). Este algoritmo combina las ventajas del descenso de gradiente estocástico con técnicas de acumulación de momentos para adaptar dinámicamente la tasa de aprendizaje de cada parámetro, evitando un gradiente excesivamente ruidoso que dificulta la adaptación. Este algoritmo supera las limitaciones del descenso de gradiente clásico utilizando estimaciones adaptativas del primer y segundo momentos del gradiente [17].

En Adam se mantienen dos estimaciones en cada paso: la media móvil del gradiente ($\mathbf{m}_k$) y la media móvil del cuadrado del gradiente ($\mathbf{v}_k$) para cada dimensión (parámetro entrenable). Estos se actualizan en cada iteración k según:

$$\mathbf{m}_k = \beta_1 \mathbf{m}_{k-1} + (1 - \beta_1) \nabla_{\boldsymbol{\theta}} L(\boldsymbol{\theta}_k), \quad (2.12)$$

$$\mathbf{v}_k = \beta_2 \mathbf{v}_{k-1} + (1 - \beta_2) (\nabla_{\boldsymbol{\theta}} L(\boldsymbol{\theta}_k))^2, \quad (2.13)$$

donde $\beta_1, \beta_2 \in [0, 1)$ son los coeficientes de decaimiento (olvido) para los momentos y el cuadrado del vector gradiente en (2.13) se entiende elemento a elemento.

Dado que estas estimaciones están inicialmente sesgadas hacia cero por el hecho de que ambos momentos se inicializan en cero, se corrigen mediante:

$$\hat{\mathbf{m}}_k = \frac{\mathbf{m}_k}{1 - \beta_1^k}, \quad (2.14)$$

$$\hat{\mathbf{v}}_k = \frac{\mathbf{v}_k}{1 - \beta_2^k}. \quad (2.15)$$

La actualización final de los parámetros es entonces:

$$\boldsymbol{\theta}_{k+1} = \boldsymbol{\theta}_k - \eta \frac{\hat{\mathbf{m}}_k}{\sqrt{\hat{\mathbf{v}}_k} + \epsilon}, \quad (2.16)$$

donde $\epsilon > 0$ es un término pequeño para evitar la división por cero y la división de vectores se entiende elemento a elemento.

AMSGrad, una variante propuesta por Reddi et al. (2018) [18], mejora la convergencia de Adam al evitar aumentos artificiales en la tasa de aprendizaje. Para ello, introduce un máximo histórico por componente del gradiente cuadrático corregido ($\hat{v}_k$).

En cada iteración k y para cada parámetro i del vector $\boldsymbol{\theta}$, se actualiza:

$$\hat{v}_k^{\max}[i] = \max(\hat{v}_{k-1}^{\max}[i], \hat{v}_k[i]), \quad (2.17)$$

donde:

- $\hat{v}_k[i]$ es el valor corregido de bias para el parámetro i -ésimo (Ec. 2.13),
- $\hat{v}_k^{\max}[i]$ almacena el máximo histórico hasta la iteración k .

La actualización de parámetros utiliza entonces este máximo histórico:

$$\theta_{k+1} = \theta_k - \eta \frac{\hat{\mathbf{m}}_k}{\sqrt{\hat{\mathbf{v}}_k^{\max} + \epsilon}}, \quad (2.18)$$

donde todas las operaciones (división, raíz cuadrada y máximo) se aplican elemento a elemento. Esta modificación garantiza que el denominador no disminuya monótonamente, estabilizando la tasa de aprendizaje para cada parámetro individual. Esta variante ajusta la tasa de aprendizaje, de modo que garantiza una convergencia más estable en ciertos problemas, donde Adam clásico puede diverger. En particular, AMSGrad ha sido empleado con éxito en tareas de aprendizaje automático, como se describe en el artículo citado en este trabajo [18].

A pesar de la capacidad expresiva de los perceptrones multicapa y las redes convolucionales, estos modelos presentan una limitación fundamental: la ausencia de memoria explícita o capacidad para retener información temporal a lo largo de secuencias de entrada. En otras palabras, tanto el MLP como la CNN procesan cada entrada de manera independiente o en ventanas temporales limitadas, sin incorporar un estado interno que acumule contexto histórico de los conjuntos de datos.

Esta característica puede resultar problemática en aplicaciones donde la información relevante depende de una secuencia temporal prolongada, como ocurre en entornos acústicos con reverberación pronunciada. En dichos casos, las señales capturadas por los micrófonos incluyen no solo el sonido directo sino también múltiples reflexiones retardadas, cuya duración puede extenderse más allá del tamaño de la ventana de datos de entrada utilizada en el modelo.

Matemáticamente, consideremos una secuencia de entradas temporales $\{\mathbf{x}_t\}_{t=1}^N$, donde cada $\mathbf{x}_i \in \mathbb{R}^d$ representa la entrada al modelo (o señal recibida) en la ventana i . Podemos decir que un modelo posee memoria o dependencia temporal de orden k si su salida para la ventana i , $\mathbf{y}_i$, puede expresarse como una función de las entradas actuales y las anteriores hasta un retraso k , es decir:

$$\mathbf{y}_i = f(\mathbf{x}_i, \mathbf{x}_{i-1}, \dots, \mathbf{x}_{i-k}). \quad (2.19)$$

En el caso de modelos como perceptrones multicapa (MLP) o redes convolucionales (CNN), el procesamiento se realiza generalmente sobre una única ventana de entrada $\mathbf{x}_i \in \mathbb{R}^d$, la cual puede representar una porción temporal limitada o un espectro de frecuencias en un periodo temporal específico. Por tanto, la capacidad para capturar contexto temporal extenso dependerá críticamente de la dimensión d de dicha ventana.

Ampliar d para incluir más información temporal implica un incremento en la cantidad de parámetros y, por ende, un mayor coste computacional y de memoria para el entrenamiento y la inferencia del modelo. Esta limitación es especialmente relevante en aplicaciones de acústica con reverberación prolongada, donde se requiere integrar información de ventanas temporales anteriores más allá de la ventana observable en un solo vector de entrada.

Como consecuencia, la capacidad de estos modelos para suprimir ruido en presencia de reverberación puede verse significativamente limitada, dado que pierden la información contextual necesaria para distinguir entre el sonido original y sus múltiples reflexiones. Este problema justifica la necesidad de arquitecturas con memoria explícita, como las redes recurrentes, que serán abordadas en el siguiente apartado.

2.6 Redes Long Short-Term Memory.

Para superar la limitación de memoria explícita en modelos como MLP y CNN, se emplean arquitecturas recurrentes (RNN) que incorporan un estado interno capaz de retener información a lo largo del tiempo. Entre ellas, las redes Long Short-Term Memory (LSTM) [19] se destacan por su capacidad para aprender dependencias temporales de largo plazo mediante un diseño especial de puertas que regulan el flujo de información.

Una celda LSTM consta de tres puertas principales: puerta de olvido (*forget gate*), puerta de entrada (*input gate*) y puerta de salida (*output gate*), que controlan qué información debe olvidarse, actualizarse y propagarse en cada instante temporal i . Formalmente, dadas la entrada actual $\mathbf{x}_i$, el estado oculto previo $\mathbf{h}_{i-1}$ y el estado de celda previo $\mathbf{c}_{i-1}$, las actualizaciones se definen mediante las siguientes ecuaciones:

$$\mathbf{f}_i = \sigma(\mathbf{W}_F \mathbf{x}_i + \mathbf{W}_{Fh} \mathbf{h}_{i-1} + \mathbf{b}_F), \quad (2.20)$$

$$\mathbf{i}_i = \sigma(\mathbf{W}_I \mathbf{x}_i + \mathbf{W}_{Ih} \mathbf{h}_{i-1} + \mathbf{b}_I), \quad (2.21)$$

$$\tilde{\mathbf{c}}_i = \tanh(\mathbf{W}_C \mathbf{x}_i + \mathbf{W}_{Ch} \mathbf{h}_{i-1} + \mathbf{b}_C), \quad (2.22)$$

$$\mathbf{c}_i = \mathbf{f}_i \odot \mathbf{c}_{i-1} + \mathbf{i}_i \odot \tilde{\mathbf{c}}_i, \quad (2.23)$$

$$\mathbf{o}_i = \sigma(\mathbf{W}_O \mathbf{x}_i + \mathbf{W}_{Oh} \mathbf{h}_{i-1} + \mathbf{b}_O), \quad (2.24)$$

$$\mathbf{h}_i = \mathbf{o}_i \odot \tanh(\mathbf{c}_i), \quad (2.25)$$

donde $\sigma(\cdot)$ representa la función sigmoide logística, $\tanh(\cdot)$ es la función tangente hiperbólica, y $\odot$ denota el producto de Hadamard (multiplicación elemento a elemento) siendo:

- $\mathbf{f}$: activación de la puerta de olvido
- $\mathbf{i}$: activación de la puerta de entrada
- $\tilde{\mathbf{c}}$: estado de celda candidato
- $\mathbf{c}$: estado de la celda de memoria
- $\mathbf{o}$: activación de la puerta de salida
- $\mathbf{h}$: estado oculto

Los parámetros $\mathbf{W}_*$, $\mathbf{W}_{*h}$ y $\mathbf{b}_*$ son matrices y vectores de pesos y sesgos a aprender durante el entrenamiento.




Figura 4: Esquema de las puertas de una LSTM. En este esquema, el bloque g es la celda candidata $\tilde{c}$. [20]

Este diseño permite que la celda LSTM controle dinámicamente qué información preservar o desechar en el estado interno c_i , mitigando problemas comunes en las redes recurrentes clásicas, como el desvanecimiento o explosión del gradiente. Gracias a esta capacidad de memoria a largo plazo, las LSTM resultan especialmente adecuadas para modelar procesos secuenciales con dependencias temporales prolongadas, como la reverberación en acústica.

El entrenamiento de una red LSTM se fundamenta en la minimización de una función de pérdida, la cual mide la discrepancia entre la salida predicha por el modelo y la salida esperada en cada instante de tiempo. Sea el conjunto de datos de entrenamiento:

$$B = \{(\mathbf{x}_i, \mathbf{y}_i) \mid i = 1, \dots, N\},$$

donde $\mathbf{x}_i \in \mathbb{R}^n$ representa el vector de entrada en el tiempo i , y $\mathbf{y}_i \in \mathbb{R}^m$ la salida esperada correspondiente. Denotamos por $\hat{\mathbf{y}}_i$ la predicción de la red en ese mismo instante. En tareas de regresión, es habitual utilizar como función de pérdida el error cuadrático medio (MSE), definido como:

$$\mathcal{L}_i = \frac{1}{m} \|\hat{\mathbf{y}}_i - \mathbf{y}_i\|^2. \quad (2.26)$$

La pérdida total acumulada a lo largo de toda la secuencia observada se expresa entonces como:

$$\mathcal{L} = \sum_{i=1}^N \mathcal{L}_i. \quad (2.27)$$

El modelo se entrena mediante *Backpropagation Through Time* (BPTT) [14], el algoritmo estándar para redes recurrentes. BPTT desenrolla computacionalmente la red a través del tiempo y aplica la regla de la cadena para calcular los gradientes de todos los parámetros (pesos de las puertas y conexiones).

Para cada paso temporal t , el algoritmo:

1. Calcula los gradientes de la pérdida respecto a las salidas,

2. Propaga estos gradientes hacia atrás a través de las puertas LSTM (olvido, entrada, salida),

Este procedimiento se repite para cada instante i desde $i = N$ hasta $i = 1$, acumulando los gradientes correspondientes para cada parámetro del modelo.¹

Sin embargo, este esquema completo de retropropagación puede resultar ineficiente y propenso a inestabilidades cuando N es grande, debido tanto al coste computacional como a la posibilidad de desvanecimiento o explosión del gradiente. Por esta razón, en la práctica se recurre frecuentemente a una versión truncada del algoritmo, en la que solo se consideran k pasos temporales hacia atrás. Este valor, conocido como *seq_len*, se define como un hiperparámetro de entrenamiento que delimita el rango temporal sobre el cual se realiza la retropropagación. Es decir, para cada paso de entrenamiento, se selecciona un bloque de k instantes consecutivos y se calcula el gradiente únicamente sobre dicho segmento, ignorando el resto de la secuencia. Por tanto, en este caso se tiene:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}} \approx \sum_{i=i_0}^{i_0+k-1} \frac{\partial \mathcal{L}_i}{\partial \mathbf{W}} \quad (2.28)$$

donde i_0 varía a lo largo de las iteraciones del entrenamiento, indicando el inicio del bloque de secuencias de duración k sobre las que se propagarán los gradientes.

Este truncamiento permite reducir significativamente el uso de memoria y los tiempos de cómputo, sin perder por completo la capacidad del modelo para capturar dependencias temporales. No obstante, introduce una limitación explícita sobre el contexto que el modelo puede utilizar en cada actualización, por lo que la elección de k debe balancear adecuadamente la eficiencia y la expresividad temporal del sistema.

2.6.1 Modelado en el dominio espectral complejo para redes LSTM

Dada una secuencia temporal $\{\mathbf{x}_i\}_{i=1}^N$, donde cada $\mathbf{x}_i \in \mathbb{R}^n$ representa una ventana temporal de una señal de audio, una estrategia alternativa al procesamiento directo en el dominio temporal consiste en transformar dicha señal al dominio frecuencia mediante la Transformada Rápida de Fourier (FFT). Esta transformación permite representar información de la señal tanto en magnitud como en fase, capturando así de forma explícita la estructura espectral del sonido.

La FFT de una ventana $\mathbf{x}_i \in \mathbb{R}^n$ se denota como:

$$\mathbf{X}_i = \text{FFT}(\mathbf{x}_i) \in \mathbb{C}^{n/2+1}, \quad (2.29)$$

donde, por simetría de la transformada de Fourier sobre señales reales, solo se retienen los primeros $n/2 + 1$ coeficientes espectrales². Cada vector complejo $\mathbf{X}_i$ puede descomponerse en su parte real e imaginaria como:

$$\mathbf{X}_i = \Re(\mathbf{X}_i) + i \Im(\mathbf{X}_i), \quad (2.30)$$

¹La derivación matemática completa del algoritmo BPTT para esta arquitectura se detalla en el Apéndice.

²Una explicación detallada sobre la Transformada Discreta de Fourier (DFT), sus propiedades fundamentales y la simetría hermitica se incluye en el Anexo A.

por lo que es posible representar cada entrada como un tensor real de dos canales: uno para la parte real y otro para la parte imaginaria. Es decir, cada entrada puede ser reformulada como un tensor:

$$\tilde{\mathbf{x}}_i \in \mathbb{R}^{2 \times (n/2+1)}, \quad (2.31)$$

donde $\tilde{\mathbf{x}}_i[0, :]$ contiene $\Re(\mathbf{X}_i)$ y $\tilde{\mathbf{x}}_i[1, :]$ contiene $\Im(\mathbf{X}_i)$. Para procesar esta entrada espectral en una red LSTM, se consideran dos estrategias estructurales:

(1) Entrada directa del espectro complejo como secuencia multicanal o proyección

En esta opción, la red LSTM se adapta para recibir directamente la secuencia $\{\tilde{\mathbf{x}}_i\}_{i=1}^N$, donde cada $\tilde{\mathbf{x}}_i \in \mathbb{R}^{2 \times (n/2+1)}$ se mapea a un vector real $\mathbf{z}_i \in \mathbb{R}^{2(n/2+1)}$. Así, la secuencia procesada por la LSTM es:

$$\mathbf{z}_i = \text{vec}(\tilde{\mathbf{x}}_i) \in \mathbb{R}^d, \quad \text{con } d = 2(n/2 + 1). \quad (2.32)$$

No obstante, al aplicar directamente un aplanamiento (*flatten*) de las componentes real e imaginaria en un único vector $\mathbf{z}_i \in \mathbb{R}^d$, se pierde la estructura natural del dato complejo, lo que puede dificultar la tarea de aprendizaje secuencial por parte de la red LSTM. Esta concatenación simple no preserva explícitamente la correspondencia entre las partes real e imaginaria de cada bin espectral, lo cual puede inducir a la red a interpretar erróneamente las relaciones temporales y espectrales implícitas en los datos. Para mitigar este problema, se propone un mapeo lineal inicial de la forma:

$$\mathbf{z}_i = \phi(\tilde{\mathbf{x}}_i) \in \mathbb{R}^d, \quad (2.33)$$

donde $\phi : \mathbb{R}^{2 \times (n/2+1)} \rightarrow \mathbb{R}^{d(n/2+1)}$ es una transformación aprendida que proyecta cada par $(\Re(X_k), \Im(X_k))$ asociado a cada bin k a un espacio latente de dimensión más amplia. La forma general de este mapeo lineal ϕ es:

$$\phi(\mathbf{x}) = \mathbf{W}\mathbf{x} + \mathbf{b}, \quad (2.34)$$

donde $\mathbf{x} = [\Re(X_k), \Im(X_k)]^\top \in \mathbb{R}^2$ es el vector de entrada para el bin k , $\mathbf{W} \in \mathbb{R}^{d \times 2}$ es la matriz de pesos aprendibles, y $\mathbf{b} \in \mathbb{R}^d$ es el vector de bias.

Este paso permite reorganizar la información de entrada de manera más estructurada y semánticamente coherente para la LSTM, facilitando la extracción de patrones relevantes sin incrementar significativamente la dimensión total del vector de entrada. En resumen, esta transformación previa actúa como un adaptador estructural entre el dominio espectral complejo y el modelo secuencial, preservando relaciones internas y aliviando la carga de representación para la LSTM. Con esta transformación podemos mitigar problemas estructurales que pueden ocurrir con un simple aplanado a la entrada de la LSTM.

(2) Reducción espacial y extracción de características previa mediante capas convolucionales

Dado que $\tilde{\mathbf{x}}_i$ tiene una estructura espacial de tipo $(2, n/2 + 1)$, una alternativa más estructurada consiste en aplicar un bloque convolucional de tipo 1D o 2D que reduzca esta representación a un vector unidimensional. Por ejemplo, se puede aplicar una red convolucional $g_\phi : \mathbb{R}^{2 \times (n/2+1)} \rightarrow \mathbb{R}^d$, donde d es una dimensión intermedia elegida, y definir:

$$\mathbf{z}_i = g_\phi(\tilde{\mathbf{x}}_i), \quad (2.35)$$

para luego procesar la secuencia $\{\mathbf{z}_i\}_{i=1}^N$ con una LSTM. Este enfoque permite explotar patrones locales y relaciones entre canales (real e imaginario) antes del modelado secuencial, actuando como un codificador espectral.

Ambos enfoques tienen ventajas: el primero permite un tratamiento directo y explícito de la información compleja, mientras que el segundo permite incorporar inductivamente un sesgo estructural en la red hacia regularidades espectrales locales mediante convoluciones.

2.6.2 El problema del desvanecimiento del gradiente y su mitigación en las redes LSTM

Uno de los principales obstáculos en el entrenamiento de redes neuronales recurrentes clásicas (RNN) es el fenómeno conocido como *desvanecimiento del gradiente* (*vanishing gradient*). Este problema fue formalizado teóricamente por [21], demostrando las limitaciones fundamentales de las RNN estándar. Durante la retropropagación a través del tiempo (BPTT), el gradiente de la función de pérdida respecto a los parámetros se calcula mediante la regla de la cadena, lo que implica sucesivas multiplicaciones de derivadas parciales. Si los factores involucrados en estas multiplicaciones tienen norma menor que uno, el gradiente se atenúa exponencialmente al retroceder en el tiempo, dificultando el aprendizaje de dependencias a largo plazo.

Sea $\mathbf{h}_i$ el estado oculto de una RNN y $\mathbf{x}_i$ la entrada en el tiempo i , el estado oculto se actualiza típicamente como:

$$\mathbf{h}_i = \phi(\mathbf{W}_H \mathbf{h}_{i-1} + \mathbf{W}_X \mathbf{x}_i + \mathbf{b}), \quad (2.36)$$

donde ϕ es una función de activación no lineal (por ejemplo, $\tanh$ o σ). Durante el proceso de entrenamiento, la derivada de la pérdida respecto a $\mathbf{h}_{i-k}$ para algún $k > 0$ involucra términos de la forma:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{h}_{i-k}} = \frac{\partial \mathcal{L}}{\partial \mathbf{h}_i} \prod_{j=1}^k \frac{\partial \mathbf{h}_{i-j+1}}{\partial \mathbf{h}_{i-j}}. \quad (2.37)$$

Dado que los jacobianos $\frac{\partial \mathbf{h}_{i-j+1}}{\partial \mathbf{h}_{i-j}}$ pueden tener norma menor que uno, su producto decrece rápidamente, haciendo que el gradiente tienda a cero conforme aumenta k .

Las redes LSTM (Long Short-Term Memory) fueron diseñadas específicamente para superar este problema. Gracias a la celda de memoria $\mathbf{c}_i$ que actúa como acumulador de información relevante, y cuya evolución temporal está controlada mediante puertas de entrada, olvido y salida. La actualización de la celda viene dada por la ecuación 2.23

La clave es que la contribución de $\mathbf{c}_{i-1}$ se propaga directamente a $\mathbf{c}_i$ modulada por $\mathbf{f}_i$, sin pasar por una función de activación no lineal que pueda saturarse.

Este diseño permite que los gradientes respecto a la celda se mantengan estables, ya que:

$$\frac{\partial \mathbf{c}_i}{\partial \mathbf{c}_{i-1}} = \mathbf{f}_i, \quad (2.38)$$

y, al estar f_i controlada por una función sigmoide, sus valores pueden aproximarse a 1, lo que preserva la magnitud del gradiente. Así, la LSTM logra una memoria constante en el tiempo, mitigando el desvanecimiento del gradiente y permitiendo el aprendizaje efectivo de relaciones a largo plazo en secuencias.

2.6.3 Mecanismo de atención en LSTM

Un mecanismo de atención es un componente arquitectónico fundamental en redes neuronales modernas que permite al modelo procesar información de forma selectiva, asignando pesos diferenciados a distintos elementos de una secuencia o conjunto de características. Inspirado en los sistemas cognitivos biológicos, este mecanismo opera mediante tres principios esenciales: (1) la generación de representaciones intermedias (consultas, claves y valores) que codifican distintos aspectos de la información, (2) el cálculo de puntuaciones de relevancia que cuantifican la afinidad entre elementos, y (3) la combinación ponderada de características según dichas puntuaciones. De esta forma, este mecanismo permite realizar predicciones basadas en los estados ocultos anteriores de una red recurrente asignando pesos de forma dinámica y consistente.

Como demostró [22], la combinación de LSTM con atención selectiva mejora el manejo de dependencias temporales largas en redes recurrentes. A continuación se hará una explicación mas formal del mecanismo:

Sea $\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_T$ la secuencia de vectores generados por una red LSTM, donde cada $\mathbf{h}_i \in \mathbb{R}^H$ representa el estado oculto en el instante i . A partir de estos estados, se obtienen tres representaciones intermedias conocidas como consultas, claves y valores, mediante proyecciones lineales parametrizadas por matrices aprendibles $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V \in \mathbb{R}^{H \times H}$. Para cada instante t , estas se definen como:

$$\mathbf{q}_i = \mathbf{W}_Q \mathbf{h}_i, \quad \mathbf{k}_i = \mathbf{W}_K \mathbf{h}_i, \quad \mathbf{v}_i = \mathbf{W}_V \mathbf{h}_i. \quad (2.39)$$

Estas representaciones son moduladas mediante compuertas aprendibles que actúan como mecanismos de control adaptativo. En concreto, se introducen tres vectores de parámetros $\mathbf{k}'_p, \mathbf{q}'_p$ y $\mathbf{v}'_p \in \mathbb{R}^H$, y se define la versión modulada de cada vector como:

$$\mathbf{k}'_i = \mathbf{k}_i \odot \sigma(\mathbf{k}'_p), \quad \mathbf{q}'_i = \mathbf{q}_i \odot \sigma(\mathbf{q}'_p), \quad \mathbf{v}'_i = \mathbf{v}_i \odot [\sigma(\mathbf{v}'_p) \odot \tanh(\mathbf{v}'_p)], \quad (2.40)$$

donde $\sigma(\cdot)$ es la función sigmoide y $\odot$ denota el producto elemento a elemento. Esta operación introduce una forma de atenuación o amplificación aprendible para cada dimensión del espacio latente, permitiendo al modelo refinar el contenido informativo transmitido por cada componente.

La puntuación de atención entre los pasos i y τ , que mide la compatibilidad entre la consulta actual y una clave pasada, se calcula mediante un producto escalar escalado:

$$s_{i,\tau} = \frac{(\mathbf{q}'_i)^\top \mathbf{k}'_\tau}{\sqrt{H}}. \quad (2.41)$$

Sin embargo, para mantener la causalidad, se impone una máscara sobre la matriz de puntuaciones que anula toda interacción con pasos futuros, es decir, se fuerza $s_{i,\tau} = -\infty$ cuando $\tau > i$. De esta forma, cada paso sólo puede atender al pasado y a sí mismo.

Las puntuaciones válidas se normalizan con una función softmax para obtener los coeficientes de atención $\alpha_{i,\tau}$, que definen cuánto debe influir cada valor $\mathbf{v}'_\tau$ en la salida del instante i . Así, el vector de contexto se calcula como:

$$\alpha_{i,\tau} = \frac{\exp(s_{i,\tau})}{\sum_{\tau'=1}^i \exp(s_{i,\tau'})}, \quad \mathbf{c}_i = \sum_{\tau=1}^i \alpha_{i,\tau} \mathbf{v}'_\tau \quad (2.42)$$

Este vector de contexto resume, de forma ponderada, la información relevante del pasado para el instante actual. Finalmente, este contexto se suma a la salida de la LSTM, formando una conexión residual que permite preservar la información original del modelo recurrente. Esta combinación se proyecta al espacio original mediante una transformación lineal definida por una matriz $\mathbf{W}_O \in \mathbb{R}^{H \times H}$ y un sesgo $\mathbf{b}_O \in \mathbb{R}^H$:

$$\mathbf{y}_i = \mathbf{W}_O(\mathbf{h}_i + \mathbf{c}_i) + \mathbf{b}_O. \quad (2.43)$$

Este mecanismo de atención causal permite al modelo capturar dependencias de largo alcance sin violar la estructura temporal del problema, constituyendo así una solución efectiva y eficiente para tareas secuenciales en tiempo real.

Capítulo 3:

Desarrollo del proyecto

3.1 Preparación del sistema acústico

En este trabajo se ha utilizado la librería `pyroomacoustics` [23] para llevar a cabo la simulación del entorno acústico en el que se desarrollará la cancelación activa de ruido. Esta herramienta resulta particularmente útil al momento de estudiar la propagación del sonido en entornos cerrados y controlados, como salas rectangulares, mediante la implementación del conocido método de las imágenes de Allen y Berkley [7].

`Pyroomacoustics` es una librería de código abierto en Python diseñada específicamente para la simulación de acústica en recintos cerrados. Su funcionamiento se basa en representar geométricamente la sala y calcular cómo se propaga el sonido entre fuentes y receptores mediante respuestas impulsivas (Room Impulse Responses, RIRs). Utiliza el método de las imágenes para modelar las reflexiones especulares que ocurren en superficies rígidas.

Una de sus principales ventajas es que permite controlar con precisión las propiedades del entorno, como dimensiones, ubicaciones de los dispositivos y coeficientes de absorción. Además, se integra bien con herramientas de análisis acústico y es útil en aplicaciones de aprendizaje automático. Sin embargo, esta librería también presenta limitaciones: se restringe a salas con geometría relativamente simple y no contempla fenómenos como la difusión o la dependencia frecuencial de la absorción.

Para esta simulación, se ha definido una sala rectangular de dimensiones $4 \times 3 \times 2$ metros, con una frecuencia de muestreo de 3000 Hz. Se ubican tres dispositivos: la fuente primaria de ruido en $[0,5, 1,5, 1]$, el altavoz de cancelación en $[1, 3, 1]$ y el micrófono en $[4, 1,5, 1]$. Se permite un máximo de 8 órdenes de reflexión para capturar adecuadamente los múltiples rebotes del sonido.





Figura 5: Sala acústica y configuración.

Una vez configurada la sala y definidos los dispositivos, se emplea la función:

```
room.compute_rir(),
```

para calcular las respuestas impulsivas entre las fuentes y el micrófono. En cada configuración se generan dos RIRs: una desde la fuente de ruido hasta el micrófono (`rir1`) y otra desde el altavoz de cancelación (`rir2`) hasta el micrófono.

Figura 6: Respuestas impulsivas del camino primario (`rir1`) y secundario (`rir2`).

Los RIRs muestran un comportamiento claramente influenciado por el RT60. Con tiempos de reverberación mayores, las respuestas impulsivas se extienden más en el tiempo, evidenciando un efecto de ecos y reflejos prolongados. Para RT60 bajos, las respuestas son más compactas, con un decaimiento rápido de la energía reflejada.

El sistema de cancelación activa se puede representar mediante operadores funcionales que actúan sobre una señal discreta $x[n]$. Este esquema se introdujo en el Capítulo 2, en la Figura 1. Definimos tres operadores:

$$P : x[n] \rightarrow P\{x[n]\}, \quad (3.1)$$

$$M : x[n] \rightarrow y[n] = M\{x[n]\}, \quad (3.2)$$

$$S : y[n] \rightarrow S\{y[n]\}, \quad (3.3)$$

donde $P\{\cdot\}$ representa el camino primario (desde la fuente hasta el micrófono), $M\{\cdot\}$ el modelo generador de la señal de cancelación, y $S\{\cdot\}$ el camino secundario (desde el altavoz de cancelación al micrófono).

La señal registrada por el micrófono viene dada por:

$$e[n] = P\{x[n]\} + S\{y[n]\} \quad (3.4)$$

Para lograr cancelación efectiva, se requiere que:

$$e[n] \rightarrow 0, \quad (3.5)$$

lo que implica

$$P\{x[n]\} + S\{M\{x[n]\}\} = 0, \quad (3.6)$$

y despejando M :

$$M\{x[n]\} = S^{-1}\{-P\{x[n]\}\}. \quad (3.7)$$

De forma general, los sistemas acústicos se consideran lineales e invariantes, en consecuencia su simulación se realiza mediante convolución de la señal con las respuestas impulsivas correspondientes a los caminos primario y secundario:

$$P\{x[n]\} = x[n] * rir1[n] \quad (3.8)$$

$$S\{y[n]\} = y[n] * rir2[n] \quad (3.9)$$

donde $*$ indica convolución discreta.

A continuación, con el objetivo de simular el funcionamiento correcto de un sistema de cancelación activa, se procederá a calcular el efecto del camino primario sobre la señal $x[n]$ como en 3.8 obteniendo así la señal perturbada $x_p[n]$. Esta será utilizada como punto de partida para estimar la salida del modelo de cancelación ideal.

Para ello, se desea hallar la señal que, al pasar por el camino secundario, anule el efecto del camino primario. Esto equivale a aplicar el operador inverso S^{-1} sobre $-P\{x[n]\}$, lo cual se realiza mediante un proceso de deconvolución de Wiener ¹ sobre la señal $x_p[n]$:

$$y[n] = M\{x[n]\} = \text{WienerDeconv}\{-x_p[n], rir2[n]\}. \quad (3.10)$$

¹La deconvolución de Wiener utilizada para estimar la señal $y[n]$ a partir de $-P\{x[n]\}$ se describe detalladamente en el Anexo A.

Esta señal $y[n]$ representa una salida óptima que, al ser convolucionada con $rir2[n]$, genera una respuesta que cancela efectivamente a $x_p[n]$. En otras palabras, se simula el comportamiento que se espera del modelo de cancelación.

Tanto la señal de entrada $x[n]$ como la salida deseada $y[n]$ serán utilizadas como pares (x, y) para entrenar el modelo real de cancelación activa en etapas posteriores.




Figura 7: Simulación del funcionamiento correcto del sistema de cancelación activa para una sala ejemplo con una superposición de tonos simples como fuente de ruido.

Además de servir como base para el entrenamiento supervisado del modelo de cancelación, esta estrategia permite establecer una referencia idealizada frente a la cual comparar distintos modelos o arquitecturas de cancelación activa. Al emplear la deconvolución de Wiener sobre la señal perturbada $x_p[n]$, se obtiene una señal $y[n]$ teóricamente óptima que cancela perfectamente la contribución del camino primario al pasar por el sistema secundario. Esta señal representa una cota superior de desempeño, útil para evaluar la capacidad de distintos enfoques de aproximarse al comportamiento ideal. La comparación entre la respuesta generada por los modelos reales y la obtenida mediante este proceso permite identificar de manera clara las limitaciones estructurales o de entrenamiento de cada modelo, constituyendo así una herramienta valiosa de análisis en tareas de benchmarking controlado.

3.2 Preparación de los datos

La etapa de preparación de datos consiste en convertir las señales continuas $x[n]$ y $y[n]$, obtenidas del proceso de simulación mediante deconvolución de Wiener (Ecuación 3.10), en conjuntos de pares (x, y) que serán utilizados para el entrenamiento de los modelos de cancelación activa desarrollados en capítulos posteriores.

3.2.1 Segmentación en ventanas temporales

Dado que los modelos propuestos procesan la información en forma de secuencias temporales discretas, se realiza una segmentación de ambas señales en fragmentos consecutivos de longitud fija. Este procedimiento se lleva a cabo mediante una función `prepare_data()`, que implementa un esquema de recorrido deslizante sobre las señales de entrada y salida. Específicamente, se extraen bloques de $T = 256$ muestras de la señal de entrada $x[n]$, y para cada uno de ellos se asocia un bloque consecutivo de igual tamaño de la señal objetivo $y[n]$, comenzando inmediatamente después del fragmento de entrada.

El desplazamiento entre fragmentos consecutivos está definido por el parámetro *hop*, que en este caso se ha fijado en 128 muestras, estableciendo un solapamiento del 50 % entre fragmentos adyacentes. De esta manera, se genera una secuencia densa de pares entrada–objetivo alineados temporalmente,

adecuada para el entrenamiento supervisado. Un ejemplo ilustrativo de este proceso se presenta en la Figura 8.

Por ejemplo, si se considera un fragmento de la señal de entrada que abarca desde la muestra $n - 128$ hasta $n + 128$, el fragmento correspondiente de la señal objetivo abarcará desde la muestra $n - 128 + 256$ hasta $n + 128 + 256$. Esto refleja que el bloque objetivo comienza justo después de finalizar el bloque de entrada, respetando el desfase temporal impuesto por el diseño del sistema.

Esta segmentación de las señales se fundamenta en el diseño del sistema físico subyacente, en particular, las características acústicas de la sala. En nuestro ejemplo y simulación, el retardo causado por las respuestas impulsionales es tal que un evento destacado en la señal $x[n]$ se refleja aproximadamente 256 muestras más tarde en la señal $y[n]$.

De esta manera, se genera el conjunto de entrenamiento $B = \{(x_i, y_i)\}$, donde cada par (x_i, y_i) corresponde a un segmento de la señal de entrada y su correspondiente segmento desplazado de la señal objetivo.

A una frecuencia de muestreo de $f_s = 3 \text{ kHz}$, cada ventana de 256 muestras representa un intervalo temporal de aproximadamente 85,3 ms:

$$T_{\text{ventana}} = \frac{256}{3000} \approx 85,3 \text{ ms.}$$

Del mismo modo, el salto entre ventanas de 128 muestras equivale a aproximadamente 42,6 ms. Este valor define la resolución temporal efectiva con la que se modelan las secuencias de entrada-salida.




Figura 8: Funcionamiento de `prepare_data()`. Si escogemos $hop = 128$, habrá un solape del 50 % entre bloques consecutivos

3.2.2 Relación entre ventana y reverberación

Cabe destacar que la duración de las ventanas temporales puede ser insuficiente para capturar completamente la respuesta impulsiva de ambientes con reverberación prolongada. En particular, si el tiempo de reverberación $RT60$ del entorno simulado excede los 85 ms, los efectos del eco se extienden más allá del contexto inmediato de la ventana. Un ejemplo de esto se puede observar en la Figura 9. Esta limitación tiene implicaciones relevantes para modelos que no disponen de mecanismos explícitos de memoria, como los modelos puramente convolucionales o basados en perceptrones multicapa. Dichos modelos sólo tienen acceso a la información contenida dentro de una ventana aislada, lo que restringe su capacidad para capturar dependencias temporales de largo alcance necesarias para una cancelación efectiva.

En contraste, modelos secuenciales como las LSTM o los que incorporan mecanismos de atención pueden mitigar parcialmente este problema al mantener un estado interno o realizar agregación contextual a lo largo de la secuencia. Esta diferencia estructural se reflejará en los resultados experimentales posteriores y constituye una de las motivaciones principales para incluir arquitecturas con memoria en el presente trabajo.




Figura 9: Ejemplo de input-target de entrenamiento para una sala de $RT60=0.212s$.

3.2.3 Construcción del conjunto de entrenamiento

Una vez extraídas las señales envantanasadas que constituyen los pares de entrenamiento supervisado $(\mathbf{x}_i, \mathbf{y}_i)$, se organiza el conjunto de entrenamiento utilizando estructuras estándar de PyTorch [24]. En particular, se emplean objetos `TensorDataset` y `DataLoader` para facilitar la manipulación por lotes “batching” durante el proceso de entrenamiento. Esto permite aprovechar de forma eficiente la paralelización en GPU y simplifica la alimentación del modelo con datos estructurados.

3.2.4 Transformación espectral

Para aquellos modelos que operan en el dominio espectral se aplica una transformación rápida de Fourier real `rFFT` sobre las ventanas temporales. Esta transformación convierte cada ventana de 256 muestras en una representación espectral de 129 componentes complejos, correspondientes a las frecuencias positivas del espectro debido a la simetría hermítica de la FFT real (ver Anexo A, Sección 2). Este dominio espectral facilita una representación explícita de las propiedades frecuenciales de la señal, lo que permite utilizar ciertas arquitecturas diseñadas para operar sobre espectrogramas o imágenes.

No obstante, esta representación introduce también algunas limitaciones importantes. En particular, la transformación al dominio de Fourier implica la pérdida de localización temporal precisa de los eventos transitorios presentes en la señal original. Esto se detalla en [25] y puede ser especialmente problemático para eventos de corta duración o patrones no estacionarios, cuya manifestación en el dominio espectral se encuentra difuminada o solapada entre varios componentes de frecuencia. Además, la fase espectral —aunque teóricamente preservada en la representación compleja— puede resultar difícil de modelar de forma robusta para arquitecturas que no hayan sido específicamente diseñadas para manipular información compleja. Por estas razones, trabajar en el dominio espectral puede implicar una pérdida de información contextual que sí está presente de manera explícita en la señal temporal. Este compromiso entre representación frecuencial y preservación temporal será un aspecto clave que influirá en la comparación entre modelos.

3.3 Modelos propuestos

En esta sección se presentan los distintos modelos desarrollados para abordar la tarea de predicción de secuencias. Todos los modelos han sido implementados utilizando la biblioteca `PyTorch` [24], una herramienta ampliamente utilizada en el campo del aprendizaje profundo por su flexibilidad y su integración nativa con operaciones en GPU. `PyTorch` proporciona una interfaz dinámica para la construcción de redes neuronales, permitiendo una implementación eficiente de arquitecturas complejas y una experimentación ágil.

A continuación, se describen los modelos explorados, comenzando por una arquitectura básica.

3.3.1 Modelo 1: Perceptrón Multicapa (MLP)

- **Arquitectura:** Red neuronal “feedforward” de tipo MLP.
- **Entrada:** Vectores individuales de dimensión 256, correspondientes a valores de señal en tiempo.
- **Procesamiento:** Una única capa oculta totalmente conectada de 300 unidades, seguida de función de activación ReLU.
- **Salida:** Capa lineal final que transforma de 300 a 256 dimensiones.
- **Número total de parámetros:** 154.156.




Figura 10: Esquema básico de MLP.

Este modelo que podemos observar en la Figura 10 no incorpora mecanismos explícitos para el manejo de dependencias temporales, lo que permite valorar la contribución específica de la arquitectura recurrente en el modelo siguiente.

3.3.2 Modelo 2: LSTM simple

- **Arquitectura:** Red neuronal de tipo LSTM unidireccional.

- **Entrada:** Secuencias de vectores de dimensión 256, correspondientes a los valores de señal en tiempo.
- **Procesamiento:** Una única capa LSTM con tamaño del estado oculto (hidden_size) de 128 unidades.
- **Salida:** Secuencia de salida proyectada mediante una capa totalmente conectada (Linear) que transforma de 128 a 256 dimensiones.
- **Número total de parámetros:** 230.656.




Figura 11: Esquema básico de LSTM. Dentro del bloque LSTM se procesa como se vió en la figura 4

Este modelo observable en la figura 11 constituye una primera aproximación al problema de mantener una memoria recurrente.

3.3.3 Modelo 3: LSTM espectral con convoluciones (ConvSpecLSTM)

- **Arquitectura:** Red neuronal que opera en el dominio espectral, combinando convoluciones espaciales y una LSTM.
- **Entrada:** Secuencias temporales transformadas a espectrogramas de 129 componentes complejos por frame (correspondientes a una FFT de tamaño 256).
- **Procesamiento:**
 - Dos capas convolucionales bidimensionales aplicadas sobre el espectrograma (canales real e imaginario) ampliando el número de canales de 2 a 4.
 - Reorganización del mapa espectral a vectores por “frame” y procesamiento mediante una LSTM unidireccional con estado oculto de 128 unidades.
 - Proyección lineal final desde 128 dimensiones a $2 \times 129 = 258$ para reconstruir la parte real e imaginaria del espectro.
- **Salida:** Secuencia del espectro complejo estimado (129 bins complejos por frame).
- **Número total de parámetros:** 364.274.

Este modelo visible en la Figura 12 opera completamente en el dominio espectral. La reconstrucción final de la señal temporal se realiza fuera de la red, mediante transformada inversa de Fourier (iFFT).




Figura 12: Esquema básico de ConvSpecLSTM.

3.3.4 Modelo 4: LSTM espectral con proyección de características (ProjSpecLSTM)

- **Arquitectura:** Red neuronal que opera en el dominio espectral, incorporando una proyección, explicada en la Sección 2.6.1, intermedia por bin hacia un espacio de características.
- **Entrada:** Secuencias de espectros de 129 componentes complejos por frame (resultantes de la FFT de la señal temporal).
- **Procesamiento:**
 - Proyección ϕ por bin complejo (parte real e imaginaria) a un espacio de características de dimensión $d = 4$ mediante una capa lineal compartida.
 - Reordenamiento de los espectros proyectados y procesamiento de la secuencia completa mediante una LSTM unidireccional con estado oculto de 128 unidades.
 - Decodificación final desde 128 a $2 \times 129 = 258$ dimensiones, correspondientes a la parte real e imaginaria de cada bin espectral.
- **Salida:** Secuencia del espectro complejo estimado (129 bins complejos por frame).
- **Número total de parámetros:** 364.046.




Figura 13: Esquema básico de ProjSpecLSTM.

Al igual que en el modelo anterior, la reconstrucción de la señal temporal se realiza fuera de la red mediante iFFT, siendo esta la base para calcular el MSE frente a la señal original.

3.3.5 Modelo 5: LSTM con mecanismo de atención (AttLSTM)

- **Arquitectura:** Red neuronal recurrente con mecanismo de atención integrado, diseñada para mejorar la captación de dependencias temporales a lo largo de secuencias extendidas.

- **Entrada:** Secuencias temporales de dimensión 256 por paso temporal, correspondientes a representaciones vectoriales de señal en tiempo.
- **Procesamiento:**
 - Una capa LSTM unidireccional con un único nivel y tamaño de estado oculto de 200 unidades.
 - Módulo de atención, Sección 2.6.3, aplicado a la salida del LSTM.
 - Conexión residual entre los vectores de contexto y la salida del LSTM.
 - Proyección final hacia la dimensión original (256) mediante una capa lineal.
- **Salida:** Secuencia reconstruida con la misma longitud temporal que la entrada y dimensión 256 por paso de tiempo.
- **Número total de parámetros:** 279.808.




Figura 14: Esquema básico de AttLSTM.

Este modelo representado en la figura 14 extiende el comportamiento de una LSTM tradicional al incorporar mecanismos de atención auto-regresiva, permitiendo una agregación explícita de información a lo largo de toda la secuencia. El objetivo es facilitar el modelado de dependencias temporales más complejas, relevantes para la predicción precisa de la señal.

3.3.6 Modelo 6: LSTM espectral con convoluciones y atención (AttConvSpecLSTM)

- **Arquitectura:** Red neuronal que opera en el dominio espectral, combinando convoluciones espaciales, una LSTM y un mecanismo de atención temporal.
- **Entrada:** Secuencias temporales transformadas a espectrogramas de 129 componentes complejos por frame (correspondientes a una FFT de tamaño 256).
- **Procesamiento:**
 - Dos capas convolucionales bidimensionales aplicadas sobre el espectro complejo (canales real e imaginario), ampliando el número de canales de 2 a 4.
 - Reorganización del mapa espectral a vectores por frame y procesamiento mediante una LSTM unidireccional con estado oculto de 128 unidades.

- Módulo de atención, Sección 2.6.3, aplicado a la salida del LSTM.
 - Conexión residual entre los vectores de contexto y la salida del LSTM.
 - Proyección final desde 128 a $2 \times 129 = 258$ dimensiones, correspondiente a la parte real e imaginaria del espectro.
- **Salida:** Secuencia del espectro complejo estimado (129 bins complejos por frame).
 - **Número total de parámetros:** 413.554.




Figura 15: Esquema básico de AttConvSpecLSTM.

Este modelo representado en la Figura 15 extiende la arquitectura del modelo *ConvSpecLSTM* al incorporar un mecanismo de atención temporal sobre la salida de la LSTM. Al igual que AttLSTM, se busca mejorar la captación de relaciones a largo plazo dentro de la secuencia, pero operando en el dominio espectral. La atención auto-regresiva permite una combinación ponderada de toda la trayectoria temporal, reforzando la capacidad del modelo para reconstruir de manera más precisa la señal.

3.4 Inferencia y reconstrucción de señal

Durante la fase de inferencia, el objetivo es reconstruir la señal completa de salida a partir de las predicciones generadas por el modelo sobre ventanas sucesivas de la señal de entrada. Para ello, se emplea una técnica clásica denominada solape y suma (*overlap-add*), que permite ensamblar múltiples predicciones parciales (ventanas) en una única secuencia continua.

3.4.1 Método de solape y suma

Durante la inferencia, cada ventana de entrada genera una predicción de salida de longitud fija. Para reconstruir la señal completa, se emplea el método de solape y suma (*overlap-add*), que consiste en ensamblar las predicciones parciales mediante suma ponderada en las regiones de solapamiento.

Supóngase que se tienen dos ventanas consecutivas de salida $\hat{y}_1[n]$ y $\hat{y}_2[n]$, cada una de longitud T , con un solape de L muestras entre ellas. El ensamblaje de ambas se define de forma segmentada como:

$$\hat{y}[n] = \begin{cases} \hat{y}_1[n], & 0 \leq n < T - L \\ \frac{1}{2} (\hat{y}_1[n] + \hat{y}_2[n - (T - L)]), & T - L \leq n < T \\ \hat{y}_2[n - (T - L)], & T \leq n < 2T - L \end{cases} \quad (3.11)$$

Este proceso se aplica recursivamente a lo largo de la secuencia de ventanas $\{\hat{y}_i[n]\}_{i=0}^N$.

Este método asegura una transición suave entre ventanas consecutivas, evitando artefactos por discontinuidad en la señal reconstruida.

3.4.2 Consideraciones según tipo de arquitectura

La elección del *hop size* durante la inferencia está íntimamente relacionada con la arquitectura del modelo, particularmente con la presencia o ausencia de mecanismos de memoria interna, como las capas LSTM.

Modelos MLP sin memoria temporal

En redes del tipo MLP, donde no existe una dependencia explícita entre ventanas, cada predicción se realiza de forma independiente. Por tanto, la cantidad de solape utilizada durante la inferencia puede ser distinta a la empleada en el entrenamiento sin afectar negativamente al desempeño. De hecho, en contextos prácticos puede ser beneficioso tanto reducir el porcentaje de solape en inferencia para acelerar la reconstrucción o aumentarlo para que no se introduzcan artefactos en los puntos de unión y la predicción se más estable.

Modelos con memoria (LSTM y derivados)

En contraste, las redes basadas en **LSTM** (o variantes con atención) modelan dependencias temporales entre ventanas sucesivas. Esto implica que las relaciones temporales aprendidas están condicionadas al patrón de solape visto durante el entrenamiento. Cambiar dicho patrón en la fase de inferencia rompe las condiciones bajo las cuales se optimizaron los pesos del modelo, pudiendo llevar a degradaciones significativas en el rendimiento.

Por tanto, en estos casos es imprescindible mantener constante el valor del *hop size* entre entrenamiento e inferencia. Si el entrenamiento se realizó con ventanas de longitud T y solape S , de modo que $H = T - S$, entonces durante la inferencia se debe aplicar el mismo valor de H .

Esta restricción se puede justificar formalmente al considerar que el modelo ha aprendido una función $f_\theta : \mathbb{R}^T \rightarrow \mathbb{R}^T$ cuyo comportamiento está adaptado a una secuencia de entradas con correlaciones específicas en su temporalidad. Alterar dicha temporalidad implica una entrada fuera de distribución respecto al conjunto de entrenamiento.

3.4.3 Definición de Problema Estacionario

A lo largo del desarrollo del proyecto utilizaremos el término *estacionario* para referirnos a ciertas condiciones particulares del problema en estudio, lo cual difiere deliberadamente de la definición clásica de estacionariedad en el contexto de procesos estocásticos.

En este sentido, diremos que un problema es estacionario (o, de manera indistinta, que la señal de entrada es estacionaria, refiriéndonos a que generará un problema estacionario) cuando el sistema alcanza un *régimen estacionario*. Este régimen se establece cuando, al convolucionar la señal de en-

trada con la respuesta impulsiva del canal (por ejemplo, el canal primario de propagación), el sistema produce una salida que refleja una dinámica estable y periódica.

Formalmente, consideramos que se alcanza un régimen estacionario cuando la señal de entrada es repetitiva con una longitud estrictamente mayor a la longitud del filtro del canal. En este caso, el sistema puede considerarse en régimen estacionario, en el sentido que su salida será también repetitiva (o periódica) y no afectada por transitorios residuales del pasado.

A modo de resumen, en este trabajo adoptamos las siguientes definiciones prácticas:

- **Problema estacionario (o señal estacionaria):** el sistema alcanza un régimen estacionario bajo la entrada dada.
- **Problema no estacionario:** el sistema nunca alcanza un régimen estacionario bajo la entrada dada.
- **Problema cuasi-estacionario o semi-estacionario:** el sistema entra y sale repetidamente del régimen estacionario a lo largo del tiempo.

Cabe destacar que, en todos los casos, nos referiremos indistintamente a la señal de entrada como estacionaria o no estacionaria, entendiendo que dicha calificación implica una propiedad global del *problema acústico* completo, y no exclusivamente de la señal como entidad matemática. Esta convención es adoptada con fines prácticos para la formulación y análisis del problema en entornos simulados y experimentales.

3.4.4 Métrica NMSE

Para cuantificar el rendimiento del sistema ANC en un entorno simulado, se emplea como métrica principal el *Error Cuadrático Medio Normalizado* (NMSE, por sus siglas en inglés). En este contexto, el NMSE se define como la razón entre la energía residual en el micrófono de error cuando el sistema de cancelación está activado y la energía registrada en ese mismo micrófono cuando el sistema está desactivado. Esta formulación refleja directamente la eficacia de cancelación en el entorno acústico considerado.

Sea $x[n]$ la señal de ruido original, y sea $\hat{y}[n]$ la señal generada por el modelo. Sean $r_{ir1}[n]$ y $r_{ir2}[n]$ las respuestas impulsivas de la sala desde la fuente de ruido y desde el altavoz secundario hasta el micrófono de error, respectivamente. Entonces, la señal que se obtiene en el micrófono de error cuando el sistema está activo es:

$$e_{\text{act}}[n] = (\hat{y} * h_2)[n] + (x * h_1)[n], \quad (3.12)$$

donde $*$ denota la convolución lineal discreta y se asume superposición perfecta de las ondas en el micrófono de error.

De forma análoga, si el sistema de cancelación está desactivado ($\hat{y}[n] = 0$), la señal registrada en el micrófono de error es simplemente:

$$e_{\text{ref}}[n] = (x * h_1)[n]. \quad (3.13)$$

La métrica NMSE se define entonces como:

$$\text{NMSE} = \frac{\sum_{n=1}^N e_{\text{act}}^2[n]}{\sum_{n=1}^N e_{\text{ref}}^2[n]} = \frac{\sum_{n=1}^N [(\hat{y} * h_2)[n] + (x * h_1)[n]]^2}{\sum_{n=1}^N [(x * h_1)[n]]^2}. \quad (3.14)$$

Esta métrica refleja de manera directa la proporción de energía residual en el entorno tras la acción del sistema de cancelación, en relación con la energía original del ruido:

- $\text{NMSE} = 0$: cancelación perfecta, la señal del micrófono de error es nula.
- $\text{NMSE} = 1$: la señal de cancelación no tiene efecto alguno; el sistema no reduce el ruido.
- $\text{NMSE} > 1$: el sistema empeora la situación, amplificando el ruido en el micrófono de error.

En ocasiones, se expresa esta métrica en decibelios, mediante la transformación:

$$\text{NMSE}_{\text{dB}} = 10 \log_{10} (\text{NMSE}). \quad (3.15)$$

Valores negativos en dB indican atenuación efectiva del ruido, mientras que valores positivos implican amplificación no deseada. Esta métrica será utilizada sistemáticamente a lo largo de este trabajo para comparar el desempeño de los distintos modelos propuestos.

3.5 Fases experimentales del proyecto

El desarrollo del presente trabajo se estructuró en tres fases experimentales sucesivas, cada una con un nivel creciente de complejidad en la naturaleza de las señales utilizadas. Este enfoque progresivo permitió evaluar la robustez y generalización de los modelos de cancelación en distintos escenarios acústicos, desde configuraciones controladas hasta condiciones más realistas. A continuación, se describen las fases:

1. **Prueba con tonos aislados y combinados.** En una primera etapa se utilizaron señales compuestas por tonos sinusoidales puros (por ejemplo, 250 Hz, 500 Hz, etc.) y combinaciones de estos. Este tipo de estímulo proporciona un entorno altamente controlado y semi-estacionario, en el cual es posible analizar con precisión la respuesta del sistema a componentes frecuenciales individuales. También se introdujeron combinaciones de tonos para estudiar la capacidad del modelo de resolver superposición espectral y componentes no estacionarias simples. Esta fase tuvo como objetivo principal la calibración preliminar de los modelos y el diagnóstico de errores estructurales básicos antes de pasar a señales más complejas.
2. **Prueba con señales de ruido estándar.** En una segunda etapa se aplicaron señales de ruido típicamente utilizadas en tareas de benchmarking en ANC [26]. Este tipo de señales presenta una mayor riqueza espectral y variabilidad temporal, lo que permite evaluar la capacidad de generalización de los modelos entrenados, así como su desempeño frente a espectros continuos y distribuciones más realistas.

3. **Simulación en entorno realista: ruido de tráfico.** Finalmente, se realizó una simulación completa de un entorno con ruido de tráfico, representando un escenario acústico más cercano a aplicaciones realistas de ANC. Este entorno implica condiciones no estacionarias y una mayor complejidad tanto en el contenido temporal como espectral de las señales. Esta fase tuvo como finalidad validar el rendimiento práctico de los modelos en situaciones realistas y evaluar sus limitaciones en contextos de implementación aplicados.

Cada una de estas fases proporcionó información clave para la comparativa de los modelos, facilitando una evaluación progresiva de las distintas soluciones propuestas a lo largo del trabajo.

Capítulo 4:

Resultados

Este capítulo presenta los resultados obtenidos a lo largo de las distintas fases experimentales del proyecto, con el objetivo de evaluar el desempeño de los modelos de cancelación activa de ruido (ANC) propuestos. Las pruebas se han diseñado de manera progresiva, comenzando con señales sintéticas altamente controladas y finalizando con simulaciones realistas que emulan escenarios del mundo real.

Cada fase busca responder preguntas específicas sobre la capacidad de generalización, adaptación y robustez de los modelos entrenados bajo distintas condiciones. Asimismo, se analizan aspectos clave como la precisión de cancelación, la estabilidad temporal, la sensibilidad a la variación espectral y la consistencia del rendimiento ante cambios en el entorno sonoro.

Los resultados se organizan en tres fases principales:

- **Fase 1:** Evaluación del sistema con tonos sinusoidales aislados y combinados.
- **Fase 2:** Pruebas con señales clásicas de benchmarking en tareas de ANC.
- **Fase 3:** Simulación del comportamiento en un entorno más realista, como ruido de tráfico.

Cada sección incluye tanto la descripción del escenario de prueba como las métricas utilizadas y el análisis cuantitativo y cualitativo de los resultados obtenidos.

4.1 Fase 1: Prueba con tonos aislados y combinados

Como se detalló en el apartado anterior, la primera fase experimental se centra en la evaluación de los modelos ante señales compuestas por tonos sinusoidales puros y sus combinaciones. Este entorno controlado permite observar de manera precisa la respuesta del sistema ante componentes frecuenciales bien definidas, lo cual resulta útil para calibrar modelos y analizar su comportamiento en condiciones ideales. El objetivo de esta fase es identificar limitaciones estructurales básicas sin la complejidad añadida de señales altamente no estacionarias o ruidos reales.

Generación de la señal de entrada

Para esta etapa se diseñó un generador de señales basado en la inyección controlada y aleatoria de tonos en segmentos consecutivos a lo largo del tiempo. El procedimiento se implementa en la clase `SegmentSignalGenerator`, que permite modular la duración total, la frecuencia de muestreo, el número de divisiones y el conjunto de frecuencias disponibles.

En esta configuración, se utilizó en el entrenamiento una duración total de $D = 20$ s con una frecuencia de muestreo $f_s = 3000$ Hz, dividida en $N = 80$ segmentos de duración uniforme. Cada uno de estos segmentos corresponde a un intervalo temporal de:

$$T_{\text{segmento}} = \frac{20 \text{ s}}{80} = 0,25 \text{ s}. \quad (4.1)$$

El conjunto de frecuencias disponibles para generar la señal es:

$$\mathcal{F} = \{300 \text{ Hz}, 400 \text{ Hz}, 500 \text{ Hz}, 700 \text{ Hz}, 1200 \text{ Hz}\}.$$

El procedimiento general de generación puede describirse formalmente de la siguiente manera:

1. Para cada segmento $i \in \{0, 1, \dots, N - 1\}$, se selecciona aleatoriamente un subconjunto no vacío de frecuencias de $\mathcal{F}$. Esta selección se realiza con probabilidad uniforme entre los $2^{|\mathcal{F}|} - 1 = 31$ subconjuntos no vacíos posibles.
2. Para cada frecuencia $f \in A_i$ (el subconjunto seleccionado para el segmento i), se genera una senoide discreta definida por:

$$s_f[n] = \sin\left(2\pi f \cdot \frac{n}{f_s} + \phi_f\right), \quad n = 0, 1, \dots, L - 1, \quad (4.2)$$

donde f_s es la frecuencia de muestreo, L es la duración del segmento en muestras ($L = D \cdot f_s$), y ϕ_f es una fase aleatoria distribuida uniformemente en el intervalo $[-\pi, \pi]$. Esta aleatorización introduce variabilidad estructural entre instancias similares.

3. Las sinusoides correspondientes al segmento se suman punto a punto:

$$s_i[n] = \sum_{f \in A_i} \sin\left(2\pi f \cdot \frac{n}{f_s} + \phi_f\right). \quad (4.3)$$

4. La señal $s_i[n]$ se normaliza en amplitud dentro del segmento para evitar saturaciones:

$$\tilde{s}_i[n] = \frac{s_i[n]}{\max(|s_i[n]|)}. \quad (4.4)$$

5. Finalmente, cada segmento $\tilde{s}_i[n]$ se inserta en su posición correspondiente dentro de la señal completa $x[n]$, que representa la señal final de entrada construida concatenando todos los segmentos.

El resultado es una señal de entrada sintética con estructura cuasi-estacionaria simple, que permite verificar la capacidad de los modelos para detectar, adaptarse y cancelar componentes frecuenciales que aparecen y desaparecen repentinamente. Este tipo de comportamiento es representativo de situaciones relativamente reales como sirenas, alarmas intermitentes o maquinaria rotativa en funcionamiento discontinuo. En la inferencia generaremos una señal con las mismas características pero de duración menor, $D = 2$ s.

Elección del RT60 de la sala para la simulación

Para esta primera fase de evaluación se ha simulado un entorno acústico con un tiempo de reverberación $RT60 = 0,3$ s, correspondiente a una sala relativamente reverberante en el contexto de ANC. Esta configuración permite analizar la capacidad de los modelos para adaptarse a condiciones acústicas complejas mediante señales simples, concretamente tonos sinusoidales con cambios abruptos de contenido espectral cada 0,25 s.

Dicho entorno introduce implicaciones relevantes respecto al contenido temporal accesible a los modelos y la persistencia de la reverberación. Como se discutió en la Sección *Relación entre ventana y reverberación*, si el tiempo de reverberación supera los 85 ms, los ecos pueden extenderse más allá del intervalo temporal de entrada considerado por modelos sin mecanismos explícitos de memoria, como los MLP.

Aunque la estructura cuasi-estacionaria de las señales facilita parcialmente la adaptación de estos modelos, también pone de manifiesto su incapacidad para representar colas de eco prolongadas. Por tanto, este escenario actúa como banco de pruebas útil tanto para evaluar el rendimiento básico frente a componentes frecuenciales aisladas como para identificar las limitaciones de la arquitectura utilizada en cuanto a memoria y adaptabilidad. La comparación con modelos más sofisticados, como los basados en redes recurrentes, será especialmente ilustrativa en esta fase.

4.1.1 Modelo 0: FxLMS clásico

Como punto de referencia inicial, se incluye una evaluación del modelo clásico *Filtered-x Least Mean Squares* (FxLMS), ampliamente utilizado en sistemas de control activo de ruido (ANC) con arquitectura feedforward [1]. La explicación detallada de su funcionamiento, así como su implementación, se encuentra en el Anexo 6.4.

El algoritmo FxLMS es especialmente efectivo en entornos con características acústicas simples y estacionarias, como cancelación de tonos fijos o ruidos periódicos en espacios con baja reverberación. Sin embargo, al aplicar este modelo en el contexto simulado de esta primera fase, con un tiempo de reverberación de $RT60 = 0,3$ s, se presentan importantes desafíos estructurales.

En particular, en entornos altamente reverberantes como este, donde los ecos persisten por encima del umbral temporal que el filtro adaptativo puede considerar (en nuestro caso, 85 ms), el modelo no dispone de mecanismos que le permitan representar adecuadamente la dinámica acústica prolongada. Como resultado, en lugar de cancelar el ruido, puede amplificarlo, generando un comportamiento inestable o ineficiente.

Como puede observarse en la Figura 16, la señal en el micrófono durante la simulación no presenta




Figura 16: Señal registrada en el micrófono durante la simulación con FxLMS.

evidencia de cancelación efectiva. De hecho, el sistema rápidamente aprende que cualquier intervención activa tiende a empeorar el resultado. Esto se refleja en el comportamiento de la señal generada por el modelo: al cabo de un breve período de adaptación, el algoritmo termina por no emitir ninguna señal de cancelación, lo que se traduce en un NMSE prácticamente nulo.

Este resultado pone en evidencia una limitación fundamental del modelo: su incapacidad para operar de forma efectiva en entornos con reverberación elevada o variaciones no triviales en el contenido espectral de la señal. En este contexto, la estrategia óptima para el modelo es no actuar.

Por tanto, este primer experimento sirve para ilustrar los límites del enfoque clásico basado en filtros adaptativos lineales y justifica la necesidad de explorar modelos más sofisticados, capaces de integrar información temporal y estructural de forma más rica. En las siguientes secciones se abordarán modelos basados en redes neuronales, diseñados para superar precisamente este tipo de limitaciones.

4.1.2 Modelo 1: MLP

El primer modelo basado en redes neuronales evaluado en esta fase es un MLP. Este tipo de modelo, como ya explicamos en el marco teórico, consiste en una red neuronal totalmente conectada, sin mecanismos explícitos de memoria, lo cual implica que su capacidad de adaptación temporal depende exclusivamente de la longitud de la ventana de entrada y del entrenamiento supervisado realizado.

Los resultados obtenidos visibles en la figura 17 indican que el modelo MLP logra un comportamiento cancelador efectivo en la mayoría de los segmentos. La pérdida de entrenamiento muestra una convergencia poco estable pero rápida, y el espectro de la señal residual revela una atenuación significativa en las bandas dominantes (entorno a -10dB y -25dB) de la fuente de ruido pero añadiendo ruido en otras frecuencias.

La señal en el micrófono también refleja una reducción clara de la energía en presencia de ANC. No obstante, se observan pequeñas ineficiencias en la respuesta ante transiciones abruptas. El modelo aprende a cancelar muy bien cuando el problema es momentáneamente estacionario pero falla en los cambios de segmentos aumentando su NMSE que alcanza un valor de -9.271dB. Esto pone de manifiesto la limitación de los MLP: su falta de memoria interna para modelar efectos de reverberación prolongados o dinámicas temporales más complejas. Este punto será abordado en mayor profundidad en los modelos posteriores, que incorporan mecanismos explícitos de memoria temporal.

Ahora probaremos el mismo modelo disminuyendo la cadencia de segmentos de 0.25s a 1s, es decir, se cambiará la superposición de tonos en vez de 4 veces por segundo, una por segundo. Aquí el




Figura 17: Resultados del modelo MLP: evolución de la pérdida durante el entrenamiento, espectro residual y señal temporal en el micrófono de error.

modelo consigue mucho mejores resultados. Esto se puede observar en la Figura 18. Sin embargo esta simulación es demasiado simple para un sistema ANC




Figura 18: Señal registrada con MLP y una fuente de ruido más monótona.

4.1.3 Modelo 2: LSTM

El segundo modelo a evaluar será LSTM. A diferencia del MLP, las LSTM cuentan con mecanismos internos que les permiten conservar información relevante a lo largo del tiempo, lo que les confiere una capacidad explícita para modelar dependencias temporales y efectos de memoria en señales secuenciales.

En esta configuración, el modelo LSTM procesa secuencias temporales de la señal de error del micrófono y genera estimaciones dinámicas de la señal de control. Gracias a su arquitectura recurrente, se espera que el LSTM pueda adaptarse mejor a entornos reverberantes y señales no estacionarias,

superando las limitaciones del MLP en el manejo de información contextual prolongada.




Figura 19: Resultados del modelo LSTM: evolución de la pérdida durante el entrenamiento, espectro residual y señal temporal en el micrófono de error.

El entrenamiento del modelo LSTM se caracterizó por ser más lento en comparación con el MLP, dado que la red debe aprender relaciones temporales más complejas y patrones de dependencia a largo plazo en la señal de error. También se observa que es mucho más estable respecto a MLP. Debido a que el modelo se inicializa con pesos aleatorios, la función de pérdida comienza en un valor más alto que el observado para el MLP.

En el análisis espectral de la señal residual, se observan reducciones ligeramente superiores en las frecuencias dominantes respecto al MLP, así como un aumento menos pronunciado del ruido en las bandas no deseadas. Esto indica una mejor capacidad del LSTM para focalizar la cancelación en las componentes principales de la señal.

Asimismo, el modelo demuestra una mejor adaptación a los cambios abruptos en el contenido frecuencial de la señal, característica que se refleja en un desempeño cuantitativo superior, alcanzando un valor de NMSE de $-13,511$ dB. Este resultado evidencia que el LSTM puede capturar y compensar más efectivamente las variaciones temporales presentes en la señal de entrada, superando las limitaciones estructurales del MLP.

4.1.4 Modelo 3: ConvSpecLSTM

Como se explicó en el marco teórico, el modelo ConvSpecLSTM combina capas convolucionales con una red LSTM para operar en el dominio espectral. A diferencia del LSTM simple que procesa señales en el dominio temporal, este modelo utiliza espectrogramas complejos, procesados primero por convoluciones bidimensionales para extraer características locales en frecuencia y tiempo.

Luego, la representación se reorganiza y pasa por una capa LSTM unidireccional que modela dependencias temporales a largo plazo, seguida de una capa lineal que reconstruye la señal estimada en el dominio espectral para su posterior transformación al dominio temporal.

Aunque esta arquitectura captura mejor la estructura espectral y temporal, la transformación espectral reduce la resolución temporal, difuminando eventos transitorios. Además, la modelación de la fase espectral es compleja para arquitecturas estándar, lo que puede limitar el desempeño con señales muy no estacionarias.




Figura 20: Resultados del modelo ConvSpecLSTM: evolución de la pérdida durante el entrenamiento, espectro residual y señal temporal en el micrófono de error.

Como se observa en la figura 20, el entrenamiento del modelo ConvSpecLSTM presenta una dinámica similar a la del modelo LSTM, siendo más lento que el MLP. En la primera época, el valor de la pérdida es incluso mayor que el obtenido con el LSTM. Esto se debe a que el modelo, inicialmente con pesos aleatorios, debe aprender simultáneamente la representación espectral adecuada, las relaciones temporales complejas, así como los parámetros de las capas convolucionales para extraer características efectivas.

A lo largo del entrenamiento, la convergencia resulta estable, similar a lo observado en el modelo LSTM. En cuanto al espectro residual, el ConvSpecLSTM muestra picos más altos en las frecuencias dominantes y un ruido en las bandas no deseadas respecto a LSTM. Su desempeño medido mediante NMSE alcanza un valor de -11.147 dB, que aunque es ligeramente mejor que el MLP, se encuentra por debajo del rendimiento obtenido con el LSTM simple.

4.1.5 Modelo 4: ProjSpecLSTM

Como se explicó en el marco teórico, el modelo ProjSpecLSTM opera en el dominio espectral, similar al ConvSpecLSTM, pero utiliza una proyección lineal compartida por bin para transformar cada componente complejo a un espacio de características reducido. Esta representación compacta es procesada por una LSTM que modela las dependencias temporales y luego decodifica el espectro complejo estimado.

A diferencia del ConvSpecLSTM, que emplea convoluciones bidimensionales para capturar patrones locales en frecuencia y tiempo, el ProjSpecLSTM simplifica la extracción de características mediante proyecciones lineales, reduciendo la complejidad computacional y el número de parámetros. No obstante, al no aprovechar la estructura local del espectrograma, puede presentar limitaciones para identificar patrones espectrales complejos.




Figura 21: Resultados del modelo ProjSpecLSTM: evolución de la pérdida durante el entrenamiento, espectro residual y señal temporal en el micrófono de error.

El entrenamiento del modelo ProjSpecLSTM que se observa en la Figura 21 es el más lento entre todos los evaluados, comenzando con un valor de pérdida inicial similar al observado en el modelo ConvSpecLSTM. Esta lentitud se debe a la complejidad del aprendizaje de la proyección de características y la modelación de las dependencias temporales en el dominio espectral.

En el análisis del espectro, se observan atenuaciones más pronunciadas en las frecuencias dominantes y un aumento de ruido ligeramente menor en el resto del espectro en comparación con los otros modelos.

Además, este modelo demuestra una notable capacidad para ajustarse a cambios abruptos en la señal, lo que se refleja en un desempeño superior medido mediante un NMSE de $-13,826$ dB, constituyendo el mejor resultado obtenido hasta el momento en esta fase de evaluación.

4.1.6 Modelo 5: AttLSTM

Este modelo constituye una ampliación del modelo LSTM, incorporando un mecanismo de atención que permite agregar explícitamente información a lo largo de toda la secuencia. Este mecanismo facilita la modelación de dependencias temporales más complejas y de largo alcance, que pueden ser críticas para mejorar la precisión en la predicción de señales en entornos con dinámicas temporales extensas, como en este caso.

La inclusión del módulo de atención busca evaluar si esta capacidad adicional de captación y ponderación de información temporal mejora el desempeño del modelo frente a las limitaciones de las LSTM tradicionales, especialmente en contextos donde la memoria temporal y la adaptabilidad son fundamentales.




Figura 22: Resultados del modelo AttSpecLSTM: evolución de la pérdida durante el entrenamiento, espectro residual y señal temporal en el micrófono de error.

Como se observa en la Figura 22, el comportamiento del modelo AttLSTM durante el entrenamiento es muy similar al del LSTM simple, mostrando una convergencia estable y comparable en términos de velocidad y estabilidad. En el dominio espectral, ambos modelos presentan características similares, sin diferencias significativas en la forma de los espectros estimados.

En cuanto al desempeño cuantitativo, el modelo AttLSTM obtiene una ligera mejora en el error cuadrático medio normalizado (NMSE), alcanzando un valor de $-13,588$ dB, ligeramente superior al obtenido por el LSTM básico.

Sin embargo, esta mejora en rendimiento conlleva un aumento en el número total de parámetros, reflejando la complejidad adicional introducida por el módulo de atención. En conjunto, estos resultados indican que la incorporación del mecanismo de atención puede ofrecer ventajas marginales en precisión.

4.1.7 Modelo 6: AttConvSpecLSTM

Este modelo constituye la arquitectura más compleja y con mayor número de parámetros entre las consideradas. Puede interpretarse como una integración de los modelos ConvSpecLSTM y AttLSTM, combinando la extracción local de características mediante convoluciones bidimensionales, la modelación de dependencias temporales mediante LSTM y la agregación global de contexto a través de un mecanismo de atención.




Figura 23: Resultados del modelo AttConvSpecLSTM: evolución de la pérdida durante el entrenamiento, espectro residual y señal temporal en el micrófono de error.

El objetivo de esta arquitectura compuesta es aprovechar simultáneamente la estructura espectral local y las dependencias temporales largas, con la expectativa de lograr una mejora en la precisión de predicción frente a señales complejas o entornos altamente reverberantes.

En términos de comportamiento durante el entrenamiento, el modelo AttConvSpecLSTM muestra una convergencia estable aunque más lenta en comparación con otras arquitecturas. En el dominio espectral, se observa una atenuación efectiva de los picos en las frecuencias dominantes, de forma similar a modelos anteriores, pero con una importante ventaja: es el modelo que introduce menos ruido en las componentes no dominantes del espectro.

En cuanto a su desempeño cuantitativo, alcanza un *NMSE* de $-12,525$ dB en el micrófono de referencia. Aunque este valor no representa el mínimo absoluto entre todos los modelos evaluados, sí sugiere una adaptación particularmente eficaz a los cambios abruptos entre segmentos, lo cual es coherente con la capacidad del mecanismo de atención para capturar dependencias globales dentro de la secuencia.

Cabe destacar que, al compararlo directamente con su contraparte sin atención (ConvSpecLSTM), la inclusión del módulo de atención proporciona una mejora notable, tanto en la estabilidad espectral co-

mo en la adaptabilidad a variaciones temporales. Esto confirma la utilidad de incorporar mecanismos de atención en arquitecturas que ya operan sobre representaciones espectrales estructuradas.

4.1.8 Conclusión de resultados en la Fase 1

En la Tabla 1 se recogen los resultados obtenidos por los diferentes modelos evaluados en esta primera fase. La comparación se ha realizado bajo las mismas condiciones de entrenamiento, asignando tiempos de entrenamiento equivalentes para todos los modelos, con el objetivo de observar su capacidad de adaptación y convergencia en un entorno con señales semi-estacionarias y reverberación moderada.

Modelo	FxLMS	MLP	LSTM	ConvSpecLSTM	ProjSpecLSTM	AttLSTM	AttConvSpecLSTM
Parámetros	256	154.156	230.656	364.274	364.046	279.808	413.554
NMSE [dB]	-0.28	-9.27	-13.511	-11.147	-13.826	-13.588	-12.525
Velocidad convergencia	Muy baja	Alta	Alta	Baja	Baja	Media	Muy baja

Tabla 1: Comparación de desempeño y complejidad de los modelos evaluados en la Fase 1.

Tal como era esperable, los modelos basados en redes LSTM, que cuentan con mecanismos explícitos de memoria temporal, superaron en desempeño a modelos sin recurrencia como los MLP, especialmente en términos de NMSE. En este sentido, el modelo ProjSpecLSTM obtuvo la mejor puntuación global con un NMSE de $-13,826$ dB, destacándose tanto por su capacidad de adaptación como por su desempeño en la atenuación de componentes dominantes del espectro.

No obstante, también se observó que los modelos que operan en el dominio espectral —como ConvSpecLSTM, ProjSpecLSTM y AttConvSpecLSTM— tienden a requerir más tiempo de entrenamiento para aprender relaciones temporales complejas. Esta característica pudo haber sido una desventaja en esta fase, en la que todos los modelos fueron entrenados un mismo tiempo aproximadamente. En contraste, los modelos que operan directamente sobre la señal temporal —como LSTM y AttLSTM— mostraron una convergencia más rápida hacia soluciones razonablemente estables.

En cuanto al impacto del módulo de atención, se observó una ligera mejora en el rendimiento general de los modelos que lo incorporaron. Esta mejora fue especialmente significativa en el caso de AttConvSpecLSTM, que mostró menor ruido residual fuera de las bandas dominantes, a pesar de no ser el modelo con menor NMSE absoluto. El mecanismo de atención parece haber facilitado una mejor adaptación a los cambios abruptos entre segmentos de señal, una cualidad deseable en entornos no estacionarios.

Desde una perspectiva de eficiencia, el modelo LSTM simple se posiciona como la mejor opción en relación al número de parámetros y el rendimiento obtenido, logrando un equilibrio destacable entre complejidad y desempeño. Por otro lado, el modelo MLP mostró una capacidad muy limitada para adaptarse a las transiciones espectrales, lo que refuerza su inadecuación en tareas con dinámica temporal relevante.

En resumen, esta fase ha permitido validar varias hipótesis preliminares sobre la utilidad de la memoria explícita, la importancia del dominio de representación (temporal vs espectral), y el valor añadido de mecanismos de atención. No obstante, debe subrayarse que los modelos espectrales podrían no haber alcanzado su rendimiento óptimo debido a restricciones de tiempo de entrenamiento.

4.2 Fase 2: Evaluación sobre señales reales de benchmarking

En esta segunda fase del estudio se analizará el comportamiento de los modelos propuestos ante señales de ruido reales ampliamente utilizadas en tareas de ANC. Para ello, se emplearán cuatro tipos de señales extraídas de la base de datos NOISEX-92, un conjunto clásico de benchmarking que contiene grabaciones de ruido ambiental bajo diversas condiciones:

- **Babble:** Ruido generado por múltiples voces humanas habladas de forma simultánea, similar al ambiente acústico de una cafetería concurrida o una sala llena de conversaciones.
- **Factory:** Ruido característico de entornos industriales, como maquinaria en funcionamiento o procesos de manufactura pesados.
- **SSN (Speech-Shaped Noise):** Ruido de espectro similar al del habla, pero sin estructura temporal ni semántica, utilizado comúnmente como máscara acústica.

Babble y SSN pueden considerarse no estacionarios, ya que presentan variaciones abruptas y dinámicas rápidas en su contenido temporal, lo que desafía la capacidad de adaptación de los modelos. Por el contrario, Factory presenta un comportamiento más cuasi-estacionario (la dinámica de las máquinas de una fábrica se puede repetir en el tiempo, mismos motores, mismos martillos, etc), con una estructura de ruido más estable y repetitiva en el tiempo, aunque con diferentes distribuciones espectrales.

Para mantener la comparabilidad con trabajos previos, se ha fijado el entorno de prueba a una sala con tiempo de reverberación $RT60 = 0,212$ s, correspondiente al entorno utilizado en [4]. En dicho estudio, se entrenó un único modelo de aproximadamente 8 millones de parámetros, diseñado para adaptarse simultáneamente a múltiples condiciones de ruido gracias a su elevada capacidad.

En contraste, nuestro enfoque busca comprender mejor la adaptabilidad y especialización de modelos mucho más compactos. Por ello, se entrenará un modelo independiente para cada tipo de ruido, utilizando las arquitecturas previamente evaluadas en la Fase 1. Este diseño experimental permite analizar en detalle qué configuración resulta más eficaz en cada entorno acústico particular, destacando fortalezas y debilidades relativas según el tipo de señal de entrada.

Esta fase, por tanto, complementa el análisis anterior ofreciendo una perspectiva más realista y centrada en escenarios de aplicación reales para sistemas ANC, sin renunciar a la eficiencia y compacidad del modelo.

Generación y segmentación de datos

Para esta fase se han utilizado señales reales extraídas de la base de datos NOISEX-92, disponibles públicamente en el repositorio [26]. Cada una de las señales seleccionadas tiene una duración aproximada de 235 segundos y está muestreada a $f_s = 3$ kHz.

Con el objetivo de simular variaciones espectro-temporales más realistas y permitir una mayor robustez en el entrenamiento, se ha diseñado un procedimiento de segmentación y recomposición aleatoria de las señales. Este proceso se basa en la siguiente estrategia:




Figura 24: Espectrogramas de las señales a utilizar.

- Se toma el 80 % inicial de la señal para generar el conjunto de entrenamiento, reservando el 20 % restante para el testeo.
- A partir del segmento de entrenamiento, se generan ventanas de longitud variable mediante un número de divisiones n seleccionado aleatoriamente de una distribución uniforme en el intervalo $[40, 70]$. Esto da lugar a ventanas de duración entre aproximadamente 3,35 s y 5,88 s.
- Las ventanas generadas se almacenan y se seleccionan aleatoriamente para recomponer una nueva señal de entrenamiento con una longitud objetivo de aproximadamente el doble del tamaño original (es decir, 470 segundos). Esta recomposición se realiza concatenando ventanas en orden aleatorio hasta alcanzar dicha longitud, truncando el exceso si fuese necesario.

Este método permite una mayor diversidad estructural en las señales de entrenamiento, al tiempo que conserva las propiedades estadísticas generales del ruido original. Así, se obtiene un conjunto más representativo para el análisis de la capacidad de adaptación de los modelos bajo condiciones variadas, sin necesidad de introducir nuevos tipos de ruido externos y previniendo la memorización.

4.2.1 Modelos de referencia: FxLMS y DeepANC

Antes de presentar los resultados obtenidos por los modelos propuestos y por poner en contexto, se recogen en la Tabla 2 los valores de NMSE reportados para dos modelos de referencia: el algoritmo clásico FxLMS y el modelo profundo DeepANC [4] en su configuración más simple computacionalmente bajo condiciones de reverberación $RT60 \approx 0,2$ s parecidas a las nuestras.

Modelo	Babble	Factory	SSN
FxLMS (dB)	-6.95	-6.62	-6.45
DeepANC (dB)	-12.08	-11.71 dB	-12.53

Tabla 2: NMSE en dB reportado en [4] para los modelos FxLMS y DeepMCANC bajo reverberación moderada ($RT60 \approx 0,2$ s).

Como se observa, el algoritmo FxLMS presenta una mejora sustancial respecto a sus resultados en la Fase 1, lo cual se atribuye a la menor reverberación en la sala, que permite una mayor estabilidad y adaptabilidad de este tipo de controlador adaptativo clásico.

Por su parte, el modelo DeepANC en su versión ligera demuestra una capacidad notable para adaptarse a las distintas señales de ruido, alcanzando valores de NMSE significativamente más bajos en todos los casos. Esto se debe en parte a su gran capacidad representacional (aproximadamente 8 millones de parámetros) y a su entrenamiento conjunto sobre múltiples escenarios.

Sin embargo, en este enfoque global no se exploraron otras posibles representaciones intermedias que podrían resultar más eficientes o especializadas. A continuación, se analizarán nuestros modelos mucho más compactos, entrenados específicamente para cada tipo de ruido, con el objetivo de evaluar si un diseño especializado puede superar en rendimiento a una arquitectura generalista como DeepANC.

4.2.2 Modelo 1: MLP

En esta sección se evalúa el comportamiento del modelo MLP en los distintos escenarios de ruido definidos. Tal como se observó en la Fase 1, el modelo MLP, al carecer de mecanismos explícitos de memoria o recurrencia, mostró limitaciones claras ante señales no estacionarias y entornos altamente reverberantes. Aunque en esta fase la reverberación ha sido reducida, no se espera que este modelo supere a arquitecturas más sofisticadas, especialmente en escenarios con dinámicas temporales marcadas. Aun así, se anticipa que su rendimiento empeore ligeramente respecto a la Fase 1, y que sea menos favorable cuanto menor sea el grado de estacionariedad del ruido.

A continuación, se presentan los resultados obtenidos por el modelo MLP para cada una de las señales consideradas:

Señal de ruido	NMSE [dB]
Babble	-5.64
Factory	-6.02
SSN	-5.32

Tabla 3: Rendimiento del modelo MLP para distintas señales de ruido en Fase 2.

Los resultados obtenidos por el modelo MLP en esta fase son inferiores a los reportados para el algoritmo clásico FxLMS. Este rendimiento subóptimo se alinea con las expectativas: el MLP no incorpora mecanismos de memoria o modelado secuencial, lo que lo hace especialmente vulnerable frente a señales altamente dinámicas o no estacionarias. En esta evaluación, todos los ruidos presentan algún grado de variabilidad temporal, siendo Babble y SSN especialmente desafiantes por su naturaleza abrupta y fluctuante. Incluso en el caso de Factory, que es más estacionario, el MLP no logra superar el rendimiento del FxLMS.

Estos resultados refuerzan la idea de que, aunque el MLP pueda ofrecer ventajas en escenarios artificiales o controlados con patrones muy regulares, su capacidad de generalización y adaptación a entornos acústicos reales es limitada. En la Figura 25 podemos observar cómo el modelo apenas es capaz de atenuar el ruido en el micrófono para SSN.

4.2.3 Modelo 2: LSTM

En esta fase se evalúa nuevamente el modelo LSTM, que en la Fase 1 demostró una destacada capacidad para adaptarse a señales semi-estacionarias con cambios abruptos, superando claramente al




Figura 25: Espectro ejemplo de SSN cancelado con MLP.

modelo MLP en términos de convergencia y rendimiento general.

Dado que el LSTM incorpora mecanismos explícitos de memoria mediante sus celdas recurrentes, se espera que responda de manera más robusta frente a los retos que presentan los ruidos de Babble, Factory y SSN, especialmente en comparación con el MLP. Su capacidad para modelar dependencias temporales a mayor escala debería traducirse en una mayor efectividad frente a componentes no estacionarios, como los presentes en las señales de esta fase. Los resultados se recogen en la Tabla 4

Señal de ruido	NMSE [dB]
Babble	-13.062
Factory	-11.76
SSN	-15.57

Tabla 4: Rendimiento del modelo LSTM para distintas señales de ruido en Fase 2.

En la Figura 26 se presentan las formas de onda en micrófono (izquierda) y los espectros residuales estimados (derecha) para cada una de las señales. El modelo LSTM muestra un comportamiento muy sólido, superando ampliamente a modelos previos como FxLMS y MLP. La mejora más significativa se observa en la señal SSN, seguida de Babble y finalmente Factory.

Este rendimiento diferencial puede explicarse, en primer lugar, por la distribución espectral de las señales de entrada. En el caso de SSN, la mayor parte de la energía espectral se concentra en el rango de 100–400 Hz, una zona donde el sistema presenta una mayor precisión temporal y espacial, entendiendo por esto la capacidad de emitir la onda opuesta en el momento y en el lugar exacto. Como se explicó en el marco teórico, las ondas de baja frecuencia requieren una menor sincronización temporal precisa entre la señal original y la señal de cancelación para lograr interferencia destructiva efectiva. En contraste, las ondas de alta frecuencia son mucho más sensibles al desfase temporal: pequeños errores en la estimación o generación de la señal de cancelación pueden convertir una cancelación destructiva en constructiva, degradando el rendimiento del sistema.

Las señales Babble y Factory, al presentar una mayor dispersión de energía en el espectro, incluyendo componentes significativos en frecuencias medias y altas, son más difíciles de cancelar de forma eficaz. En particular, Factory presenta una caída más lenta del contenido espectral hacia frecuencias altas, lo que agrava este problema. Por esta razón, aunque el rendimiento en Babble es ligeramente inferior al de SSN, resulta mejor que en Factory, donde la cancelación de componentes de alta

frecuencia es menos efectiva debido a las limitaciones inherentes al modelo.




Figura 26: Resultados del modelo LSTM para señales Babble, Factory y SSN (de arriba a abajo). A la izquierda se muestra la señal en micrófono y a la derecha el espectro residual correspondiente.

En conjunto, los resultados refuerzan la conclusión de que el modelo LSTM ofrece una capacidad de adaptación notable frente a señales no estacionarias, y que su desempeño está fuertemente influenciado por la distribución espectral de la señal de referencia.

Cabe destacar que este modelo LSTM, a pesar de su simplicidad y bajo número de parámetros en comparación con arquitecturas mucho más complejas como DeepANC, ha conseguido superar su rendimiento en todas las señales evaluadas. Esta mejora puede atribuirse al hecho de que el modelo ha sido entrenado específicamente para cada tipo de señal, lo que permite una mejor adaptación a las características particulares del ruido objetivo.

Esta estrategia de entrenamiento especializado representa una ventaja clave frente a enfoques generalistas como el de [4], cuyo modelo altamente parametrizado fue entrenado de forma conjunta para múltiples escenarios.

Con el objetivo de evaluar la capacidad de generalización de los modelos compactos entrenados específicamente para cada tipo de señal, se ha probado el modelo LSTM previamente ajustado para el entorno Factory sobre señales distintas: Babble y SSN.

Este análisis permite observar hasta qué punto la estructura del modelo y la información aprendida en una condición acústica determinada son transferibles a otras situaciones. Dado que Factory presenta

un contenido espectral relativamente amplio, se espera que el modelo pueda capturar patrones útiles también en señales con distribuciones espectrales similares o más restringidas.

Los resultados obtenidos se resumen en la Tabla 5.

Señal de prueba	NMSE [dB]
Babble	-11.656
SSN	-12.138

Tabla 5: Resultados de NMSE al evaluar el modelo LSTM entrenado con Factory sobre otras señales.

Como se observa, el modelo logra mantener un desempeño razonable en Babble y especialmente en SSN, lo que sugiere una cierta capacidad de generalización cuando el dominio espectral de la señal de prueba está contenido en el de entrenamiento. No obstante, la pérdida de rendimiento respecto al entrenamiento específico evidencia la importancia de ajustar los modelos a las características particulares de cada señal acústica.




Figura 27: Ejemplo del funcionamiento en SSN entrenado con Factory.

Se realizará el mismo experimento, entrenando el modelo con la señal SSN para evaluar su capacidad de extrapolación a Babble y Factory. Esto permitirá comprobar si el modelo también generaliza en esta dirección.

Los resultados obtenidos son los esperados. Al entrenar con SSN, una señal con espectro más acotado y menor riqueza espectral, el modelo pierde capacidad para generalizar adecuadamente a señales con espectros más dispersos y variados como Babble y Factory. Esto evidencia que la diversidad espectral en el entrenamiento es clave para una mejor extrapolación en este modelo.

Señal de prueba	NMSE [dB]
Babble	-8.869
Factory	-8.413

Tabla 6: Resultados de NMSE al evaluar el modelo LSTM entrenado con SSN sobre otras señales.




Figura 28: Espectro de cancelación en Factory entrenado con SSN para LSTM.

4.2.4 Modelo 3: ConvSpecLSTM

En esta fase evaluaremos nuevamente el modelo ConvSpecLSTM, que combina convoluciones espaciales con una LSTM en el dominio espectral. Aunque en la Fase 1 mostró un rendimiento intermedio, su arquitectura tiene potencial para capturar relaciones espectro-temporales complejas. En esta segunda fase, con señales más realistas y ricas en contenido frecuencial, evaluaremos si este modelo es capaz de superar sus limitaciones previas y destacar frente al resto, mejorando los resultados obtenidos anteriormente.

Señal de ruido	NMSE [dB]
Babble	-11.353
Factory	-10
SSN	-12.329

Tabla 7: Rendimiento del modelo ConvSpecLSTM para distintas señales de ruido en Fase 2.

Los resultados obtenidos por el modelo ConvSpecLSTM se muestran en la Tabla 7. En general, su rendimiento ha sido inferior al del modelo LSTM, presentando una menor capacidad de cancelación en todo el rango frecuencial. Esta limitación ha sido especialmente evidente en la banda de frecuencias medias (400–800 Hz), donde la cancelación ha resultado menos eficaz.

Esta deficiencia puede observarse claramente en la Figura 29, donde se muestra el espectro residual para la señal SSN. En comparación con la Figura 26, correspondiente al modelo LSTM, la diferencia en la capacidad de atenuación en dicho rango frecuencial es evidente.

Esta degradación del rendimiento puede atribuirse, en parte, a la codificación espectral utilizada en este modelo, la cual introduce una pérdida de resolución temporal al representar las señales en el dominio frecuencia-tiempo. Esta pérdida dificulta una reconstrucción precisa de la señal a cancelar,




Figura 29: Espectro residual del modelo ConvSpecLSTM para la señal SSN.

especialmente en regiones donde se requiere una sincronización temporal muy precisa. Asimismo, se observa una merma de resolución en frecuencias altas, lo que repercute de manera notable en el resultado obtenido para la señal Factory, cuyo contenido espectral está más distribuido hacia dichas frecuencias. Esta pérdida de precisión explica la caída más pronunciada del NMSE para esta señal en comparación con el resto.

A continuación, se evaluará la capacidad de extrapolación del modelo mediante pruebas de validación cruzada entre señales, siguiendo la misma metodología aplicada en los modelos anteriores.

A) NMSE entrenado con SSN		B) NMSE entrenado con Factory	
Señal de prueba	NMSE [dB]	Señal de prueba	NMSE [dB]
Babble	-6.795	Babble	-8.072
Factory	-6.405	SSN	-7.95

Tabla 8: Comparación cruzada de rendimiento del modelo ConvSpecLSTM entrenado con distintas señales al evaluarse sobre señales distintas.

Los resultados presentados en la Tabla 8 muestran un rendimiento modesto del modelo ConvSpecLSTM en escenarios de generalización cruzada. En todos los casos, se observa que el modelo extrapola con mayor eficacia cuando es entrenado con la señal Factory, lo que confirma nuevamente la ventaja que ofrece su mayor riqueza espectral. Esta característica permite al modelo aprender representaciones más versátiles que se transfieren mejor a otras señales, incluso con contenidos espectrales distintos.

No obstante, el rendimiento global del modelo es limitado, tanto en términos absolutos como relativos frente a otras arquitecturas evaluadas previamente. A pesar de ser el modelo más estructuralmente similar a DeepANC —en cuanto al uso combinado de codificación espectral y convoluciones—, ConvSpecLSTM ha demostrado una peor capacidad de adaptación y generalización. Esta diferencia de comportamiento podría atribuirse a la limitada profundidad de capas convolucionales (solo 2) del modelo empleado en este estudio, así como a su número reducido de parámetros, lo cual podría restringir su capacidad de modelar eficazmente patrones complejos en las señales de entrada. Es plausible que los modelos convolucionales, para ser competitivos en este tipo de tareas, requieran una

arquitectura de mayor complejidad. Sin embargo, eso escapa a los objetivos de este trabajo.

4.2.5 Modelo 4: ProjSpecLSTM

Esta sección nos ayudará a verificar si el uso de una codificación espectral proyectada mediante la transformación ϕ de ProjSpecLSTM descrita en el marco teórico es capaz de captar de forma más eficiente la estructura relevante del espectro, reduciendo la dimensionalidad sin perder información significativa para la tarea de cancelación.

En la Fase 1, esta arquitectura mostró un rendimiento superior al de ConvSpecLSTM, evidenciando una mayor capacidad de modelado a pesar de contar con una estructura similar en términos de parámetros. En esta segunda fase, evaluaremos si esta ventaja se mantiene al enfrentarse a señales de ruido reales, con características espectro-temporales más complejas y variadas.

Señal de ruido	NMSE [dB]
Babble	-11.756
Factory	-11.01
SSN	-14.5

Tabla 9: Rendimiento del modelo ConvSpecLSTM para distintas señales de ruido en Fase 2.

El modelo ProjSpecLSTM ha demostrado un rendimiento superior al de ConvSpecLSTM en todas las señales evaluadas, tal como se observa en la Tabla 9. Este resultado sugiere que la codificación espectral proyectada mediante $\phi(\cdot)$ permite al modelo capturar mejor la estructura temporal de las señales, facilitando una cancelación más precisa y robusta.




Figura 30: Espectro de salida del modelo ProjSpecLSTM para la señal SSN.

En particular, el modelo ha conseguido una notable mejora en la señal SSN, alcanzando un NMSE de $-14,5$ dB respecto a ConvSpecLSTM. Esto refuerza la idea de que la proyección espectral mejora la resolución temporal, facilitando la modelización de detalles dinámicos del espectro.

Tal como se puede apreciar en la Figura 30, correspondiente al espectro de salida para la señal SSN, el modelo consigue una atenuación más uniforme y eficaz en todo el rango de frecuencias, con una mejora especialmente notable alrededor de los 800 Hz, donde ConvSpecLSTM presentaba mayores

dificultades, como se observó en la Figura 29.

A continuación, se presentan las figuras correspondientes a la señal captada en el micrófono para la señal Factory y su respectivo espectro de salida tras la cancelación mediante el modelo ProjSpecLSTM. Estas imágenes se incluyen en la Figura 31.




Figura 31: Señal en el micrófono (arriba) y espectro de salida (abajo) del modelo ProjSpecLSTM para la señal Factory.

Los resultados obtenidos con ProjSpecLSTM evidencian una mejora significativa respecto a ConvSpecLSTM en la tarea de cancelación sobre señales con un espectro más disperso, como es el caso de Factory. Mientras que ConvSpecLSTM presentaba limitaciones en su capacidad para atenuar eficazmente las componentes de media y alta frecuencia, el modelo proyectado ha conseguido una cancelación más precisa y estable en esas bandas. Si bien los resultados no alcanzan aún el desempeño del modelo LSTM simple, que continúa siendo el más eficaz en términos generales, ProjSpecLSTM representa un avance sustancial hacia una cancelación precisa mediante arquitecturas espectrales compactas. Esto sugiere que la combinación de representaciones espectrales con mecanismos de proyección adecuados puede ser una vía prometedora para optimizar modelos ligeros en escenarios complejos.

Los resultados del modelo ProjSpecLSTM evaluado en condiciones cruzadas de entrenamiento y prueba se muestran en la Tabla 10. Se observa que, aunque este modelo presenta un rendimiento notable en tareas específicas, su capacidad de generalización entre diferentes tipos de ruido es inferior a la mostrada por el modelo LSTM. Esto sugiere que, a pesar de las mejoras introducidas por la codificación espectral proyectada, ProjSpecLSTM sigue dependiendo en mayor medida de las características particulares del ruido con el que ha sido entrenado.

A) NMSE entrenado con Babble		B) NMSE entrenado con Factory	
Señal de prueba	NMSE [dB]	Señal de prueba	NMSE [dB]
Factory	-10.38	Babble	-10
SSN	-9.88	SSN	-7.8

Tabla 10: Comparación cruzada de rendimiento del modelo ProjSpecLSTM entrenado con distintas señales al evaluarse sobre señales distintas.




Figura 32: Espectro de cancelación en SSN entrenado con Babble para ProjSpecLSTM.

4.2.6 Modelo 5: AttLSTM

Este modelo corresponde a la variante con mecanismo de atención del modelo LSTM. Tal como se detalló en el marco teórico, la atención permite al modelo focalizarse dinámicamente en las partes más relevantes de la secuencia de entrada, lo que puede mejorar la capacidad de representación temporal y espacial. En la Fase 1, este enfoque logró una ligera mejora respecto al LSTM clásico. En esta sección, se evaluará nuevamente si esta arquitectura, sin representaciones espectrales explícitas, logra un mejor desempeño frente a los modelos espectrales, y si el mecanismo de atención vuelve a aportar ventajas relevantes bajo las condiciones de prueba de esta Fase 2.

Señal de ruido	NMSE [dB]
Babble	-15.407
Factory	-14.42
SSN	-15.226

Tabla 11: Rendimiento del modelo AttLSTM para distintas señales de ruido en Fase 2.

Los resultados obtenidos por el modelo AttLSTM se muestran en la Tabla 11. Tal como ocurrió en la Fase 1, este modelo logra superar al LSTM clásico en todas las señales de prueba, lo que confirma que el mecanismo de atención aporta una mejora sistemática en el rendimiento del modelo, probablemente debido a su capacidad para asignar pesos dinámicos a diferentes partes de la secuencia de entrada. Esto convierte a este modelo en el que mejor desempeño ha tenido hasta ahora.

En la Figura 33 se presentan los resultados correspondientes a las señales Factory y SSN, tanto a nivel de señal en el micrófono como en su representación espectral. Comparando con la Figura 26, es

posible observar una atenuación más pronunciada, especialmente en las frecuencias medias-altas, lo que evidencia una mayor capacidad del modelo para cancelar componentes más difíciles del espectro acústico. Esta mejora sugiere que el mecanismo de atención puede estar ayudando al modelo a enfocarse más eficazmente en las componentes temporales y espectrales más relevantes para la tarea de cancelación.




Figura 33: Resultados del modelo AttLSTM para señales Factory (arriba) y SSN (debajo). A la izquierda se muestra la señal en micrófono y a la derecha el espectro residual correspondiente.

A) NMSE entrenado con Babble

Señal de prueba	NMSE [dB]
Factory	-14.06
SSN	-12.91

B) NMSE entrenado con Factory

Señal de prueba	NMSE [dB]
Babble	-13.44
SSN	-12.96

Tabla 12: Comparación cruzada de rendimiento del modelo AttSpecLSTM entrenado con distintas señales al evaluarse sobre señales distintas.

En la Tabla 12 se muestran los resultados obtenidos por el modelo AttLSTM en la comparación cruzada. Estos resultados representan una mejora significativa respecto al modelo DeepANC en su configuración más simple, demostrando que, incluso con una arquitectura mucho más compacta y sin requerir un entrenamiento conjunto sobre todos los escenarios, es posible alcanzar e incluso superar el rendimiento de dicho modelo. En particular, se observa que el modelo entrenado con la señal Factory generaliza de forma eficaz tanto a Babble como a SSN.

Como se aprecia en la Figura 34, donde se presentan los espectros de cancelación para Babble y SSN, se logra una atenuación significativa en un amplio rango de frecuencias. La cancelación en Babble resulta más efectiva debido a la similitud espectral con Factory, mientras que en SSN la reducción es algo más limitada, probablemente porque la energía está concentrada en frecuencias más bajas, región para la cual el modelo no fue específicamente entrenado. Estos resultados refuerzan la capacidad del modelo AttLSTM para generalizar y adaptarse, proponiéndose como la arquitectura más robusta de

entre todas las analizadas en ambas fases del estudio hasta el momento.




Figura 34: Espectros para Babble (arriba) y SSN (abajo) entrenados con Factory para AttLSTM.

4.2.7 Modelo 6: AttConvSpecLSTM

El siguiente modelo a evaluar es AttConvSpecLSTM, una variante del modelo ConvSpecLSTM que incorpora el mecanismo de atención.

Durante la Fase 1 de evaluación la inclusión del mecanismo de atención permitió una mejora ligera pero consistente en el desempeño del modelo en términos de NMSE. En este contexto, la evaluación de AttConvSpecLSTM nos permitirá verificar si estas ganancias se mantienen o incluso se amplifican en escenarios donde la estructura del ruido presenta mayor complejidad y variabilidad.

Señal de ruido	NMSE [dB]
Babble	-11.118
Factory	-10.78
SSN	-13.94

Tabla 13: Rendimiento del modelo AttConvSpecLSTM para distintas señales de ruido en Fase 2.

Se observan ligeras mejoras en el desempeño del modelo AttConvSpecLSTM respecto a su contraparte sin mecanismo de atención (ConvSpecLSTM), lo cual sugiere que la atención aporta cierto beneficio en la priorización de regiones relevantes de la señal. No obstante, el modelo aún se encuentra por debajo del rendimiento alcanzado por los modelos no espectrales como el LSTM puro, lo que indica que la integración espectral mediante convoluciones no necesariamente garantiza una mejor representación para la tarea de cancelación activa de ruido.

Además, a pesar de incorporar un módulo de atención, los resultados obtenidos por AttConvSpecLSTM son inferiores a los logrados por ProjSpecLSTM a pesar de incluir el mecanismo de atención. Esto sugiere que la codificación espectral ϕ mediante una proyección lineal podría estar proporcionando una representación temporal más adecuada para el procesamiento posterior por parte de la red LSTM, en comparación con la extracción de características mediante convoluciones.




Figura 35: Micrófono de cancelación en SSN para AttConvSpecLSTM.

A) NMSE entrenado con Babble

Señal de prueba	NMSE [dB]
Factory	-9.4
SSN	-8.02

B) NMSE entrenado con Factory

Señal de prueba	NMSE [dB]
Babble	-9.02
SSN	-7.88

Tabla 14: Comparación cruzada de rendimiento del modelo AttConvSpecLSTM entrenado con distintas señales al evaluarse sobre señales distintas.

4.2.8 Conclusión de resultados de la fase 2

Los resultados obtenidos en esta segunda fase permiten extraer conclusiones significativas sobre el comportamiento relativo de las diferentes arquitecturas evaluadas frente a señales de ruido reales.

Superioridad de los modelos temporales sobre los espectrales

Un hallazgo destacado es la superioridad sistemática de los modelos que procesan ventanas temporales directamente (LSTM y AttLSTM) frente a aquellos que emplean representaciones espectrales (ConvSpecLSTM, ProjSpecLSTM y AttConvSpecLSTM). Como se observa en la Tabla 15, los modelos temporales logran valores de NMSE consistentemente mejores en todas las señales evaluadas.

Esta diferencia de rendimiento sugiere que, para la tarea específica de cancelación activa de ruido con modelos compactos, el procesamiento directo de la información temporal preserva mejor las relaciones causales necesarias para una cancelación precisa. Las transformaciones espectrales, aunque conceptualmente atractivas, pueden introducir pérdidas de resolución temporal que comprometen la sincronización requerida para la interferencia destructiva efectiva.

Modelo	Babble [dB]	Factory [dB]	SSN [dB]
<i>Modelos Temporales</i>			
LSTM	-13.062	-11.76	-15.57
AttLSTM	-15.407	-14.42	-15.226
<i>Modelos Espectrales</i>			
ConvSpecLSTM	-11.353	-10.0	-12.329
ProjSpecLSTM	-11.756	-11.01	-14.5
AttConvSpecLSTM	-11.118	-10.78	-13.94

Tabla 15: Comparación entre modelos temporales y espectrales. En negrita los mejores resultados para cada señal.

Efectividad del mecanismo de atención

La incorporación del mecanismo de atención ha demostrado mejoras consistentes en todas las arquitecturas evaluadas. La Tabla 16 muestra cómo las variantes con atención superan sistemáticamente a sus contrapartes básicas. Estos resultados confirman que el mecanismo de atención permite a los

Arquitectura Base	Sin Atención	Con Atención
LSTM	-13.46	-15.02
ConvSpecLSTM	-11.23	-11.95

Tabla 16: Comparación del efecto del mecanismo de atención. Valores promedio de NMSE en dB.

modelos focalizar sus recursos computacionales en las regiones más relevantes de la secuencia de entrada, mejorando la capacidad de modelado sin incrementar significativamente la complejidad de la arquitectura.

Superioridad de la codificación proyectada en modelos espectrales

Dentro del subconjunto de modelos espectrales, ProjSpecLSTM ha demostrado un rendimiento superior a ConvSpecLSTM, como se evidencia en la Tabla 17. Esta mejora sugiere que la codificación mediante proyección lineal $\phi(\cdot)$ proporciona una representación espectral más eficaz que las convoluciones espaciales para esta aplicación específica.

Modelo	Babble [dB]	Factory [dB]	SSN [dB]
ConvSpecLSTM	-11.353	-10.0	-12.329
ProjSpecLSTM	-11.756	-11.01	-14.5

Tabla 17: Comparación entre enfoques de codificación espectral.

La ventaja de ProjSpecLSTM puede atribuirse a que la proyección lineal preserva mejor las relaciones temporales inherentes en el espectro, evitando las pérdidas de información que pueden introducir las operaciones convolucionales en el dominio frecuencial.

Capacidad de generalización excepcional del modelo AttLSTM

Un resultado particularmente notable es la capacidad de generalización demostrada por el modelo AttLSTM. Con aproximadamente más de 20 veces menos parámetros que DeepANC ($\sim 300k$ vs $\sim 8M$), este modelo logró superar el rendimiento del modelo de referencia no solo en entrenamiento específico, sino también en escenarios de generalización cruzada.

Como se observó en la Tabla 12, el modelo AttLSTM entrenado únicamente con la señal Factory alcanzó valores de NMSE de -13.44 dB en Babble y -12.96 dB en SSN, superando los resultados reportados para DeepANC (-12.08 dB y -12.53 dB respectivamente) que fue entrenado conjuntamente sobre todas las señales. Este resultado demuestra que la especialización arquitectónica y el entrenamiento específico pueden ser más efectivos que el escalado masivo de parámetros para tareas bien definidas.

Los resultados obtenidos en este estudio son consistentes con hallazgos recientes en este campo. Zhang et al. [5] reportaron resultados similares utilizando una ARN para ANC de baja latencia, donde su modelo ARN alcanzó valores de NMSE de -11.57 dB para Babble, -11.68 dB para SSN y -11.49 dB para Factory con frames de 4ms. Estos resultados, aunque ligeramente inferiores a los obtenidos por nuestro modelo AttLSTM (-15.407 dB, -15.226 dB y -14.42 dB respectivamente con frames mas grandes), confirman la efectividad de los mecanismos de atención en arquitecturas recurrentes para tareas de cancelación activa de ruido. La mejora adicional observada en nuestros modelos puede atribuirse tanto a las optimizaciones específicas en la arquitectura de atención implementada como a las diferencias en las estrategias de entrenamiento y procesamiento de señales empleadas.

Perspectivas para la siguiente fase

Los resultados de esta fase identifican claramente a AttLSTM y LSTM como las arquitecturas más prometedoras, combinando eficiencia computacional con capacidad de generalización superior. En la siguiente fase del estudio, estos dos modelos serán evaluados frente a señales significativamente más complejas y no estacionarias que las señales de “benchmarking” tradicionales utilizadas en esta fase, con el objetivo de verificar su robustez en condiciones acústicas extremadamente desafiantes.

Esta progresión metodológica permitirá establecer los límites operativos de estos modelos compactos y determinar su viabilidad para aplicaciones de cancelación activa de ruido en entornos acústicos altamente dinámicos e impredecibles.

4.3 Fase 3: Evaluación frente a ruido altamente aleatorio

Una vez realizado el análisis comparativo entre las distintas arquitecturas, se selecciona el modelo más simple y eficiente —la red LSTM sin componentes espectrales ni mecanismos de atención— para realizar las pruebas en condiciones acústicas significativamente más inestables. Esta elección responde tanto a su bajo costo computacional como a su rápida convergencia durante el entrenamiento.

En esta tercera fase, se evalúa el desempeño de dicho modelo frente a una señal de ruido caracterizada por una alta aleatoriedad y complejidad espectro-temporal, con el objetivo de analizar sus límites operativos y su capacidad de adaptación en escenarios no estructurados. Para reforzar su capacidad de modelado sin incrementar la complejidad estructural, se aumenta la dimensión interna del modelo (con `hidden_size = 20.417.856` parámetros), permitiendo una representación más expresiva de las dinámicas temporales.

La señal de ruido utilizada corresponde a una grabación ambiental realizada en un semáforo urbano situado en una ciudad altamente transitada. El fragmento fue extraído de una fuente de video pública [27], capturado en una intersección con alto flujo vehicular y peatonal en la ciudad de Lima, Perú. Esta señal presenta un comportamiento acústico mucho más impredecible que los ruidos utilizados en la fase anterior, como Babble o SSN.

A diferencia de los entornos controlados, la dinámica sonora de un entorno urbano abierto introduce una enorme variabilidad, tanto en frecuencia como en energía. En dicha señal pueden encontrarse eventos altamente transitorios e irregulares, tales como arranques de motores, frenazos súbitos, bocinas ocasionales, conversaciones espontáneas, gritos, pasos sobre el pavimento, e incluso elementos no repetitivos como sirenas o campanas. Esta composición acústica no sólo carece de una estructura espectral recurrente, sino que además involucra cambios abruptos en el contenido y nivel sonoro, lo que representa un reto extremo para los modelos de cancelación.




Figura 36: Espectro Señal de ruido en Lima.

La evaluación en este escenario tiene como propósito observar cómo responden ambos modelos —que demostraron excelente desempeño frente a ruido estructurado— cuando se enfrentan a condiciones realistas y no predecibles. Específicamente, se busca analizar si la capacidad de atención y modelado secuencial permite preservar el rendimiento observado anteriormente o si la aleatoriedad excesiva compromete significativamente la calidad de cancelación.

La evaluación se realiza en condiciones controladas dentro de una sala virtual con características

acústicas equivalentes a las utilizadas en la Fase 2, concretamente con un tiempo de reverberación $RT60 = 0,212s$ y una tasa de muestreo de $f_s = 3\text{ kHz}$. Esta configuración busca mantener la consistencia experimental, aislando el efecto del nuevo tipo de señal ruidosa como la principal fuente de variabilidad.

En primer lugar, se evaluará el modelo LSTM estándar, entrenado exclusivamente sobre la señal urbana descrita previamente. Para ello, se segmenta la grabación en fragmentos de entrada y salida siguiendo el mismo procedimiento de la Fase 2, utilizando ventanas deslizantes de longitud fija y solapamiento parcial.

Además, se aplican las mismas técnicas de aumento de datos previamente definidas para la Fase 2 con el objetivo de prevenir la memorización del modelo. La partición de datos se realiza de forma secuencial, destinando el 80 % inicial de la señal para entrenamiento y reservando el 20 % final como conjunto de prueba. Esta división permite evaluar el rendimiento del modelo en segmentos acústicos que no fueron vistos durante el entrenamiento, asegurando una medida realista de su capacidad de generalización dentro del mismo dominio.




Figura 37: Espectrograma de la señal de ruido de tráfico en Lima.

Los resultados obtenidos por el modelo LSTM en este entorno urbano aleatorio son notoriamente positivos, alcanzando una reducción de NMSE de -12.53 dB. A pesar de la complejidad espectro-temporal de la señal, el modelo logra mantener una cancelación efectiva a lo largo de toda la señal, lo que demuestra una capacidad destacable para adaptarse a patrones acústicos impredecibles sin necesidad de mecanismos explícitos de atención.

Los resultados indicados en la Tabla 18 muestran que el modelo LSTM mantiene un desempeño robusto frente a variaciones en el tiempo de reverberación, incluso cuando estas condiciones no fueron vistas durante el entrenamiento. La degradación del rendimiento es gradual y predecible, lo que su-

RT_{60} (s)	NMSE [dB]
0.19	-11.00
0.20	-12.02
0.212	-12.53
0.22	-12.05
0.23	-10.11

Tabla 18: Desempeño del modelo LSTM en entornos con diferentes tiempos de reverberación RT_{60} .

giere una adecuada generalización del modelo ante distintas condiciones acústicas. Sin embargo, en ambientes con reverberación algo más prolongada (como en el caso de $RT_{60} = 0,23$ s), el rendimiento comienza a deteriorarse más notablemente, lo que indica un límite operativo ante aumentos significativos en la persistencia del campo reverberante.

Para analizar la capacidad de generalización del modelo LSTM frente a ruido aleatorio no visto, se evaluó el mismo sobre una señal de tráfico capturada en Uttar Pradesh, India [28].




Figura 38: Espectrograma de la señal de ruido de tráfico en Uttar Pradesh.

A pesar de tratarse también de ruido urbano, la dinámica acústica difiere notablemente: el tráfico en India es más caótico, con eventos frecuentes como bocinas, aceleraciones y voces superpuestas. Esta señal presenta un entorno acústico aún más impredecible que el de Lima. La evaluación permite comprobar si el modelo entrenado en un país generaliza adecuadamente a condiciones de ruido similares pero con una dinámica completamente distinta.

El modelo LSTM logró alcanzar un **NMSE de -12.298 dB** al ser evaluado con una nueva señal de tráfico urbano grabada en Uttar Pradesh, India, una localización completamente distinta a la utilizada durante el entrenamiento. Este resultado es especialmente significativo si se considera que la dinámica sonora en este entorno es marcadamente diferente: se caracteriza por un flujo vehicular más caótico, un uso más frecuente e impredecible de bocinas, y una mayor densidad de eventos acústicos simultáneos.




Figura 39: Micrófono y espectro para la señal de ruido de tráfico de Uttar Pradesh con el modelo LSTM.

A pesar de estas diferencias, el modelo —entrenado únicamente con ruido urbano de una ciudad latinoamericana— fue capaz de mantener un nivel de cancelación comparable, lo que evidencia una capacidad de generalización robusta frente a variaciones geográficas y culturales en el patrón de ruido. El hecho de que logre predecir eficazmente fenómenos acústicamente tan dispares confirma su habilidad para capturar estructuras temporales generales del ruido debidas a la sala donde se realiza el control activo, más allá de particularidades locales o eventos específicos del entrenamiento.

En términos de eficiencia computacional, el modelo LSTM demostró ser altamente viable para su ejecución en tiempo real. Durante la evaluación, logró procesar cada ventana de 256 muestras, lo que equivale aproximadamente a 85 ms de audio, en un tiempo promedio de 0.8192 ms, permitiendo una implementación práctica en dispositivos de cómputo convencionales. Todas las pruebas se realizaron en una CPU Intel(R) Core(TM) i7-8565U @ 1.80GHz con 16 GB de RAM y almacenamiento SSD, sin aceleración por GPU. A pesar de tratarse de un entorno no especializado, el modelo mantuvo un rendimiento constante.

Capítulo 5:

Conclusiones y trabajo futuro

El presente trabajo ha demostrado de manera convincente la viabilidad de implementar sistemas de cancelación activa de ruido eficaces mediante arquitecturas de redes neuronales significativamente más simples que las propuestas en el estado del arte. Los resultados obtenidos confirman la hipótesis inicial de que es posible simplificar sustancialmente la complejidad arquitectónica sin comprometer el rendimiento, estableciendo nuevos paradigmas para el diseño de sistemas ANC computacionalmente eficientes.

5.1 Cumplimiento de los objetivos de investigación

Los objetivos planteados han sido satisfactoriamente alcanzados a través de una metodología experimental rigurosa y un análisis comparativo exhaustivo:

Análisis de modelos de referencia: se realizó un estudio detallado de la arquitectura DeepMCANC, identificando sus limitaciones computacionales ($\approx 8\text{M}$ parámetros) y estableciendo métricas de comparación que permitieron evaluar objetivamente las propuestas alternativas desarrolladas.

Diseño de arquitecturas simplificadas: se diseñaron y evaluaron cinco arquitecturas alternativas (LSTM, AttLSTM, ConvSpecLSTM, ProjSpecLSTM y AttConvSpecLSTM), logrando reducciones de hasta 26 veces en el número de parámetros (300k vs 8M) manteniendo o superando el rendimiento de referencia.

Análisis de representaciones de entrada: se condujo un estudio sistemático comparando representaciones temporales directas versus espectrales, revelando que las primeras preservan mejor las relaciones causales necesarias para la cancelación efectiva, contradiciendo asunciones previas sobre la superioridad de las representaciones frecuenciales.

Evaluación comparativa rigurosa: los experimentos cuantitativos demostraron que el modelo AttLSTM no solo supera a DeepANC en términos de NMSE, sino que además exhibe una capacidad de generalización excepcional, manteniendo rendimiento superior incluso cuando se entrena con una sola señal y se evalúa en otras.

Viabilidad práctica demostrada: se estableció la factibilidad de implementación en tiempo real, con

tiempos de procesamiento de 0.8192 ms por ventana de 85 ms de audio en hardware convencional, confirmando la aplicabilidad práctica de las soluciones propuestas.

5.2 Hallazgos principales

Los resultados han revelado tres conclusiones fundamentales que desafían paradigmas establecidos en el campo:

Superioridad del procesamiento temporal directo: contrariamente a la tendencia predominante hacia representaciones espectrales complejas, los modelos que procesan directamente ventanas temporales (LSTM, AttLSTM) demostraron consistentemente mejor rendimiento que sus contrapartes espectrales. Esta superioridad se atribuye a la preservación de las relaciones causales temporales críticas para la interferencia destructiva efectiva que son debidas principalmente a la sala de audición.

Eficacia de mecanismos de atención simples: la incorporación de mecanismos de atención demostró mejoras consistentes (-1.56 dB promedio) sin incrementar significativamente la complejidad computacional, validando su utilidad en arquitecturas compactas para ANC.

Codificación espectral optimizada: Dentro del subconjunto de modelos espectrales, la codificación mediante proyección lineal (ProjSpecLSTM) superó sistemáticamente a las aproximaciones convolucionales (ConvSpecLSTM), sugiriendo que la preservación de relaciones temporales es más crítica que la extracción de características espaciales en el dominio frecuencial.

Robustez frente a ruido altamente aleatorio: la evaluación con señales urbanas reales demostró que los modelos compactos mantienen rendimiento efectivo (-12.53 dB NMSE) incluso frente a ruido altamente impredecible, y exhiben capacidad de generalización notable (-12.298 dB en señal no vista de diferente procedencia).

5.3 Contribuciones al Desarrollo Sostenible

Este trabajo aporta contribuciones significativas a múltiples Objetivos de Desarrollo Sostenible de las Naciones Unidas, estableciendo un paradigma de innovación tecnológica sostenible:

Eficiencia Energética y Reducción de Emisiones (ODS 7, 13)

La reducción de hasta 26 veces en la complejidad computacional se traduce directamente en menor consumo energético durante la operación de sistemas ANC. Esta eficiencia es particularmente relevante en el contexto de dispositivos móviles y sistemas embebidos, donde el consumo energético impacta directamente la autonomía y la huella de carbono. La democratización de tecnologías ANC eficientes puede reducir significativamente el consumo energético agregado de millones de dispositivos de audio personales.

Innovación e Infraestructura Sostenible (ODS 9)

Las arquitecturas simplificadas facilitan la implementación de sistemas ANC en dispositivos con recursos limitados, promoviendo la innovación inclusiva y el acceso equitativo a tecnologías de reduc-

ción de ruido. Esta democratización tecnológica es especialmente valiosa en aplicaciones de transporte público, espacios laborales y entornos urbanos donde la cancelación activa representa una alternativa más eficiente que las soluciones pasivas tradicionales.

La cancelación activa de ruido presenta ventajas fundamentales sobre los métodos pasivos, particularmente en términos de eficiencia material y peso. Mientras que las soluciones pasivas requieren materiales densos y voluminosos para lograr atenuación efectiva, los sistemas ANC pueden alcanzar reducciones comparables o superiores con dispositivos ligeros y compactos. Esta eficiencia es crítica en aplicaciones donde el peso representa costes operativos adicionales o limitaciones de diseño.

Salud y Bienestar (ODS 3)

La exposición prolongada al ruido ambiental constituye un factor de riesgo reconocido para múltiples patologías, incluyendo estrés crónico, trastornos del sueño, hipertensión y deterioro cognitivo. Los sistemas ANC eficientes desarrollados en este trabajo pueden contribuir significativamente a la reducción de la contaminación acústica en entornos urbanos, mejorando la calidad de vida y reduciendo la incidencia de enfermedades relacionadas con el estrés acústico.

La implementación masiva de tecnologías ANC eficientes puede generar beneficios de salud pública mensurables, especialmente en poblaciones urbanas expuestas a altos niveles de ruido de tráfico y actividad industrial.

Ciudades y Comunidades Sostenibles (ODS 11)

La reducción de la contaminación acústica mediante tecnologías ANC eficientes contribuye directamente al desarrollo de entornos urbanos más habitables y sostenibles. La viabilidad económica y energética de las soluciones propuestas permite su integración en infraestructuras de transporte público, espacios de trabajo colaborativo y zonas residenciales, promoviendo el bienestar comunitario y la sostenibilidad urbana.

5.4 Trabajos Futuros

Los resultados obtenidos abren múltiples líneas de investigación prometedoras que pueden consolidar y expandir las contribuciones realizadas:

Exploración de Arquitecturas Ultra-Compactas

La demostración de que modelos simples pueden superar arquitecturas complejas sugiere la existencia de un espacio de diseño arquitectónico aún no explorado completamente. Futuras investigaciones podrían explorar arquitecturas con menos de 100k parámetros, investigando técnicas de cuantización, poda y destilación de conocimiento específicamente adaptadas para tareas ANC. La exploración de arquitecturas recurrentes alternativas como GRU o variantes especializadas podría revelar configuraciones aún más eficientes.

Codificaciones Espectrales Avanzadas

Aunque los modelos temporales demostraron superioridad, los resultados con ProjSpecLSTM sugieren que existen representaciones espectrales optimizadas que merecen investigación adicional. El desarrollo de codificaciones espectrales que preserven explícitamente las relaciones temporales, como transformadas tiempo-frecuencia adaptativas o representaciones espectrales dispersas, podría combinar las ventajas de ambos dominios.

La investigación en representaciones espectrales inspiradas en el procesamiento auditivo humano, como bancos de filtros gammatone o codificaciones basadas en la cóclea, podría revelar representaciones más naturales y eficientes para tareas ANC.

Implementación en Arquitecturas Embebidas

La validación de la viabilidad computacional en hardware convencional establece las bases para la implementación en sistemas embebidos especializados. Futuras investigaciones deberían abordar la optimización específica para procesadores de señal digital (DSP), unidades de procesamiento neuronal (NPU) y arquitecturas FPGA, donde las restricciones temporales son críticas.

El desarrollo de técnicas de inferencia de precisión fija, optimizaciones de memoria y paralelización específica para hardware embebido podría habilitar implementaciones en dispositivos con restricciones extremas de potencia y latencia.

Adaptación Dinámica y Aprendizaje Continuo

Los resultados de generalización obtenidos sugieren que los modelos compactos poseen capacidad de adaptación que podría explotarse mediante técnicas de aprendizaje continuo. La investigación en algoritmos de adaptación en línea que permitan la personalización automática a entornos acústicos específicos sin reentrenamiento completo representa una línea de investigación particularmente prometedora.

El desarrollo de métodos de meta-aprendizaje que permitan la adaptación rápida a nuevos tipos de ruido con mínimos datos de entrenamiento podría expandir significativamente la aplicabilidad práctica de las soluciones propuestas.

Validación en Condiciones Reales y Estudios de Usuario

Aunque las evaluaciones en simulación han demostrado la eficacia de las propuestas, la validación en condiciones reales mediante prototipos físicos y estudios de usuario representa un paso crítico hacia la adopción práctica. Futuras investigaciones deberían incluir evaluaciones psicoacústicas, estudios de aceptabilidad de usuario y análisis de rendimiento en condiciones ambientales variables.

Integración con Tecnologías Emergentes

La convergencia con tecnologías emergentes como procesamiento cuántico de señales, computación neuromórfica e inteligencia artificial explicable, podría abrir nuevas dimensiones de investigación.

La exploración de sinergias con estas tecnologías podría revolucionar tanto la eficiencia como las capacidades de los sistemas ANC futuros.

En conclusión, este trabajo ha establecido fundamentos sólidos para una nueva generación de sistemas ANC computacionalmente eficientes, demostrando que la simplicidad de la arquitectura, lejos de ser una limitación, puede constituir una ventaja competitiva significativa. Las líneas de investigación identificadas prometen consolidar estos avances y expandir su impacto hacia aplicaciones de relevancia social y ambiental.

Bibliografía

- [1] S. M. Kuo y D. R. Morgan, *Active Noise Control Systems: Algorithms and DSP Implementations*, Wiley, 1996.
- [2] Zhang, Y., Wang, Z., & Liu, H. (2019). Deep Learning for Active Noise Control. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 27(12), 1952-1962.
- [3] Elliott, S. J., & Nelson, P. A. (1987). A multiple error LMS algorithm and its application to the active control of sound and vibration. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 35(10), 1423-1434. DOI: 10.1109/TASSP.1987.1165054.
- [4] H. Zhang and D. Wang, "DeepMCANC: A deep learning approach to multi-channel active noise control," *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 30, pp. 2032–2042, 2022.
- [5] H. Zhang, A. Pandey, and D. L. Wang, "Low-Latency Active Noise Control Using Attentive Recurrent Network," *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 31, pp. 1114–1123, 2023.
- [6] S. Im, S. Kim, S. Woo, I. Jang, T. Han, U. Hwang, W.-S. Ohm, and M. Lee, "Deep learning-assisted active noise control in a time-varying environment," *Journal of Mechanical Science and Technology*, vol. 37, no. 3, pp. 1189–1196, 2023.
- [7] J. B. Allen and D. A. Berkley, *Image method for efficiently simulating small-room acoustics*, The Journal of the Acoustical Society of America, vol. 65, no. 4, pp. 943–950, 1979, doi: 10.1121/1.382599.
- [8] Hodgson, M., & Nosal, E. M. (2002). Reverberation time in enclosed spaces: From Sabine's empirical foundations to modern computational methods. *Journal of the Acoustical Society of America*, **111**(1), 1-14. DOI: 10.1121/1.1471360.
- [9] Y. Xia and C.-H. Jeong, *Room dimensions and absorption inference from room transfer function via machine learning*, arXiv preprint arXiv:2304.12993, 2023.
- [10] T. J. Cox and P. D'Antonio, *Porous Materials and Absorption Mechanisms*, The Journal of the Acoustical Society of America, vol. 125, no. 2, pp. 676–684, 2009, doi: 10.1121/1.3040232.
- [11] Elliott, S. J. (2001). *Signal Processing for Active Control*. London: Academic Press.
- [12] H. Bao and I. Panahi, *A perceptually motivated active noise control design and its psychoacoustic analysis*, ETRI Journal, vol. 35, no. 5, pp. 859–868, 2013. doi: 10.4218/etrij.13.0112.0822.

- [13] Shin, H., Kim, J., Choi, J. (2021). Deep Learning-Based Active Noise Control with Ultra-Low Latency for Real-Time Applications. *IEEE Transactions on Signal Processing*, 69, 2461-2475.
- [14] Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
- [15] Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer.
- [16] Masci, J., Meier, U., Cireşan, D., & Schmidhuber, J. (2011). *Stacked Convolutional Auto-Encoders for Hierarchical Feature Extraction*. In Artificial Neural Networks and Machine Learning – ICANN 2011 (pp. 52–59). Springer Berlin Heidelberg. DOI: 10.1007/978-3-642-21735-7_7
- [17] Kingma, D. P., & Ba, J. (2017). Adam: A Method for Stochastic Optimization. *arXiv preprint arXiv:1412.6980*. (Artículo fundacional que introduce el algoritmo Adam)
- [18] Reddi, S. J., Kale, S., & Kumar, S. (2018). *On the Convergence of Adam and Beyond*. International Conference on Learning Representations (ICLR).
- [19] S. Hochreiter and J. Schmidhuber, *Long Short-Term Memory*, Neural Computation, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.
- [20] MathWorks, “What Is Long Short-Term Memory (LSTM)?”, *MATLAB & Simulink*, disponible en: <https://in.mathworks.com/discovery/lstm.html>
- [21] Bengio, Y., Simard, P., & Frasconi, P. (1994). Learning long-term dependencies with gradient descent is difficult. *IEEE Transactions on Neural Networks*, 5(2), 157-166. DOI: 10.1109/72.279181
- [22] Chorowski, J. K., Bahdanau, D., Serdyuk, D., Cho, K., & Bengio, Y. (2015). Attention-Based Models for Speech Recognition. *Advances in Neural Information Processing Systems*, 28, 577-585.
- [23] Scheibler, R., Bezzam, E., & Dokmanić, I. (2018). Pyroomacoustics: A Python Package for Audio Room Simulation and Array Processing Algorithms. *IEEE ICASSP*, 351-355. DOI: 10.1109/ICASSP.2018.8461317.
Repositorio: <https://github.com/LCAV/pyroomacoustics>
- [24] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Kopf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai, and Soumith Chintala, *PyTorch: An Imperative Style, High-Performance Deep Learning Library*, Advances in Neural Information Processing Systems 32 (NeurIPS 2019), 2019.
- [25] Oppenheim, A. V., & Schafer, R. W. (1999). *Discrete-Time Signal Processing* (2nd ed.). Prentice Hall. (Capítulos 8-9: Tratamiento matemático de STFT y propiedades)
- [26] A. Varga and H. J. M. Steeneken, *NOISEX-92: A database and an experiment to study the effect of additive noise on speech recognition systems*, Available at: <https://github.com/speechdnn/Noises/blob/master/NoiseX-92>, Accessed: June 10, 2025.

- [27] The Sound of You (24 jun 2024). *City Ambience - Car Sounds - Horns - People Talking*. YouTube. https://www.youtube.com/watch?v=_1VIXOLyaUQ
- [28] City Soundscape India. “Real Indian Traffic Noise at Busy Intersection – Uttar Pradesh.” *YouTube*, 2023. Disponible en: <https://www.youtube.com/watch?v=iJZcjZD0fw0&t=8s>

Parte II

Anexos

Capítulo 6:

Anexo A: Explicaciones adicionales

El algoritmo empleado para actualizar los parámetros de una LSTM es el conocido como *Backpropagation Through Time* (BPTT), que extiende la retropropagación clásica al caso de redes con estructura secuencial. La idea central es desplegar la red en el tiempo y aplicar la regla de la cadena desde los últimos estados hacia los primeros, acumulando los gradientes que posteriormente serán utilizados para ajustar los pesos compartidos. El objetivo es calcular:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}} = \sum_{i=1}^N \frac{\partial \mathcal{L}_i}{\partial \mathbf{W}} \quad (6.1)$$

para cada conjunto de pesos $\mathbf{W}$ del modelo, incluyendo los pesos de las puertas de olvido, entrada, salida y de la celda candidata.

Dado que la salida de la red en el tiempo i se calcula a partir del estado oculto $\mathbf{h}_i$ como:

$$\hat{\mathbf{y}}_i = \mathbf{W}_Y \mathbf{h}_i + \mathbf{b}_Y, \quad (6.2)$$

el gradiente de la pérdida con respecto a la salida se propaga hacia atrás de la siguiente forma:

$$\frac{\partial \mathcal{L}_i}{\partial \hat{\mathbf{y}}_i} = \frac{2}{m} (\hat{\mathbf{y}}_i - \mathbf{y}_i), \quad (6.3)$$

por lo tanto, el gradiente respecto al estado oculto $\mathbf{h}_i$ resulta:

$$\frac{\partial \mathcal{L}_i}{\partial \mathbf{h}_i} = \mathbf{W}_Y^\top \frac{\partial \mathcal{L}_i}{\partial \hat{\mathbf{y}}_i}. \quad (6.4)$$

Este gradiente se propaga posteriormente hacia las puertas internas de la LSTM. En particular, el estado oculto está relacionado con la celda de memoria a través de:

$$\mathbf{h}_i = \mathbf{o}_i \odot \tanh(\mathbf{C}_i), \quad (6.5)$$

por lo que se tiene:

$$\frac{\partial \mathcal{L}_i}{\partial \mathbf{o}_i} = \frac{\partial \mathcal{L}_i}{\partial \mathbf{h}_i} \odot \tanh(\mathbf{C}_i), \quad (6.6)$$

$$\frac{\partial \mathcal{L}_i}{\partial \mathbf{C}_i} = \frac{\partial \mathcal{L}_i}{\partial \mathbf{h}_i} \odot \mathbf{o}_i \odot (1 - \tanh^2(\mathbf{C}_i)). \quad (6.7)$$

Dado que la celda de memoria se actualiza como:

$$\mathbf{C}_i = \mathbf{f}_i \odot \mathbf{C}_{i-1} + \mathbf{i}_i \odot \tilde{\mathbf{C}}_i, \quad (6.8)$$

el gradiente se propaga hacia el pasado con:

$$\frac{\partial \mathcal{L}_i}{\partial \mathbf{C}_{i-1}} = \frac{\partial \mathcal{L}_i}{\partial \mathbf{C}_i} \odot \mathbf{f}_i, \quad (6.9)$$

y se obtienen los gradientes para cada puerta de la siguiente manera:

$$\frac{\partial \mathcal{L}_i}{\partial \mathbf{f}_i} = \frac{\partial \mathcal{L}_i}{\partial \mathbf{C}_i} \odot \mathbf{C}_{i-1}, \quad \frac{\partial \mathcal{L}_i}{\partial \mathbf{i}_i} = \frac{\partial \mathcal{L}_i}{\partial \mathbf{C}_i} \odot \tilde{\mathbf{C}}_i, \quad \frac{\partial \mathcal{L}_i}{\partial \tilde{\mathbf{C}}_i} = \frac{\partial \mathcal{L}_i}{\partial \mathbf{C}_i} \odot \mathbf{i}_i. \quad (6.10)$$

Finalmente, dado que cada puerta tiene la forma general:

$$\mathbf{g}_i = \sigma(\mathbf{W}_G \mathbf{x}_i + \mathbf{W}_{Gh} \mathbf{h}_{i-1} + \mathbf{b}_G), \quad (6.11)$$

el gradiente respecto a sus pesos se calcula como:

$$\frac{\partial \mathcal{L}_i}{\partial \mathbf{W}_{G/h}} = \frac{\partial \mathcal{L}_i}{\partial \mathbf{g}_i} \odot \sigma'(\mathbf{W}_G \mathbf{x}_i + \mathbf{W}_{Gh} \mathbf{h}_{i-1} + \mathbf{b}_G) \odot \mathbf{x}_i / \mathbf{h}_{i-1}. \quad (6.12)$$

Este procedimiento se repite para cada instante i desde $i = N$ hasta $i = 1$, acumulando los gradientes correspondientes para cada parámetro del modelo.

6.1 Deconvolución de Wiener

La deconvolución de Wiener es una técnica utilizada para estimar la señal de entrada original de un sistema lineal a partir de su salida y de una respuesta impulsiva conocida, en presencia de ruido.

Formalmente, dado un sistema descrito por una convolución:

$$x_p[n] = x[n] * h[n] + \eta[n], \quad (6.13)$$

donde $h[n]$ es la respuesta al impulso del sistema y $\eta[n]$ es ruido aditivo, se desea recuperar una estimación de $x[n]$. Para ello, la deconvolución de Wiener proporciona una solución óptima en el sentido de mínimos cuadrados en frecuencia.

Este criterio de optimalidad se refiere a minimizar el error cuadrático medio (ECM) entre la señal original $x[n]$ y su estimación $\hat{x}[n]$, pero formulado en el dominio de la frecuencia. Bajo el supuesto de que tanto $x[n]$ como $\eta[n]$ son procesos estocásticos estacionarios, y que el sistema $h[n]$ es lineal e invariante en el tiempo (LTI), el problema puede plantearse como:

$$\min_{W(f)} \mathbb{E} \left[|X(f) - W(f)X_p(f)|^2 \right], \quad (6.14)$$

donde $X(f)$ y $X_p(f)$ son las transformadas de Fourier de $x[n]$ y $x_p[n]$, respectivamente, y $W(f)$ es un filtro complejo en frecuencia que actúa sobre $X_p(f)$ para estimar $X(f)$. La solución que minimiza este error es precisamente:

$$W(f) = \frac{H^*(f)}{|H(f)|^2 + \frac{S_\eta(f)}{S_x(f)}}, \quad (6.15)$$

donde:

- $H(f)$ es la transformada de Fourier de la respuesta impulsiva $h[n]$,
- $S_\eta(f)$ es la densidad espectral de potencia del ruido,
- $S_x(f)$ es la densidad espectral de potencia de la señal original,
- y $*$ denota conjugado complejo.

Esta expresión se interpreta como una inversión regularizada en frecuencia: si no hubiera ruido ($S_\eta(f) = 0$), se tendría una inversión directa del canal $1/H(f)$; sin embargo, en presencia de ruido, el denominador evita amplificaciones inestables y proporciona un equilibrio entre atenuar el ruido y preservar la señal.

En la práctica, este filtro se implementa eficientemente mediante transformadas rápidas de Fourier (FFT), aplicando $W(f)$ a la señal observada $x_p[n]$ en frecuencia y luego transformando de nuevo al dominio temporal. Esta técnica se ha aplicado en el presente proyecto para estimar la señal ideal de cancelación $y[n]$ a partir de la señal $x_p[n] = P\{x[n]\}$ y del RIR del camino secundario.

6.2 Transformada Discreta de Fourier (DFT)

La DFT es una herramienta fundamental en procesamiento de señales que permite transformar una señal del dominio temporal al dominio frecuencial. Su principal utilidad radica en descomponer una señal discreta en una combinación lineal de senos y cosenos (o exponenciales complejas), revelando así su contenido espectral.

6.2.1 Definición formal

Sea $\mathbf{x} = \{x_0, x_1, \dots, x_{n-1}\} \in \mathbb{R}^n$ una señal discreta de longitud n . La DFT de $\mathbf{x}$ es un vector complejo $\mathbf{X} = \{X_0, X_1, \dots, X_{n-1}\} \in \mathbb{C}^n$, definido por la expresión:

$$X_k = \sum_{t=0}^{n-1} x_t \cdot e^{-2\pi i \frac{kt}{n}}, \quad k = 0, 1, \dots, n-1. \quad (6.16)$$

Cada componente X_k representa la contribución de la frecuencia $\frac{k}{n}$ a la señal original. La DFT es una transformación lineal que puede representarse matricialmente como $\mathbf{X} = \mathbf{F}_n \mathbf{x}$, donde $\mathbf{F}_n$ es la matriz de Fourier de tamaño $n \times n$.

La inversa de la DFT permite reconstruir la señal original a partir de su representación espectral, y está dada por:

$$x_t = \frac{1}{n} \sum_{k=0}^{n-1} X_k \cdot e^{2\pi i \frac{kt}{n}}, \quad t = 0, 1, \dots, n-1. \quad (6.17)$$

6.2.2 Propiedad de simetría hermítica

Cuando la señal de entrada x es real, su DFT cumple una propiedad importante denominada *simetría hermítica*. Esta propiedad establece que los coeficientes del espectro complejo están relacionados por:

$$X_{n-k} = \overline{X_k}, \quad \text{para } k = 1, \dots, \frac{n}{2} - 1, \quad (6.18)$$

donde $\overline{X_k}$ denota el complejo conjugado de X_k . Como consecuencia, la segunda mitad del espectro (exceptuando posiblemente $X_{n/2}$) no aporta nueva información y es redundante. Por lo tanto, en el caso de señales reales, es habitual trabajar únicamente con los primeros $\frac{n}{2} + 1$ coeficientes, que contienen toda la información necesaria para la reconstrucción completa de la señal.

6.2.3 Transformada Rápida de Fourier (FFT)

El cálculo directo de la DFT requiere $\mathcal{O}(n^2)$ operaciones, lo cual es computacionalmente costoso para señales largas. La *Transformada Rápida de Fourier* (FFT) es un algoritmo eficiente que permite calcular la DFT con una complejidad computacional reducida a $\mathcal{O}(n \log n)$. Existen diversas variantes del algoritmo FFT (Cooley-Tukey, Radix-2, etc.), pero todas comparten el principio de aprovechar simetrías y redundancias en la DFT para minimizar el número de operaciones requeridas.

Gracias a la FFT, el análisis espectral de señales se vuelve práctico incluso en contextos en tiempo real o sobre grandes volúmenes de datos, como es el caso del procesamiento de señales acústicas en redes neuronales.

6.3 Algoritmo LMS

El algoritmo *Least Mean Squares* (LMS) es uno de los métodos adaptativos más ampliamente utilizados para problemas de filtrado y control en sistemas en tiempo discreto. Su objetivo principal es adaptar de forma iterativa los coeficientes de un filtro lineal para minimizar el error cuadrático medio (MSE) entre la señal deseada y la salida del filtro. Es la base de muchos algoritmos posteriores, incluido el FxLMS.

Formulación general

Sea una señal de entrada $x[n] \in \mathbb{R}$, y un filtro adaptativo FIR de orden $L - 1$ caracterizado por un vector de pesos $\mathbf{w}[n] \in \mathbb{R}^L$. Se define el vector de entrada como:

$$\mathbf{x}[n] = [x[n], x[n-1], \dots, x[n-L+1]]^T. \quad (6.19)$$

La salida del filtro en el instante n se expresa como el producto interno entre el vector de pesos y el vector de entrada:

$$y[n] = \mathbf{w}^T[n] \cdot \mathbf{x}[n]. \quad (6.20)$$

Sea $d[n]$ la señal deseada (por ejemplo, una señal limpia o de referencia), el error instantáneo se define como:

$$e[n] = d[n] - y[n]. \quad (6.21)$$

El objetivo del algoritmo es minimizar el valor esperado del error cuadrático:

$$J = \mathbb{E}[e^2[n]]. \quad (6.22)$$

Regla de actualización

El algoritmo LMS aplica un descenso de gradiente estocástico sobre J , aproximando su gradiente mediante el valor instantáneo. La regla de actualización del vector de pesos se expresa como:

$$\mathbf{w}[n+1] = \mathbf{w}[n] + \mu \cdot e[n] \cdot \mathbf{x}[n], \quad (6.23)$$

donde $\mu > 0$ es la tasa de aprendizaje (también llamada paso de adaptación), que regula la velocidad de convergencia del algoritmo.

Convergencia y estabilidad

Para asegurar la estabilidad y convergencia del algoritmo LMS en media, se debe elegir un valor de μ tal que:

$$0 < \mu < \frac{2}{\lambda_{\max}}, \quad (6.24)$$

donde $\lambda_{\max}$ representa el valor propio máximo de la matriz de correlación $\mathbf{R} = \mathbb{E}[\mathbf{x}[n]\mathbf{x}^T[n]]$. En la práctica, como $\lambda_{\max}$ no suele conocerse, se utiliza una cota basada en la potencia de la señal:

$$0 < \mu < \frac{2}{\text{tr}(\mathbf{R})} \approx \frac{2}{L \cdot P_x}, \quad (6.25)$$

donde P_x es la potencia promedio de la señal $x[n]$.

Ventajas y limitaciones

El LMS es computacionalmente eficiente (requiere aproximadamente $2L$ operaciones por muestra), fácil de implementar y robusto ante ciertas condiciones de ruido. Sin embargo, presenta limitaciones importantes:

- Su velocidad de convergencia depende fuertemente de la elección de μ y de la correlación entre las muestras de entrada.
- No es adecuado cuando la salida del filtro se ve afectada por un canal o sistema adicional (como ocurre en el control activo de ruido con entornos acústicos), ya que no contempla distorsiones posteriores.
- Suponiendo linealidad y estacionariedad del entorno, el LMS converge en media al valor óptimo, pero es sensible a retardos y no puede modelar efectos acústicos como reverberaciones si no se modifican sus supuestos.

Estas deficiencias motivan la necesidad de algoritmos modificados, como el FxLMS, que extienden su aplicabilidad a escenarios donde se requiere tener en cuenta dinámicas externas adicionales, como el camino secundario en sistemas ANC.

6.4 Algoritmo FxLMS

El algoritmo *Filtered-x Least Mean Squares* (FxLMS) constituye una extensión del clásico algoritmo LMS (Least Mean Squares) adaptado específicamente para entornos de ANC en configuraciones feedforward. Su objetivo es minimizar el contenido de ruido residual en un micrófono de error mediante la emisión de una señal de cancelación desde un actuador (típicamente un altavoz secundario), aprendiendo de forma adaptativa la respuesta óptima.

A diferencia del LMS estándar, el algoritmo FxLMS tiene en cuenta explícitamente la distorsión introducida por el llamado *camino secundario*—esto es, la respuesta acústica y electroacústica entre el actuador de cancelación y el micrófono de error. Esta incorporación es crucial para mantener la estabilidad y convergencia del sistema de control, ya que el LMS tradicional asume un canal de salida sin distorsión, lo cual no se cumple en escenarios físicos reales.

Configuración general del sistema ANC

Un sistema ANC feedforward típico basado en FxLMS puede representarse por el siguiente diagrama de bloques:

Los principales elementos del sistema son:

- $x[n]$: señal de referencia (ruido antes de alcanzar el oyente).
- $y[n]$: señal de control emitida por el altavoz secundario.
- $e[n]$: señal de error registrada en el micrófono.




Figura 40: Diagrama de FxLMS

- $\hat{y}[n] = y[n] * \hat{s}[n]$: señal de control filtrada a través de una estimación del camino secundario.
- $d[n]$: ruido original presente en el micrófono sin cancelación.
- $\hat{s}[n]$: estimación del camino secundario $s[n]$, necesaria para la correcta adaptación.
- $\mathbf{w}[n]$: vector de pesos adaptativos del filtro.

Formulación matemática del algoritmo

La señal de control se genera a partir de la convolución discreta entre la señal de entrada y un filtro FIR adaptativo $\mathbf{w}[n]$ de longitud L . Formalmente, la salida del sistema es:

$$y[n] = \sum_{k=0}^{L-1} w_k[n] \cdot x[n-k] = \mathbf{w}^T[n] \cdot \mathbf{x}[n], \quad (6.26)$$

donde:

$$\mathbf{x}[n] = [x[n], x[n-1], \dots, x[n-L+1]]^T. \quad (6.27)$$

Sin embargo, dado que la señal de control pasa por un entorno acústico (camino secundario $s[n]$), la señal que finalmente llega al micrófono es:

$$\hat{y}[n] = y[n] * s[n]. \quad (6.28)$$

El error residual observado en el micrófono es entonces:

$$e[n] = d[n] - \hat{y}[n] = d[n] - (y[n] * s[n]). \quad (6.29)$$

Para evitar la necesidad de conocer exactamente $s[n]$, el algoritmo FxLMS emplea una estimación $\hat{s}[n]$, obtenida típicamente mediante técnicas de identificación del canal o medición directa. La señal de referencia es filtrada a través de $\hat{s}[n]$, dando lugar a la señal llamada *Filtered-x*:

$$\tilde{x}[n] = x[n] * \hat{s}[n]. \quad (6.30)$$

El vector de entrada filtrado se define como:

$$\tilde{\mathbf{x}}[n] = [\tilde{x}[n], \tilde{x}[n-1], \dots, \tilde{x}[n-L+1]]^T. \quad (6.31)$$

Regla de actualización

El vector de pesos se actualiza siguiendo la regla descendente del gradiente estocástico aplicada sobre el error $e[n]$:

$$\mathbf{w}[n+1] = \mathbf{w}[n] + \mu \cdot e[n] \cdot \tilde{\mathbf{x}}[n], \quad (6.32)$$

donde μ es el paso de adaptación o *tasa de aprendizaje*, cuya magnitud afecta directamente la velocidad de convergencia y la estabilidad del algoritmo. Este esquema de adaptación tiene como objetivo minimizar el error cuadrático esperado:

$$J = \mathbb{E}[e^2[n]]. \quad (6.33)$$

La actualización dada por (6.32) se obtiene al aproximar el gradiente de J por el gradiente instantáneo:

$$\nabla J \approx -e[n] \cdot \tilde{\mathbf{x}}[n]. \quad (6.34)$$

Estabilidad y convergencia

Para asegurar la convergencia en media del algoritmo FxLMS, se deben cumplir ciertas condiciones sobre el tamaño del paso de aprendizaje μ . En general, se requiere:

$$0 < \mu < \frac{2}{P}, \quad (6.35)$$

donde P es la potencia promedio de la señal $\tilde{x}[n]$. En la práctica, debido a la presencia de retardos, errores en la estimación de $\hat{s}[n]$, y la posible no linealidad del camino secundario real, se recomienda utilizar valores conservadores de μ para evitar inestabilidades.

Limitaciones del modelo

El algoritmo FxLMS, aunque robusto y de fácil implementación, presenta varias limitaciones en escenarios reales:

- Su rendimiento decae significativamente en entornos con alta reverberación o múltiples trayectorias acústicas reflejadas.

- No es capaz de modelar estructuras no lineales ni dinámicas temporales complejas fuera del alcance del filtro FIR.
- La estimación del camino secundario $\hat{s}[n]$ es crítica: errores en este modelo se traducen directamente en pérdidas de cancelación o incluso en amplificación del ruido.
- La respuesta adaptativa es lenta frente a señales no estacionarias, especialmente si el contenido espectral cambia bruscamente (como se observó en la Fase 1 del experimento).

Estas limitaciones han motivado la exploración de técnicas más avanzadas de aprendizaje automático y redes neuronales profundas, capaces de modelar relaciones temporales de largo alcance, no linealidades y adaptaciones rápidas a entornos dinámicos.