

Navegación

Ir a:

- Inicio
- Línea Temporal
- Explorador
- Comparativa
- Visualizaciones
- Conclusiones

TFG 2025-26
Detección de Defectos Industriales
Vision Transformers vs CNNs

Detección de Defectos Industriales

Comparativa de Arquitecturas: Vision Transformers vs CNNs

0.785

mAP Mejor Modelo (DEIMv2)

8

Experimentos Realizados

3

Arquitecturas Evaluadas

Contexto de la Investigación

Este proyecto de investigación evalúa y compara diferentes arquitecturas de deep learning para la **detección de defectos en componentes industriales**. El objetivo principal es determinar qué tipo de arquitectura ofrece mejor rendimiento para este problema específico de visión por computador.

Dataset utilizado: Conjunto curado de imágenes industriales con 6 tipos de defectos: NORMAL (sin defectos), DEFORMACIONES, ROTURA/FRACTURA, RAYONES/ARAÑAZOS, PERFORACIONES y CONTAMINACIÓN. El dataset presenta alta variabilidad en iluminación, escalas y tipos de superficies.

Metodología de Experimentación

La experimentación se ha dividido en **4 fases principales**:

- Fase 1 (Octubre 2025):** Establecer líneas base con arquitecturas CNN clásicas (ResNet-18, EfficientNet-B0)
- Fase 2 (Noviembre 2025):** Explorar Vision Transformers (DEIMv2) con diferentes configuraciones
- Fase 3 (Diciembre 2025):** Validar resultados entrenando CNNs con la misma resolución que los ViTs
- Fase 4 (Diciembre 2025):** Validación de robustez del mejor modelo con score thresholds altos

Para cada experimento, el **mejor checkpoint** se selecciona según:

- CNNs (ResNet/EfficientNet): Menor pérdida de validación (val_loss)
- ViTs (DEIMv2): Mayor mAP@0.5 en el conjunto de validación

Arquitecturas Evaluadas

ResNet-18

Tipo: CNN (Red Neuronal Convocional)

Año: 2015 (Microsoft Research)

Características:

- 18 capas con conexiones residuales
- Bias inductivo fuerte (localidad espacial)
- Convergencia rápida (~50 epochs)
- 11M parámetros

Detector: Faster R-CNN

EfficientNet-B0

Tipo: CNN con escalado compuesto

Año: 2019 (Google Brain)

Características:

- Escalado balanceado de profundidad/anchura
- Optimizada para resoluciones 224-380px
- Muy eficiente en parámetros
- 5M parámetros

Detector: Faster R-CNN

DEIMv2 (Vision Transformer)

Tipo: Transformer para detección en tiempo real

Año: 2024-2025

Características:

- Backbone DINOv3 (ViT preentrenado)
- Atención global desde el inicio
- Convergencia lenta (~150-200 epochs)
- ~17M parámetros

Detector: DEIM Decoder

Enfoque en DEIMv2: Estado del Arte en Detección en Tiempo Real

DEIMv2 es una arquitectura de detección de objetos en tiempo real que combina:

- DINOv3:** Backbone de Vision Transformer preentrenado con auto-supervisión en grandes datasets
- DEIM (Dense Enhanced Image Matching):** Framework de entrenamiento optimizado para DETRs
- Spatial Tuning Adapter (STA):** Convierte la salida de escala única de DINOv3 en features multi-escala

Según el paper científico de DEIMv2, esta arquitectura logra resultados estado del arte en el benchmark COCO:

- DEIMv2-S: Primer modelo sub-10M en superar 50 AP en COCO
- DEIMv2-X: 57.8 AP con solo 50.3M parámetros

La clave del éxito de los Vision Transformers en detección es su capacidad de capturar **relaciones espaciales globales** desde las primeras capas, a diferencia de las CNNs que construyen el contexto gradualmente a través de convoluciones locales.

Resultado clave: En nuestro problema de detección de defectos industriales, DEIMv2 alcanzó un mAP de 0.785, superando significativamente a las arquitecturas CNN que obtuvieron máximos de 0.08-0.16.